



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



UNIVERSITAT POLITÈCNICA DE VALÈNCIA

Escuela Técnica Superior de Ingeniería Informática

Análisis y Generación de discursos en el contexto electoral
estadounidense: una aproximación a las estrategias
discursivas de Donald Trump

Trabajo Fin de Grado

Grado en Ingeniería Informática

AUTOR/A: García Esparter, Pau

Tutor/a: Martínez Plumed, Fernando

CURSO ACADÉMICO: 2024/2025

Resum

Donald Trump va aconseguir derrotar a Kamala Harris durant les eleccions estatunidenques de 2024. La explicabilitat d'esta victòria és multifactorial però una de les perspectives més interessants i inexplorades de la seua victòria ha sigut l'anàlisi dels seus discursos més enllà de les seues propostes. La forma en la qual transmet sentiments, realitats i preocupacions és fonamental per a entendre el seu èxit en les eleccions.

Este treball té com a objecte analitzar, mitjançant models d'anàlisi de sentiments i de classificació de temàtiques, els discursos de Donald Trump durant la seua campanya electoral prèvia a les eleccions. A partir de la llum llançada per estes dades es pretén generar discursos electorals que puguem transmetre emocions i temàtiques determinades de manera adequada per al context estatunidenc.

El treball s'estructura en 3 fases. Una primera fase de neteja dels discursos i creació del dataset de discursos. Una segona fase d'anàlisi descriptiva mitjançant les ferramentes de sentiments i temàtiques. Finalment, una tercera fase d'enriquiment de la IA generativa amb les dades obtingudes en les dos fases anteriors per a obtindre discursos adequats.

Paraules clau: Anàlisi de sentiments, classificació de temàtiques, discursos, campanya electoral, Donald Trump

Resumen

Donald Trump consiguió derrotar a Kamala Harris durante las elecciones estadounidenses de 2024. La explicabilidad de esta victoria es multifactorial pero una de las perspectivas más interesantes e inexploradas de su victoria ha sido el análisis de sus discursos más allá de sus propuestas. La forma en la que transmite sentimientos, realidades y preocupaciones es fundamental para entender su éxito en las elecciones.

Este trabajo tiene como objeto analizar, mediante modelos de análisis de sentimientos y de clasificación de temáticas, los discursos de Donald Trump durante su campaña electoral previa a las elecciones. A partir de la luz arrojada por estos datos se pretende generar discursos electorales que puedan transmitir emociones y temáticas determinadas de forma adecuada para el contexto estadounidense.

El trabajo se estructura en 3 fases. Una primera fase de limpieza de los discursos y creación del dataset de discursos. Una segunda fase de análisis descriptivo mediante las herramientas de sentimientos y temáticas. Por último, una tercera fase de enriquecimiento de la IA generativa con los datos obtenidos en las dos fases anteriores para obtener discursos adecuados.

Palabras clave: Análisis de sentimientos, clasificación de temáticas, discursos, campaña electoral, Donald Trump

Abstract

Donald Trump managed to defeat Kamala Harris during the 2024 US elections. The explainability of this victory is multifactorial but one of the most interesting and unexplored perspectives of his victory has been the analysis of his speeches beyond his proposals. The way in which he conveys feelings, realities and concerns is fundamental to understanding his success in the elections.

This paper aims to analyse, using sentiment analysis and issue classification models, Donald Trump's speeches during his pre-election campaign. From the light shed by

these data, the aim is to generate electoral speeches that can convey emotions and themes determined in a way that is appropriate for the American context.

The work is structured in three phases. A first phase of cleaning of the speeches and creation of the speech dataset. A second phase of descriptive analysis using the sentiment and thematic tools. Finally, a third phase of enrichment of the generative AI with the data obtained in the two previous phases in order to obtain suitable discourses.

Key words: Sentiment analysis, topic classification, speeches, electoral campaign, Donald Trump

Índice general

Índice general	V
Índice de figuras	IX
Índice de tablas	X
1 Introducción	1
1.1 Motivación	1
1.2 Objetivos	2
1.3 Contribuciones	3
1.4 Estructura del documento	3
2 Estado del arte	5
2.1 Evolución del análisis con PLN	5
2.1.1 Modelos basados en LDA	5
2.1.2 Modelos basados en clasificación predeterminada	6
2.1.3 Modelos basados en zero shot classification	6
2.2 Análisis políticos con PLN	7
2.2.1 Análisis de política global	7
2.2.2 Análisis de política estadounidense	7
2.3 Generación de discursos mediante IA	8
2.4 Análisis crítico del estado del arte	8
3 Herramientas utilizadas	9
3.1 Base de datos	9
3.1.1 Microsoft Excel	9
3.1.2 SQLite	9
3.2 Lenguaje de programación	10
3.2.1 Python	10
3.2.2 Gestión de archivos y entorno	10
3.2.3 Almacenamiento y manipulación de datos	11
3.2.4 Extracción y Limpieza de contenido	11
3.2.5 Embeddings y recuperación semántica	12
3.2.6 Modelado	12
3.2.7 Utilidades de proceso	12
3.3 Plataforma	14
3.3.1 Visual Studio Code	14
3.4 Herramientas de análisis	14
3.4.1 Herramientas de análisis estadístico	14
3.4.2 Herramientas de análisis gráfico	16
4 Diseño de la solución	17
4.1 Elección y descripción de modelos	17
4.2 Modelo de clasificación de temáticas	17
4.2.1 Selección de etiquetas para el modelo de temáticas	18
4.2.2 Descripción de las temáticas	19
4.3 Modelo de análisis de emociones	22

4.3.1	Descripción de las emociones	23
4.4	Modelo de análisis de sentimiento	25
4.4.1	Descripción de los estados del sentimiento	25
4.5	Selección de los discursos	26
4.5.1	Periodo a considerar	27
4.5.2	Obtención de los discursos	28
4.6	Procesamiento de textos	30
4.6.1	Signos de puntuación	30
4.6.2	Stop words	31
4.6.3	Chunks	31
4.6.4	Conclusión de la discusión del tratamiento	33
4.7	Diseño de la base de datos	33
4.7.1	Descripción de la base de datos	33
4.7.2	Diagrama de clases	34
4.7.3	Diagrama relacional	35
4.7.4	Acceso a la base de datos	35
4.8	Diseño de embeddings para la recuperación de fragmentos	36
4.9	Modelos de lenguaje para la generación de discursos	36
4.9.1	Prompting	36
4.10	Evaluación de los discursos generados	38
4.10.1	Diseño de la encuesta de verificación	39
5	Desarrollo de la solución	41
5.1	Obtención de las transcripciones	41
5.2	Procesado de texto	42
5.2.1	Corchetes e interpelaciones	42
5.2.2	Chunks y solapamiento	42
5.3	Configuración de modelos	43
5.3.1	Bart Large MNLI	43
5.3.2	Distil RoBERTa Emotion	44
5.3.3	RoBERTa Sentiment	44
5.3.4	Ejecución de los modelos	45
5.4	Base de datos	45
5.4.1	Creación y definición de la base de datos	45
5.4.2	Carga de la base de datos	46
5.5	Generación de embeddings con Mini-LM	46
5.6	Construcción del índice semántico FAISS	47
5.7	Generación de discursos con GPT-4	47
6	Análisis de resultados	49
6.1	Análisis de los discursos de Trump	49
6.1.1	Análisis de frecuencia de los atributos	49
6.1.2	Análisis de correlación entre temáticas y entre emociones	52
6.1.3	Análisis cruzado de correlación de los atributos	54
6.1.4	Análisis por Estados	57
6.1.5	Evolución temporal de los atributos	60
6.1.6	Análisis del impacto del intento de homicidio	64
6.2	Análisis de la generación de discursos mediante IA	67
6.2.1	Resultados generales de acierto	68
6.2.2	Cambios en la percepción de seguridad	69
6.2.3	Resultados por poblaciones	70
6.2.4	Análisis de Correlación por Spearman	74
7	Conclusiones	77

7.1 Ampliaciones y estudios futuros	78
---	----

Apéndice	
A Anexos	83
A.1 Recogida de datos	83
A.2 Test de verificación	84
A.3 Respuestas del test	87
A.4 Abreviaturas de los estados	87
A.5 Acceso público a la base de datos de los discursos	87
Anexo B – Relación del TFG con los ODS	88

Índice de figuras

4.1	Diagrama de clases de la base de datos	34
4.2	Esquema relacional de la tabla Fragment	35
4.3	Esquema relacional de la tabla Discourse	35
4.4	Método de acceso a la base de datos	36
5.1	Código de detección del autor	41
5.2	Código de detección del fragmento	41
5.3	Código de eliminación de corchetes e interpelaciones	42
5.4	Código de segmentación del texto en <i>chunks</i>	43
5.5	Código de asignación de etiquetas	43
5.6	Código de llamada al classifier	44
5.7	Código de configuración del classifier	44
5.8	Código de configuración del modelo de emociones	44
5.9	Código de configuración del modelo de sentimiento	45
5.10	Código de conexión y creación de la base de datos	45
5.11	Código de configuración de la base de datos	46
5.12	Código de carga de la base de datos	46
5.13	Código de generación de <i>embeddings</i>	47
5.14	Código de generación el índice FAISS	47
5.15	Código de recuperación de fragmentos	48
5.16	Código de envío del prompt	48
5.17	Parte de un discurso impreso por terminal	48
6.1	<i>Heatmap</i> de Correlación entre las emociones	52
6.2	<i>Heatmap</i> de correlación entre las temáticas	53
6.3	<i>Heatmap</i> de correlación entre emociones y sentimientos	54
6.4	<i>Heatmap</i> de correlación entre emociones y temáticas	56
6.5	Número de discursos por estado	57
6.6	Tabla de correlación entre temáticas y estados	58
6.7	Tabla de correlación entre emociones y estados	59
6.8	Gráfico de evolución mensual de las emocionales	60
6.9	Gráfico de evolución mensual del sentimiento	61
6.10	Gráfico de evolución mensual de las temáticas	61
6.11	Clasificación promedio según el tipo real del discurso.	68
6.12	Distribución de participantes por rango de edad de un total de 108 encuestados	70
6.13	Porcentaje de aciertos en la identificación de discursos generados por IA con y sin fragmentos, agrupado por edad.	71
6.14	Porcentaje de aciertos en la identificación de discursos generados por IA con y sin fragmentos, agrupado por nivel de información acerca de los discursos Trump (1–5).	72
6.15	Porcentaje de aciertos en la identificación de discursos generados por IA con y sin fragmentos, agrupado por nivel de simpatía (1–6).	72

6.16	Porcentaje de aciertos en la identificación de discursos generados por IA con y sin fragmentos, agrupado por familiaridad con IA.	73
6.17	Porcentaje de aciertos en la identificación de discursos generados por IA con y sin fragmentos, agrupado por nivel de escepticismo (2–5).	74

Índice de tablas

3.1	Librerías de Python utilizadas en el proyecto.	13
4.1	Discursos de Trump en campaña	28
6.1	Valores medios por temática en los discursos	49
6.2	Temática predominante por fragmento (%)	50
6.3	Valores medios por emoción en el conjunto de datos	50
6.4	Emoción predominante por fragmento (%)	50
6.5	Valores medios por sentimiento en el conjunto de datos	51
6.6	Tendencias lineales de emociones	62
6.7	Tendencias lineales de sentimientos	62
6.8	Tendencias lineales de temáticas	62
6.9	Correlación de emociones con el paso del tiempo	63
6.10	Correlación de sentimientos con el paso del tiempo	63
6.11	Correlación de temáticas con el paso del tiempo	63
6.12	Comparación entre los discursos del 20 y 24 de julio y la media total sin incluir el discurso de vuelta y el del ataque	64
6.13	Medias de variables: total, pre y post intento	66
6.14	Correlación de variables con el tiempo: total vs. post intento	67
6.15	Respuestas por discurso individual: número de clasificaciones como Trump o IA, y aciertos.	68
6.16	Media del nivel de certeza (1 a 5) entre los participantes que acertaron o fallaron en la identificación de discursos generados por IA.	69
6.17	Correlaciones de Spearman: valores p y coeficientes ρ entre variables personales y acierto de la IA con y sin fragmentos. En negrita, las correlaciones estadísticamente significativas ($p < 0,05$).	74
A.1	Relación entre los discursos utilizados y su fuente	87
A.2	Correspondencia entre abreviaturas y nombres completos de los estados representados en la Figura 6.5.	87
A.3	Grado de relación del TFG con los Objetivos de Desarrollo Sostenible	88

CAPÍTULO 1

Introducción

El 5 de Noviembre de 2024 se confirmó la victoria de Donald Trump sobre Kamala Harris en las elecciones presidenciales de Estados Unidos. Trump es, probablemente, una de las figuras más controvertidas del siglo XXI y muchas explicaciones se han intentado dar a su éxito en la carrera presidencial. Sin embargo, a menudo no se tiene en cuenta sus estrategias discursivas dentro de sus polémicos mítines. La explicabilidad de su triunfo es multifactorial, pero gracias a las tecnologías que nos proporciona la Inteligencia Artificial [1], podemos indagar más sobre el impacto de los mensajes y la forma en la que son transmitidos en plena campaña electoral.

En un contexto político cada vez más polarizado y agresivo, resulta fundamental entender la comunicación que utilizan los candidatos para llegar a su electorado. Pudiendo discernir cuáles son las temáticas que mayor preocupación de la población, podemos entender cómo los políticos impactan en ellas para conseguir el mayor número de votos posibles. Por otro lado, entendiendo los sentimientos que se transmiten en los discursos, podemos identificar cómo los políticos instrumentalizan las emociones para resaltar las temáticas o problemas que les interesan. Esta información permite ir más allá de los típicos análisis políticos, permite ver cuáles son las estrategias más comunes, y hasta el momento exitosas, que utilizan los políticos para influenciar nuestro voto.

En otro prisma, el trabajo de fin de grado también pretende tener una aplicación práctica. No quedarse en el mero análisis, sino utilizar los datos extraídos de los discursos para permitir crear discursos políticos desde 0 con mayor precisión. Enriquecer modelos existentes con los datos de un político real como Donald Trump, para que cualquier persona pueda plasmar sus ideas de forma política y pueda conocer cómo llegar a la gente.

El trabajo se centrará de forma exclusiva en el contexto estadounidense y Donald Trump. Sin embargo, el proceso, la metodología y las herramientas utilizadas son extrapolables a cualquier contexto político. Este trabajo pretende sentar las bases de un posterior estudio mucho más avanzado sobre la comunicación política y cómo está puede ser accesible y conocida por la mayor cantidad de gente posible.

1.1 Motivación

La creciente accesibilidad de modelos de lenguaje a gran escala (LLM) [2] y de librerías de PLN [3] (Hugging Face¹, spaCy², etc.) abre la puerta a un análisis masivo, reproducible y cuantitativo de las estrategias discursivas. Sin embargo, hasta la fecha existen escasas aproximaciones que: (1) integren de forma conjunta análisis de tópicos

¹<https://huggingface.co/>

²<https://spacy.io/>

(enfoque temático) y análisis de emociones/sentimientos (enfoque afectivo) en grandes corpus de discursos políticos; (2) aumenten estos análisis descriptivos con una etapa de generación automática de texto, adaptada estilísticamente al orador estudiado; y (3), validen empíricamente, ante usuarios reales, el grado de naturalidad y credibilidad de los textos producidos por IA frente a discursos auténticos.

Este Trabajo de Fin de Grado cubre ese hueco, proponiendo un *pipeline* de extremo a extremo: desde la adquisición de transcripciones, el etiquetado automático y la construcción de una base de datos relacional, hasta la recuperación de fragmentos semánticos para alimentar un modelo generativo (GPT-4 [4]). Además, se lleva a cabo un experimento con 108 participantes que cuantifica la tasa de “engaño” o de “verdad percibida” de los discursos sintéticos.

A **nivel personal**, mi vida universitaria se ha centrado en dos pilares fundamentales: Mi doble grado en Ingeniería Informática y ADE y mi participación activa en el Club de Debate de la UPV. Siempre he sido un apasionado de la política y la oratoria y gracias al club pude desarrollar esta vocación al mismo tiempo que estudiaba mi carrera. Mientras tanto, la parte de la informática que siempre me resultó más interesante fue la minería y análisis de datos, poder extraer información de donde otros ven únicamente números y palabras sin significado. Definitivamente será mi futuro laboral y el área donde pretendo especializarme.

Estuve bastante tiempo meditando sobre el tema de mi trabajo de fin de grado hasta que descubrí los modelos de procesamiento de lenguaje natural (PLN). La detección de sentimientos en un contexto donde la política estaba en boca de todos me pareció una oportunidad magnífica para aplicar mis conocimientos de análisis y minería de datos a un campo que me resultaba familiar.

Siempre he sido defensor de que la capacidad discursiva debe ser una *soft skill* que todo el mundo debe adquirir. Este trabajo profundiza en las formas en las que comunica uno de los políticos más relevantes del panorama internacional, para conseguir un conocimiento que pueda ser utilizado, más adelante, por otras personas.

1.2 Objetivos

El **objetivo general** consiste en desarrollar y validar un marco metodológico que combine técnicas de PLN y generación automática de texto para analizar y reproducir, con alto grado de fidelidad, las estrategias discursivas de un candidato presidencial.

Los **objetivos específicos** que pretende cubrir el trabajo son:

- Identificar cuáles son las principales temáticas abordadas en los discursos analizados.
- Identificar cuáles son los principales sentimientos y emociones presentes en los discursos analizados mediante modelos de procesamiento de lenguaje natural.
- Generar discursos coherentes que reproduzcan la retórica del ponente, en este caso de estudio, Donald Trump. Sin embargo, la solución debe ser extensible a cualquier persona que aporte una muestra significativa de discursos.

1.3 Contribuciones

Las principales aportaciones de este trabajo pueden resumirse en los siguientes puntos:

- Un corpus georreferenciado y anotado de 73 discursos de campaña de Trump, disponible para la comunidad. El acceso se proporciona en el anexo A.5.
- Una metodología reproducible de análisis descriptivo de tópicos y emociones en grandes corpus políticos.
- Un módulo de recuperación de fragmentos mediante *embeddings*, capaz de seleccionar ejemplos estilísticos y de contenido relevantes.
- Un módulo de generación *retrieval-augmented* que demuestra cuantitativamente el valor añadido de incorporar ejemplos reales.
- Un experimento de validación con 108 participantes, que mide la credibilidad de los discursos sintéticos y aporta conclusiones sobre la percepción ciudadana.

1.4 Estructura del documento

La estructura del documento será la siguiente:

- **Estado del arte:** Se realiza una revisión crítica de la literatura académica que existe al respecto del uso del PLN, del análisis de discursos políticos mediante PLN y de la generación de discursos políticos mediante IA. Por último, se pasa a justificar el espacio académico que pretende suplir el trabajo de fin de grado.
- **Herramientas utilizadas:** Se describirán las herramientas y métodos utilizados en el estudio, incluyendo explicaciones teóricas de su funcionamiento y constantes referencias a la parte del trabajo que hace uso de ellas.
- **Diseño de la solución:** Se justifica toda la elección teórica de los tres modelos de temáticas, emociones y sentimiento, para posteriormente diseñar también el pre-procesado. Una vez clarificado esto, se diseña también la base de datos y se justifica la elección del modelo de lenguaje para la generación de discursos. Por último, se diseña la evaluación de la generación de discursos.
- **Desarrollo de la solución:** Se explica con detalle la puesta en práctica del diseño de la solución. Se muestran las configuraciones y aplicaciones prácticas de todos los modelos escogidos en el diseño de la solución.
- **Análisis de resultados:** Se exploran los datos arrojados por los modelos y por el test de verificación de los discursos aportando conclusiones de cada uno de los procesos. Además se añaden variables al análisis como los estados y las fechas para enriquecerlos. En la parte de la verificación, se incluye también un análisis por poblaciones.
- **Ampliaciones:** Se incluye un apartado para futuras ampliaciones y continuaciones de este trabajo en el ámbito académico.
- **Conclusiones:** Se exponen las principales conclusiones extraídas gracias al trabajo de análisis previamente hecho.

- **Bibliografía:** Se exponen todas las fuentes en las que se ha basado el trabajo adecuadamente referenciadas.
- **Anexos:** Alguna información adicional relevante que no se pudo incluir en el resto de secciones.

CAPÍTULO 2

Estado del arte

En este segundo capítulo, se presenta una revisión sistemática de estudios e investigaciones existentes alrededor del análisis de discursos políticos con herramientas de PLN.

2.1 Evolución del análisis con PLN

A lo largo de los últimos años, con el fortalecimiento de las tecnologías de PLN, han proliferado diversos discursos relacionados con el análisis político. Era necesario pues, aplicar un enfoque tecnológico y diferente a un ámbito que decide nuestro día a día constantemente. Unos de los primeros estudios que se aventuraron a analizar esto fueron Laver, Benoit y Garry [5]. Ya en 2003, idearon un sistema de conteo de palabras con el que eran capaces de estimar la posición ideológica del manifiesto político que analizaban. Este y otros papers sirvieron como base e inspiración para los primeros análisis que podemos considerar de PLN en su totalidad.

2.1.1. Modelos basados en LDA

Un claro ejemplo de los primeros modelos PLN fue Grimmer [6], uno de los primeros estudios en utilizar LDA (Latent Dirichlet Allocation) [7] para analizar la atención e inclinación ideológica de los senadores estadounidenses.

En el estudio, Grimmer mostraba que a partir de un modelo probabilístico podía identificar automáticamente los temas de los que hablaban los senadores de EE.UU. en sus notas de prensa. Utilizaba LDA bayesianos jerárquicos [8], que son más flexibles que los tradicionales, para estimar el resultado a partir del corpus de los *press releases* emitidos por los senadores.

Este corpus, que contenía más de 65.000 notas de prensa entre 2005 y 2007, mostró que algunos de los temas más relevantes eran la salud pública o la economía local.

Esta tecnología de PLN, aunque ahora tiene otros reemplazos, sigue siendo la base de la gran mayoría de estudios PLN recientes. Por ejemplo, De Campos et al. [9], mostraban como los algoritmos LDA son eficientes para clasificar políticos según especialidades.

Este estudio tenía como objetivo desarrollar un sistema automatizado para identificar políticos expertos en áreas específicas, utilizando sus intervenciones parlamentarias como fuente de información. Para probarlo usaron un corpus de 10.025 intervenciones del parlamento andaluz de un total de 132 parlamentarios. Como posteriormente se analizará, los LDA deben ser configurados para detectar k temas, es decir, es el usuario quien determinar cuantos temas detecta el algoritmo. Según Campos et al., la estrategia basada

en la distancia de Sorensen con $k = \sqrt{n/2}$, fue la más eficiente para clasificar correctamente a los políticos por especialidades.

2.1.2. Modelos basados en clasificación predeterminada

Sin embargo, no todo es LDA en el análisis PLN. Más adelante surgirían modelos de clasificación preentrenados para detectar determinadas características. Este es el caso de Wang [10] que aborda la clasificación supervisada de textos políticos en temas predefinidos utilizando modelos de lenguaje preentrenados como BERT y RoBERTa.

Precisamente Wang señalaba el problema del etiquetado de datos y temáticas que en ocasiones puede ser escaso o incluso imposible y planteaba la oportunidad de trabajar a partir de temáticas y datos ya preetiquetados. Esto lo hacen utilizando modelos de lenguaje con *finetuning* y con un 70 % menos de datos que los grandes modelos de PLN.

En este estudio, consiguen concluir que el rendimiento de sus modelos supera en un 27 % al rendimiento de los grandes modelos, abriendo la puerta a un análisis de PLN mucho más barato, accesible y preciso.

Otro avance en este sentido fue Osnabrügge, Ash y Morelli [11] donde se utilizó un corpus que contiene más de 115.000 declaraciones en inglés etiquetadas según 44 temas específicos y 8 categorías amplias. Es decir, el modelo ya estaba preentrenado para saber identificar que temática correspondía a que declaraciones. Con esto, su objetivo era clasificar discursos parlamentarios de Nueva Zelanda, entre 1987 y 2002, sin etiquetas temáticas previas.

La precisión de este estudio fue medida respecto a codificadores humanos, es decir, que humanos clasificaban también el código entre las temáticas existentes y luego comparaban ambos resultados. La conclusión fue que el modelo consiguió reproducir el trabajo de los codificadores humanos en la gran mayoría de ocasiones.

Además, a nivel de temáticas, encontraron datos relevantes para el panorama político. Por ejemplo, la existencia de una brecha de género en la representación política: mientras que las parlamentarias tendieron a enfocarse más en temas de bienestar, los parlamentarios hombres hablaron más sobre relaciones exteriores.

2.1.3. Modelos basados en zero shot classification

Por último, una de las tecnologías que más libertad ofrece para la clasificación de temáticas y etiquetas es la clasificación por *zero shot*, es decir sin ejemplos previos. Una referencia en este aspecto es Xian et al. [12] que introduce un modelo denominado *Latent Embeddings* (LatEm) para abordar el problema de la clasificación sin ejemplos previos.

El objetivo del estudio era mejorar la capacidad de los modelos para clasificar imágenes de clases no vistas durante el entrenamiento, utilizando información auxiliar como descripciones semánticas o atributos. Es decir, que clasificaba imágenes, en vez de textos, pero utilizaba metodología y tecnologías aplicables a nuestro trabajo.

En este sentido, los resultados demostraron mejoras significativas en la precisión de la clasificación en comparación con métodos anteriores, especialmente al utilizar representaciones de clases no supervisadas como GloVe [13], que posteriormente se tratará en mayor profundidad.

Otros estudios han explorado diferentes formas de clasificación sin ejemplos, como Li, Guo y Schuurmans [14], que introduce una novedad en la clasificación sin ejemplos: el aprendizaje de representaciones de etiquetas en un marco semi-supervisado. Esto, con el fin de mejorar la capacidad de los modelos para clasificar instancias de clases no vistas

durante el entrenamiento, utilizando tanto datos etiquetados de clases observadas como datos no etiquetados de clases no observadas. Es decir combinar el *zero shot* con las etiquetas predefinidas.

Este estudio reconoce un alto coste y necesidad de recursos para llevar a cabo este modelo, pero concluye que el aprendizaje semi-supervisado consigue mejores resultados que los modelos de *zero shot* preexistentes.

2.2 Análisis políticos con PLN

A lo largo del anterior apartado ya pudimos vislumbrar como De Campos et al. [9], Osnabrügge, Ash y Morelli [11] y Grimmer [6] realizaban sus estudios directamente sobre el campo político. Sin embargo, durante esta sección trataremos de encontrar ejemplos tanto de Estados Unidos como del resto del mundo para observar los diferentes enfoques realizados en este campo.

2.2.1. Análisis de política global

Primero podemos revisar el contexto anglosajón. Abercrombie y Batista-Navarro [15] aplican técnicas de minería de opiniones a las transcripciones de los debates parlamentarios británicos (Hansard) para clasificar la polaridad del sentimiento de los oradores hacia las mociones propuestas.

Aparte de llegar a conclusiones similares a las del resto de estudios, consiguiendo una mejora en el resultado gracias a la polaridad, destacaban que el léxico político es muy específico en ocasiones y puede reducir la certeza en algunos contextos.

Ahora revisemos un contexto algo más familiar. Mestre et al. [16] estudiaban, desde la UPV, la toxicidad en el parlamento valenciano. El estudio, aplicado a intervenciones en Les Corts Valencianes, propone un enfoque innovador al incluir una zona de confusión para la detección de la toxicidad en la política. Esto no deja de ser parecido a la clasificación de temáticas, solo que ahora la etiqueta es la propia toxicidad.

Mediante esta zona de confusión, sobre todo en contextos políticamente cargados y lingüísticamente complejos, como Les Corts, la precisión mejora hasta el 87,89 % respecto del 80,35 % que obtenía sin. Esta zona de confusión lo que permite es, en lugar de etiquetar un mensaje como simplemente tóxico o no tóxico, detectar los casos más ambiguos y someterlos a un análisis de sentimiento que permite evaluar mejor el tono emocional del discurso. Aunque bien es cierto que esto conlleva un doble procesamiento y mayor utilización de recursos.

2.2.2. Análisis de política estadounidense

Uno de los primeros análisis a los que nos podemos asomar para acercarnos al contexto estadounidense es Ficcadenti et al. [17]. Para este estudio se recopilaban 951 discursos presidenciales desde 1789 hasta 2017 mediante técnicas de *web scraping* del sitio del Miller Center. Después del preprocesado, las palabras de cada discurso se ordenaron según su frecuencia de aparición, permitiendo identificar patrones en el uso del lenguaje.

Uno de los principales hallazgos de este estudio fue que existe un mantenimiento de la estructura discursiva a pesar de las diferencias temporales y contextuales. Es decir, los discursos presentan patrones similares en la distribución de frecuencias de palabras, sugiriendo una estructura retórica común. Esto se asocia a una posible imitación retórica de los sucesores.

No son los únicos, en analizar el camino hasta la casa blanca y sus peculiaridades. Jiménez-Preciado et al. [18] exploraban, en este caso, los debates presidenciales desde la perspectiva del análisis. El estudio se centra en los debates entre Donald Trump, Joe Biden y Kamala Harris, utilizando las transcripciones de los eventos moderados por CNN y ABC News.

Entre otros modelos léxicos, utilizaban modelos de sentimientos para medir la carga emocional del lenguaje de los candidatos. Concluyeron que Trump utilizó un lenguaje emocionalmente cargado con alta volatilidad en el sentimiento, abarcando desde -1 hasta $+1$ en la escala de sentimiento. En otras palabras, que variaba mucho el espectro emocional. Mientras tanto, los candidatos demócratas teniendo un tono más estable y menos volátil.

2.3 Generación de discursos mediante IA

Analicemos ahora discursos alineados con la segunda parte del objetivo, referida a la generación de discursos políticos mediante modelos de lenguaje de IA. El primer estudio al que nos referiremos a este respecto será Kassarnig [19]. En este estudio se presenta un sistema capaz de generar discursos políticos alineados con partidos específicos y orientaciones.

Kassarnig lo consigue a través de una combinación de modelos de lenguaje y de tópicos entrenados en el conjunto de datos Convote, que contiene transcripciones de debates del Congreso de EE.UU. El modelo de tópicos es precisamente un LDA que sirve para comprobar y mantener la coherencia semántica del análisis. También se utilizaban filtros para la corrección gramatical.

Tras todo este proceso y una revisión manual de los propios discursos, conseguían una alta calidad en términos de corrección gramatical y coherencia temática.

Sin embargo, no existen muchos más estudios que utilicen tecnologías diferentes de estas. Es un terreno definitivamente poco explorado.

2.4 Análisis crítico del estado del arte

En conclusión, el estado del arte nos deja una imagen bastante clara. Existen multitud de estudios de clasificación de temáticas y sentimientos mediante PLN. Es un campo realmente muy explorado y con multitud de técnicas en las que elegir. Sin embargo, aunque sí en los debates, no existe ninguna investigación aún de la campaña electoral de EE.UU. en 2024, una de las más ajustadas y controvertidas de todos los tiempos. Además, existe poco análisis cruzado entre temáticas y sentimientos, siempre se hacen análisis por separado, pero existe poco estudio de la correlación y el uso de los sentimientos de los políticos en cada una de las diferentes temáticas. Resulta interesante realizar un análisis con ambas perspectiva aplicado al contexto electoral más reciente.

Al respecto de la generación de discursos, es un terreno poco explorado académicamente. Existen poco estudios al respecto y los que existen lo hacen mediante modelos propios. No existen aún estudios que utilicen modelos de lenguaje avanzados, ni que instrumentalicen varios análisis de PLN para luego enriquecer los discursos. Los estudios que existen hasta el momento tratan de hacer discursos sobre corpus ya preetiquetados y no sobre corpus que se diseñan específicamente para la generación. En este sentido, resulta interesante la inclusión de los modelos de lenguaje y de los corpus específicos para enriquecer la generación de discursos mediante IA.

CAPÍTULO 3

Herramientas utilizadas

En este apartado se hablará sobre las herramientas que han sido utilizadas para llevar a cabo el trabajo de fin de grado. Se incluyen las herramientas de procesamiento de datos, de análisis de los mismos y de generación de discursos. Para mayor claridad, se han dividido según su utilidad para el trabajo.

3.1 Base de datos

En esta sección se incluyen las herramientas que han servido como base de datos a lo largo del *pipeline*. Al ser este un proceso largo, han habido cambios respecto de donde se alojaban los datos en cada momento del proceso.

3.1.1. Microsoft Excel

En un principio, los ficheros CSV fueron la fuente de almacenamiento mientras se realizaba la limpieza del texto. Para abrir y tratar estos ficheros utilizamos Microsoft Excel¹.

Microsoft Excel es una herramienta en forma de hoja de cálculo que permite almacenar, organizar, analizar y visualizar datos de manera eficiente mediante el uso de celdas distribuidas en filas y columnas. Desarrollada por Microsoft como parte del paquete Microsoft Office, Excel tiene un uso muy extendido a nivel personal, académico y profesional.

La razón principal de su uso en fases tempranas es su facilidad de manejo en el flujo de proceso de los códigos de Python. Resulta más sencillo tener ficheros de *input* y *output*, en vez de tener que estar reescribiendo constantemente una base de datos como la que haremos posteriormente. Excel es una herramienta perfecta para estas etapas tempranas del procesamiento.

3.1.2. SQLite

Por otro lado, en las etapas avanzadas del proyecto, especialmente en el análisis y generación de discursos, SQLite² fue la herramienta utilizada para administrar una base de datos que se creó en el repositorio local como se verá más adelante.

SQLite es un sistema de gestión de bases de datos relacional embebido, ligero y de código abierto. A diferencia de otros sistemas como MySQL o PostgreSQL, SQLite no

¹<https://www.microsoft.com/es-es/microsoft-365/excel>

²<https://www.sqlite.org/>

requiere de un servidor externo, ya que opera directamente sobre un único archivo que contiene toda la base de datos. Esta característica lo hace especialmente adecuado para aplicaciones locales, prototipos rápidos o entornos de bajo consumo de recursos que es precisamente el terreno en el que nos vamos a mover a lo largo de todo el trabajo.

En el contexto de este trabajo, se ha optado por utilizar SQLite por dos razones principales. La primera, debido a su facilidad de integración, bajo coste computacional y portabilidad. La limitación de recursos va a ser una constante a lo largo de este trabajo, y las herramientas optimizadas ayudan a resolver este problema. Por otro lado, SQLite es una ventaja frente a Excel, tanto en análisis, como en recuperación de fragmentos. Los modelos de *embeddings* están directamente preparados para trabajar con bases de datos SQL y, por lo tanto, facilitan su implementación. De igual forma, extraer estadísticas mediante Python de una base de datos SQL es mucho más sencillo que de ficheros agrupados en CSV. Por estas razones, SQLite es la herramienta escogida para las partes más avanzadas de este proyecto.

3.2 Lenguaje de programación

Exploremos ahora cuál ha sido el lenguaje de programación que se ha utilizado para programar los modelos, extraer estadísticas y generar los discursos. En esta sección también se incluyen las librerías que amplían la utilidad base del propio lenguaje de programación.

3.2.1. Python

Todo el trabajo se ha realizado bajo el lenguaje de programación Python³. Python es un lenguaje de programación de alto nivel orientado a objetos que se creó a finales de los años ochenta por Guido van Rossum. Conocido por su fácil accesibilidad y legibilidad, Python además ofrece una multitud de librerías que le permiten adaptarse mucho mejor a cualquier contexto que se le demande. En especial, y como veremos a lo largo del trabajo, Python posee una cantidad de librerías relacionadas con el análisis estadístico y el análisis PLN, que hacen mucho más fácil este trabajo. Estas son las razones por las que utilizaremos Python a lo largo de todo el trabajo.

Hagamos un análisis más específico de las funciones que cumple Python dentro del proyecto mediante cada una de las diferentes librerías. Todos los links de acceso a las librerías están disponibles en la tabla 3.1 al final de este apartado.

3.2.2. Gestión de archivos y entorno

Para la gestión de archivos y entorno, hemos utilizado librerías que permiten interactuar con el sistema de ficheros (listar, mover, renombrar archivos...), gestionar fechas y horas, y cargar variables de entorno de forma segura. Más específicamente hemos utilizado las siguientes librerías:

- **Os:** Esta librería actúa como una interfaz para operar con el sistema de archivos y variables de entorno. Algunos ejemplos de esto son: navegación de rutas (mediante `os.getcwd()` o `os.chdir()`) o acceso a variable de entorno (mediante `os.getenv()`).

³<https://docs.python.org/3/reference/>

- **Glob:** Una librería que ayuda en la búsqueda de ficheros gracias a patrones tipo shell. Gracias a esta librería podemos listar todos los archivos csv con facilidad mediante ordenes como `glob.glob('data/*.csv')`.
- **Datetime:** Una librería clásica para el manejo de fechas y horas. Especialmente útil para obtener la fecha y hora actual y hacer cálculos a partir de ella, como sumar o restar intervalos (mediante `datetime.timedelta()`).
- **python-dotenv:** Librería esencial para la carga de variables de entorno desde un archivo env, por ejemplo, mediante `load_dotenv()`.

3.2.3. Almacenamiento y manipulación de datos

La finalidad de estas librerías es facilitar la lectura, escritura, transformación y consulta de datos estructurados. Utilizamos para ello las siguientes:

- **Numpy:** Para cálculos numéricos rápidos y eficientes y manejo de matrices multidimensionales mediante cálculos directamente vectorizados que no requieren de bucles, por ejemplo, con `np.arange()`. También ayuda con la generación de distribuciones y transformaciones lineales.
- **Pandas:** La librería de referencia en el manejo y creación de *Dataframes*. Por lo tanto, la librería perfecta para el manejo de estructuras de datos. En el trabajo es especialmente importante para la lectura y escritura en CSV en la primera parte de la transformación de datos (por ejemplo, mediante `pd.read_csv()`),
- **SQLite3:** Utilizada para la conexión a la base de datos SQL. Fundamental para extraer los datos de la base en el análisis descriptivo del trabajo o para crear la propia base de datos. Para todas estas operaciones se utiliza el lenguaje SQL dentro de las cajas de los comandos, pero primero es fundamental conectarse mediante `sqlite3.connect()`.
- **SQLAlchemy:** Fundamental para la definición de modelos Python que se traducen a tablas en la base de datos. Es la que se utiliza en la arquitectura de la base de datos, creando la base declarativa, abriendo la sesión o generando usuarios.

3.2.4. Extracción y Limpieza de contenido

En este apartado se presentan librerías que otorgan herramientas para procesar texto en bruto, extraer patrones y tratar los archivos HTML/XML. En este caso se han utilizado dos:

- **Re:** Esta librería provee de manejo de expresiones regulares para búsqueda y sustitución de patrones. Esta librería es especialmente útil en el primer paso de la limpieza de texto para sustituir los corchetes mediante `re.sub()`.
- **Beautiful Soup 4:** Otra librería fundamental para el tratamiento y navegación de ficheros de texto. Esta es utilizada a lo largo de todo el proceso, pero resultó especialmente útil en el *scraping* de los ficheros HTML, mediante comandos como `soup.find_all()`.

3.2.5. Embeddings y recuperación semántica

Las librerías listadas en esta subsección se utilizan para la generación de vectores de alta dimensión que representan el significado del texto, y para la posterior búsqueda eficiente por similitud. Para este trabajo se han utilizado las siguientes librerías:

- **Sentence transformers:** Esta librería utiliza modelos preentrenados para convertir frases en embeddings semánticos. Algunos de los modelos que utiliza para ello son BERT, Mini LM o RoBERTa, que se tratan más adelante en el trabajo. Esta librería se utiliza especialmente en la parte del trabajo de creación de embeddings para la posterior recuperación de fragmentos. Antes de realizar cualquier operación se debe seleccionar el modelo que se carga mediante *SentenceTransformer('all-MiniLM-L6-v2')*.
- **FAISS:** Esta es una librería de Facebook utilizada para la indexación y búsqueda rápida de vectores. Se trata en especial profundidad en el apartado 4.5 y 5.6 del trabajo, ya que es un eje central del recuperado de fragmentos. Este es precisamente su valor, la búsqueda semántica entre millones de embeddings de forma eficiente.

3.2.6. Modelado

En esta subsección, se presentan librerías que dan acceso a modelos de lenguaje avanzado, vía API, para tareas de generación. Dos librerías son las utilizadas para estos fines:

- **Transformers:** esta librería actúa como *framework* para descargar, entrenar y usar modelos Transformer. Su funcionalidad clave se relaciona con los *pipeline* de tareas que sirven para manejar todos los modelos que se utilizan a lo largo del trabajo.
- **OpenAI:** Es la librería oficial para consumir la API de OpenAI (GPT-4, embeddings, etc.). Es necesaria, especialmente, para la generación de discurso que se hace con el modelo de GPT-4. Para utilizarla hay que generar una 'KEY' en tu cuenta de OpenAI, y luego cargarla mediante Python y así poder utilizar el cliente. Para esto simplemente utilizamos el siguiente código: `openai = os.getenv('OPENAI_API_KEY')`.

3.2.7. Utilidades de proceso

Algunas librerías que ayudan al cálculo y optimización de procesos. En este caso solo una:

- **TQMD:** Es una librería especialmente útil en entornos de programación con limitación de recursos. Calcula el tiempo restante a partir de las primeras iteraciones y dispone de una barra de progreso para informar al usuario del tiempo restante. Muy necesario para saber si es viable o no escalar el etiquetado. El límite de 7 etiquetas de temáticas y de emociones se establece precisamente gracias a esta librería.

Tabla resumen

Se pueden consultar todas las librerías utilizadas a lo largo del proyecto, con una pequeña descripción y el link de acceso en la tabla 3.1.

Librería	Descripción	Enlace oficial
os	Acceso al sistema de archivos, rutas y variables de entorno.	https://docs.python.org/3/library/os.html
sqlite3	Módulo estándar para interactuar con bases de datos SQLite.	https://docs.python.org/3/library/sqlite3.html
pandas	Manipulación y análisis de datos en estructuras tipo DataFrame.	https://pandas.pydata.org/
numpy	Cálculo numérico eficiente con arrays y operaciones matriciales.	https://numpy.org/
faiss	Búsqueda de vectores por similitud a gran escala.	https://github.com/facebookresearch/faiss
sentence-transformers	Generación de embeddings semánticos con modelos preentrenados.	https://www.sbert.net/
openai	Acceso a los modelos de lenguaje de OpenAI como GPT-4.	https://platform.openai.com/docs
dotenv	Carga variables de entorno desde un archivo .env.	https://pypi.org/project/python-dotenv/
sqlalchemy	ORM para interactuar con bases de datos relacionales desde objetos Python.	https://www.sqlalchemy.org/
re	Expresiones regulares para procesamiento de texto.	https://docs.python.org/3/library/re.html
glob	Búsqueda de archivos con patrones tipo wildcard.	https://docs.python.org/3/library/glob.html
datetime	Manipulación de fechas y tiempos.	https://docs.python.org/3/library/datetime.html
bs4 (BeautifulSoup)	Extracción y análisis de contenido HTML o XML.	https://www.crummy.com/software/BeautifulSoup/
transformers	Acceso a modelos de lenguaje de Hugging Face para PLN.	https://huggingface.co/docs/transformers
tqdm	Barra de progreso para bucles largos.	https://tqdm.github.io/

Tabla 3.1: Librerías de Python utilizadas en el proyecto.

3.3 Plataforma

3.3.1. Visual Studio Code

Visual Studio Code⁴ es un editor de código fuente desarrollado por Microsoft, ampliamente reconocido por su versatilidad y su integración con múltiples lenguajes de programación, especialmente con Python, el lenguaje utilizado en este trabajo. Su uso es popular en entornos académicos y profesionales debido a su ligereza, personalización y capacidad de adaptación.

La elección de Visual Studio Code en este trabajo responde a su facilidad de uso e integración dentro de un entorno de programación local, Además también tiene una integración en Git muy fácil, lo que permite un control de versiones muy fluida. Por estas razones, VS es una magnífica elección para este proyecto.

3.4 Herramientas de análisis

3.4.1. Herramientas de análisis estadístico

Analicemos algunos de los estadísticos utilizados en este trabajo y la explicación de cómo funcionan.

Coefficiente de Pearson

Para el estudio de la correlación entre variable,s se han calculado matrices de correlación de Pearson [20] entre las emociones, las temáticas y el sentimiento. El coeficiente de Pearson es una medida estadística que cuantifica la fuerza y dirección de una relación lineal entre dos variables cuantitativas. Su valor oscila entre -1 y 1 : un coeficiente de 1 indica una correlación lineal positiva perfecta, -1 una correlación lineal negativa perfecta, y 0 implica ausencia de correlación lineal. Formalmente, se define como el cociente entre la covarianza de las variables y el producto de sus desviaciones estándar:

$$r_{X,Y} = \frac{\text{cov}(X,Y)}{\sigma_X \cdot \sigma_Y}$$

Correlación con la variable tiempo

Funciona exactamente igual que la correlación de Pearson. La única diferencia es que para realizar la correlación con la variable tiempo, debemos de convertir el tiempo en una variable más dentro del estudio y después realizar el cálculo de Pearson mostrado anteriormente.

Pendiente en regresión lineal

En un modelo de regresión lineal simple [21], la pendiente representa el cambio esperado en la variable dependiente y ante un incremento unitario en la variable independiente x . Es, por lo tanto, una medida de la tasa de cambio lineal entre ambas variables.

⁴<https://code.visualstudio.com/>

Formalmente, dado un conjunto de observaciones $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, la pendiente β_1 de la recta de regresión $y = \beta_0 + \beta_1 x$ se calcula como:

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

En el trabajo, la variable dependiente son las puntuaciones de temáticas, emociones y sentimiento y la variables independiente es el tiempo. Así, si la pendiente es positiva la variable dependiente aumenta con el tiempo, y si es negativa, desciende.

Porcentaje de predominancia

Esta es una estadística utilizada a efectos de este estudio para obtener cual es la temática o sentimiento mayormente predominante en un fragmento. Simplemente se comparan todas las puntuaciones del fragmento y se asigna a ese fragmento tan solo la temática o emoción que mayor puntuación tiene. De esta forma, se puede realizar análisis más allá de la media que confirmen si una media alta es debida a picos grandes, o si es debida a que la puntuación de dicha variable es constantemente alta a lo largo de los fragmentos.

Media aritmética

La media aritmética es una de las medidas basicas de la estadística descriptiva. Representa el valor promedio de un conjunto de datos.

Dado un conjunto de n observaciones $x_1, x_2, \dots, x_n$, la media aritmética $\bar{x}$ se define como:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Correlación según Spearman

Para los datos de la encuesta, se utiliza el índice de correlación de Spearman [22]. El coeficiente de correlación de Spearman, denotado como ρ_s , es una medida no paramétrica de la dependencia estadística entre dos variables. A diferencia del coeficiente de Pearson, que evalúa relaciones lineales, Spearman evalúa la monotonía de la relación, es decir, si al aumentar una variable la otra tiende a aumentar o disminuir, sin asumir una relación lineal específica. Esto es lo que lo hace especialmente útil para escalas del 1 al 5, como en la encuesta, donde no podemos asumir modelos de regresión lineal.

Spearman también otorga el valor p que indica el nivel de certeza de que exista o no la correlación (en este trabajo usaremos $p < 0.05$), mientras que ρ que indica la dirección de la correlación, si es inversa o no.

Formalmente, para un conjunto de pares ordenados (x_i, y_i) , se calculan los rangos de x y y , y se aplica la fórmula:

$$\rho_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

donde:

- d_i es la diferencia entre los rangos de x_i y y_i ,
- n es el número de observaciones.

3.4.2. Herramientas de análisis gráfico

A continuación se enumeran algunas de las representaciones que se han utilizado para visualizar los resultados obtenidos por los estadísticos anteriores en el apartado de análisis de resultados:

- **Gráficos de barras simples:** Gráficos que sirven para mostrar de forma gráfica el conteo de alguna variable. En nuestro caso, sirven para mostrar el número de discursos que realiza Donald Trump por estado.
- **Gráficos de barras verticales agrupados:** Gráficos que representan valores indicados por grupos específicos partiendo del suelo. Permiten representar 3 dimensiones de variables, ya que pueden haber varias barras dentro de un mismo grupo. Nos han permitido ilustrar de mejor forma las medias por grupos poblaciones en el análisis de la encuesta, representando las variables de acierto, tipo de generación del discurso y, por ejemplo, nivel de escepticismo.
- **Gráficos temporales de líneas:** Gráficos que mediante líneas y puntos representan la evolución temporal de diferentes tipos de variables. En nuestro caso nos permiten una mejor visualización de cuál ha sido la evolución temporal de la puntuación de temáticas, emociones y sentimientos.
- **Mapas de calor o *Heatmaps*:** Elementos gráficos que permiten representar de forma clara valores que oscilan en una escala entre dos valores, otorgando colores más fuertes a medida que un valor se acerca al extremo. En nuestro estudio se utiliza para representar los valores de las correlaciones de Pearson entre diferentes variables, como las temáticas y los estados.
- **Gráfico de sectores:** Diagrama circular que permite la representación de sectores de población de la encuesta en este trabajo. Se utiliza para representar el tipo de muestra obtenida a partir de la encuesta.

CAPÍTULO 4

Diseño de la solución

4.1 Elección y descripción de modelos

Lo primero, antes de empezar a diseñar nuestra solución, es escoger cuáles van a ser los modelos que se van a utilizar en el análisis de sentimientos y de temáticas. Dependiendo de cuáles elijamos, el procesamiento de los datos se orientará de una forma u otra. Del modelo depende, en buena medida, el tipo de análisis que realizaremos y hacia donde orientaremos la parte de generación de discursos. Depende del tipo de datos que tengamos, podremos enriquecer de una forma u otra. A este respecto, nos interesa analizar dos aspectos fundamentales de los discursos: la clasificación de temáticas y la detección de sentimientos mediante procesamiento de lenguaje natural (PLN).

4.2 Modelo de clasificación de temáticas

El objetivo de clasificar temáticas es doble. Por una parte, queremos observar cuáles son las temáticas más presentes en los discursos electorales y obtener datos temporales o geográficos sobre el uso de estos discursos. En segundo lugar, queremos que el modelo sea capaz de clasificar correctamente las temáticas porque luego la IA recuperará los fragmentos que tengan una alta puntuación de esa temática, para analizar cómo Trump habla sobre esa temática en específico y reproducirlo. Por lo tanto, necesitamos un modelo que nos deje clasificar los fragmentos en las principales temáticas y que nos permita tener puntuaciones sobre cuáles son los fragmentos más fuertemente relacionados con cada temática.

Los primeros modelos de clasificación de temáticas que se introdujeron fueron los de detección de temáticas. Un ejemplo claro de estos son los modelos basados en Latent Dirichlet Allocation (LDA) como el que explican Jelodar et al. [7]. Estos modelos, tras eliminar palabras superfluas, consiguen detectar las temáticas más relevantes del texto a partir de palabras claves. Es decir, este modelo podría decirnos que la temática más relevante incluye las palabras *war, peace, China, people, economy* y que esta temática está presente en el 50 % del texto. Sin embargo, podemos ver las primeras problemáticas claras de este modelo a primera vista. En primer lugar, el modelo no clasifica temáticas, tan solo las detecta. Es decir, si el modelo detecta 5 temáticas diferentes por cada fragmentos y estas no coinciden entre fragmentos, podríamos acabar con un número muy grande de temáticas. Cada fragmento podría tener una temática totalmente diferente al anterior al describirse las temáticas con las 5 palabras mas relacionadas. Podríamos solucionar esto intentando resumir con un proceso posterior estas 5 palabras en una o clasificando el fragmento a partir de las 5 palabras otorgadas por el LDA. Sin embargo, esto daría pie

a ambigüedades, o en el mejor de los escenarios, donde funcionara bien, sería mucho más ineficiente que un modelo que clasifique directamente. Por último, muchos de estos modelos no ofrecen correlación de los textos con las temáticas, tan solo las clasifican en importancia dentro del texto. En vez de que la IA interprete que un fragmento tiene un 50 % de *health*, los LDA simplemente dicen que la temática más importante es la de *health*, pero no cuánto de importante es esta. Se pierde mucha información por el camino. Urge buscar alternativas a los modelos más tradicionales para que se adecúe al enfoque del trabajo.

En segundo lugar, podríamos pensar en modelos que ya tengan las temáticas pre-determinadas, para no tener el problema de escalado infinito de temáticas. Por ejemplo, Google Cloud Natural Language que tiene más de 700 temáticas entre las que clasificar [23]. Estos modelos ya tienen las temáticas predefinidas y clasifican entre ellas. Otra vez, con modelos con tantas temáticas como el de Google, volvemos a tener un problema de escalado de datos grande, al poder tener cientos de atributos en cada fragmento. Podríamos para esto utilizar modelos más generalistas como IBM Watson Natural Language Understanding[24]. El problema reside en su adaptación al mundo político. Las temáticas como *Sports* o *Science* son mucho menos relevantes en este contexto. Mientras tanto, otros asuntos relevantes como las relaciones internacionales, se descuidan en estos modelos al ser generalistas y no centrarse en la política. La problemática principal de estos modelos reside en la falta de adaptación al trabajo que se está realizando.

La última consideración sería utilizar modelos aplicados al campo político, como por ejemplo el modelo de Political Classification de MeaningCloud [25]. Estos modelos pueden adaptarse a este contexto del trabajo. Sin embargo, el propósito del mismo trabajo es que pueda ser aplicable a distintos contextos y utilizar estos modelos ceñiría exclusivamente su uso al campo político, especialmente a la política occidental. Además estos modelos, no nos permiten centrarnos en las temáticas más relevantes de cada país y debemos conformarnos con las que el modelo impone como relevantes.

Hecho este análisis, necesitamos un modelo personalizable, que nos dé porcentajes de correlación con cada texto para después realizar asociaciones y que no clasifique en demasiadas temáticas para no tener demasiados atributos.

Cumpliendo con lo expuesto, el modelo seleccionado es Bart Large MNLI. Este modelo está basado en *zero shot classification* [12]. Es decir, que a diferencia de otros modelos que necesitan de miles de datos para asociarlos a una etiqueta, este modelo coge el texto y una lista de posibles etiquetas que proporciona el usuario y consigue clasificar el texto eficientemente. Además, lo clasifica aportando porcentajes de correlación con un acierto realmente alto [26]. Por lo tanto, Bart Large MNLI cumple con las características expuestas en el anterior párrafo. Deja seleccionar las etiquetas que prefiera el usuario, lo que permite poner pocas temáticas para que no escalen los atributos y, por otro lado, permite otorgar una puntuación de correlación a cada temática por separado.

4.2.1. Selección de etiquetas para el modelo de temáticas

Una vez escogido el modelo de *zero shot*, debemos escoger cuáles van a ser las temáticas que se van a poner como etiquetas. Para ello recurriremos a Policy Agendas Project (PAP) . La PAP [27] es uno de los repositorios de datos sobre contenido de políticas públicas más extensamente citados y utilizados en la ciencia política. Fue lanzado por el Centro de Políticas Públicas de la Universidad de Texas y recopila sistemáticamente miles de documentos—discursos legislativos, iniciativas ejecutivas y comunicados de prensa—codificados según un esquema temático estandarizado desde la posguerra hasta hoy.

Este esquema, en su versión de 2019, incluye entre otros: Macroeconomics, Civil Rights, Health, Energy, Education, Transportation, Defense, Banking, Sports...

No todos estos temas son relevantes en un contexto electoral. Trataremos de rebajar el número total de temáticas a 7 por disponibilidad de recursos para el procesado de los discursos. Aumentar en más de 7 las temáticas, escala demasiado los tiempos de procesamiento. La práctica de reagrupado es común dentro de los análisis de alto nivel de discursos y se ha utilizado en estudios como Izhar, Bhatti y Alharthi [28]. Para ello agruparemos algunos y descartaremos otros que sean menos importantes o que representen información repetida.

La selección final de temáticas se obtuvo estudiando la correlación entre más de 20 temáticas en una muestra reducida que permitía computarlas y quedándonos tan solo con una de las solapadas.

4.2.2. Descripción de las temáticas

La selección final de temáticas se compone de las siguientes:

- **Economy / Economía:** Englobando todas las categorías relacionadas con la macroeconomía y las políticas públicas económicas, pero también relacionadas con los impuestos y la política fiscal. Introduciendo *Taxes* como categoría separada, la correlación entre ambas categorías era de un 86,17 %. Más específicamente, Trump hizo realmente mucho hincapié durante su campaña en la lucha contra la inflación, el desempleo y arreglar el malgasto económico del gobierno.

Este es uno de los fragmentos con más puntuación en el apartado de *economy* (0.9963):

"this. The economy stinks. What timing, what timing. Four days before the election, they have among the worst numbers ever in history nobody's ever heard. They did 12,000 jobs. Normally, you're 250,000, 300,000, 400,000, They did 12,000. Think of it, 12,000 jobs. And it's hundreds of thousands of jobs less than it should be because they're pathetic. They don't know anything. These people don't know anything. She's a very low-IQ person. We don't need a low-IQ individual. We just had that for four years. We don't need this. But those numbers are so low. They're almost disqualifying. The only thing good about the numbers I'm going to give you now are that it's great to run against the people that created those numbers because it's terrible. And just..."

— Donald Trump, Asheville, Carolina del Norte, 14 de agosto de 2024

- **Infrastructure / Infraestructura:** Esta etiqueta engloba todas las nuevas construcciones y proyectos que quiere crear Donald Trump. De forma real, esto se plasma con Trump haciendo especial énfasis durante su campaña en utilizar el dinero para hacer crecer el país mediante carreteras, puentes y reconstrucción de ciudades en vez de utilizarlo en guerras extranjeras o "green deal scam".

Este es uno de los fragmentos con más puntuación en el apartado de *infrastructure* (0.9899):

"But they would always say, 'Trump is going to get us into war with his attitude.' No, my attitude kept us out of war. We defeated ISIS, totally defeated ISIS. We got out of Syria. We got out of Iraq. I got out of these wars because I'm a big believer. I want to spend our money in our country, doing our country's great things. Our country – you drive down our roads, you drive down our highways, our country is falling to pieces. Our infrastructure is falling. And then these guys, all they want to do is spend money on the green new scam. It's a green new scam. I mean, the things they're..."

— Donald Trump, Phoenix, Arizona, 6 de junio de 2024

- **Health / Salud:** Todo aspecto relacionado con la sanidad está especialmente englobado aquí. Desde la creación de sistemas nacionales de salud hasta la batalla contra las drogas que se ha desarrollado últimamente en EEUU. Observando los fragmentos con más puntuación, Trump habló de seguros privados o drogas, pero también se incluyen referencias a la mala salud de Joe Biden y a su "fantástica salud" pese a su edad.

Este es uno de los fragmentos con más puntuación en el apartado de *health* (0.9928):

"You're not going to have a country anymore. People like Scott, brilliant Wall Street people, they're right about what they say. And that's also common sense. I'll tell you, it's all about common sense. The Republican Party is the party of common sense. Kamala Harris wants to eliminate private health insurance. Does anybody have private health insurance here? A lot of people, yeah. A lot of people. They want it. That's what they want. They want to have it. Now, if you want to have other, you have other, but they want to take it and they want to turn it off. It doesn't cost our country anything. They want to turn it off. This is what people – they work hard, they make enough money, they want..."

— Donald Trump, Asheville, Carolina del Norte, 14 de agosto de 2024

- **Security / Seguridad:** Aunque a priori pueda parecer ambigua, el análisis demuestra todo lo contrario, Security tiene correlaciones muy altas con *Crime* o *Defense*. Engloba desde gasto militar y policial, hasta la propia percepción de seguridad. De esta forma, incluye asuntos como la Seguridad Social o, en algunos casos, la inmigración. Observando las mayores puntuaciones, Trump solía correlacionar la seguridad a las fronteras y a las subvenciones del Estado, explicando que Kamala iba a abrirlas de par en par y que él nunca desactivaría el escudo social de la Seguridad Social. Como se puede intuir, en la prueba previa, *Social Affairs* tuvo una correlación alta con Security (85,23 %) y se solapaba con frecuencia.

Este es uno de los fragmentos con más puntuación en el apartado de *security* (0.9985):

"from me. She says they want to ban IVF, a total outrageous lie. In fact, I'm going to require insurance companies to pay for IVF. And I was – long, long – and many other things. I'm going to protect your Medicare, your Social Security. We're never ending it. She said we're – she never heard me say it. If she ever heard me, let her prove it. She gets up and lies. He's going to end Social Security. No, the nice thing is we can fight back because we have a voice, so we can fight back. We can tell you what's true and what's not true. But Kamala's open borders catastrophe – this is what's going to kill your Social Security. Her open borders will kill..."

— Donald Trump, Albuquerque, Nuevo México, 31 de octubre de 2024

- **Education / Educación:** Esta etiqueta aborda todos los aspectos de la educación, desde su precio y accesibilidad hasta su calidad. Esto fue lo que remarcó especialmente Donald Trump, atacando a la subida de precios de la educación y de la deuda estudiantil. También, por otra parte, hacía hincapié en la importancia de seguir teniendo una educación de calidad.

Este es uno de los fragmentos con mayor puntuación en el apartado de *education* (0.9963):

"Washington, DC, Department of Education, Department of – you say, What the hell do all these people do? Here's what I need. I need one good person, let's say, to be the secretary. And then, I need a real secretary that takes stenography. I need two people because I just want them to make sure they teach English, that they teach reading, writing, and arithmetic. And we're going to do that very fast. We're going to do that very fast. And it's going to be great. But to do that, you have to vote for Trump, and you have to do it fast. You have to do it very quickly. And, you know, while I'm on the subject of smart people, I want to thank Elon Musk. He..."

— Donald Trump, Saginaw, Michigan, 3 de octubre de 2024

- **Immigration / Inmigración:** El tema, probablemente, más asociado a Trump, no podía faltar en el análisis. Es cierto que existe cierta correlación entre inmigración y seguridad, pero no la suficiente para descartarlas, ya que la etiqueta de seguridad es mucho más amplia. Inmigración se centra especialmente en el impacto de los inmigrantes en Estados Unidos, no solo en el aspecto de criminalidad que tanto se atribuye a Trump, sino que Trump también los culpaba de arruinar la Seguridad Social o quitar empleos, entre otras muchas cosas.

Este es uno de los fragmentos con mayor puntuación en el apartado de *immigration* (0.9964):

"I mean, the people can't get a bottle of water. If you want to save Medicare and save Social Security, you must vote for a gentleman named Donald J. Trump. Have you heard of him? You know it's an amazing stat, but virtually 100 percent of the net job creation in the last year, you know who it's gone to? Migrants. They're creating jobs – I didn't believe it. I actually have that – Andy Biggs, I have to have that number checked. And it was right. The jobs are going to people that are pouring in. This border invasion of millions of people pouring in is causing a job crisis for Black and Hispanic population. That's what's happening. Hispanic and Black are losing their jobs because..."

— Donald Trump, Bozeman, Montana, 9 de agosto de 2024

- **Foreign Policy / Política Exterior:** Por último, un tema recurrente de la actualidad mundial. Esta etiqueta pretende acotar todos los conflictos mundiales que influyen de forma significativa en la agenda estadounidense. Desde Ucrania hasta Israel, pero también incluyendo conflictos no militares, como los de México y Canadá. Trump hizo especial referencia a que durante su mandato no había iniciado guerras y a su supuesta gran capacidad negociadora. El mensaje de Trump solía ser bastante triunfalista y pacifista en este sentido; no quería una guerra mundial ni el uso de armas nucleares.

Este es uno de los fragmentos con mayor puntuación en el apartado de *foreign policy* (0.9908):

"Under my leadership, we had no new wars. Hillary Clinton, she used to say, look at him, look at him, listen to him. He's going to start wars. No, I stopped wars. We defeated 100 % of the ISIS caliphate. We brought our troops back home. I had no new wars. I had no wars. I started no wars, first time in 78 years instead of a globalist warmonger, and that's what you have in the White House. You finally had a peacemaker at 1600 Pennsylvania Avenue. These terrible wars that were started, they never end. We call them the endless battles. Biden's weakness and failure are putting us in grave danger. As president, I will restore peace through strength. And my next term, we will build a great..."

— Donald Trump, Detroit, Michigan, 15 de agosto de 2024

4.3 Modelo de análisis de emociones

El proceso para elegir el modelo de emociones es más sencillo. Los primeros modelos de reconocimiento de emociones que se crearon en el ámbito del PLN son textuales o funcionan por cercanía en las redes neuronales. Por ejemplo, NRC Emotion Lexicon [29], un recurso que asocia palabras con emociones básicas y polaridad, simplemente lo hace a partir de la literalidad. Si en un texto aparece la palabra feliz, lo asocia a alegría directamente, sin tener en cuenta la ironía, por ejemplo. De forma parecida, existen modelos que analizan sentimientos por cercanía en la red neuronal. Por ejemplo, GloVe [13] es un recurso orientado a representar el significado semántico de las palabras en vectores densos. Sin embargo, al funcionar por cercanía, *banco empresarial* y *banco del parque* obtienen representaciones parecidas, ya que estos recursos no entienden los contextos generalmente, solo que ambas comparten la palabra banco.

Por lo tanto, estamos buscando un modelo que, cuando analice los fragmentos, tenga en cuenta los contextos y cuestiones como la ironía o la burla. Esto es más complicado de lo que parece en texto escrito. Es por esto que debemos recurrir a modelos especialmente entrenados para esta tarea. Es aquí donde aparece el modelo de DistilRoBERTa-base. Específicamente el fine-tuning de J.Hartmann [30], que fue entrenado con datasets anotados para emociones (como GoEmotions[31] de Google), lo que lo hace muy preciso en esta tarea.

DistilRoBERTa es un modelo que ha demostrado ser fiable en tareas de PLN porque conserva la mayoría del rendimiento de RoBERTa-base emotions, mientras reduce significativamente su tamaño y tiempo de inferencia. Según Sanh et al. [32] permite transferir conocimientos de un modelo grande (como BERT o RoBERTa) a uno más compacto, manteniendo más del 95 % de su precisión. Esto se logra mediante el entrenamiento supervisado de un modelo más pequeño (Distil RoBERTa) para imitar la salida del modelo grande (RoBERTa). Por lo tanto, estamos hablando de un modelo probado académicamente y utilizado frecuentemente en el ámbito del PLN.

En este caso, las puntuaciones de las temáticas sí suman 1 en total. De esta forma, representan la inclinación del fragmento hacia una emoción. Cuando hablamos de sentimiento, esto tiene mucho más sentido, ya que, pese a existir la posibilidad de tener varios sentimientos a la vez, esto es mucho menos común e intenso. De hecho, la mayoría de los modelos de emociones PLN utilizan el softmax de 1 [33], porque tratan las emociones como relativamente excluyentes, priorizando un sentimiento y permitiendo que los matices se noten con los porcentajes secundarios que obtienen las emociones secundarias en cada fragmento. Sin embargo, sí puede tratar varias temáticas a la vez con intensidad, por eso se trataba de forma individual en vez de agregada.

4.3.1. Descripción de las emociones

Por último, analizaremos las emociones del modelo Emotion English DistilRoBERTa-base. El modelo se basa en la teoría de las 6 emociones de Ekman [34], añadiendo una séptima emoción neutral que representa el texto informativo y las emociones que no coinciden con el resto. Según Ekman, existen las siguientes emociones base:

- **Joy / Alegría:** Ekman la describe como un estado emocional positivo que se manifiesta mediante sonrisas y expresiones faciales de satisfacción. Se manifiesta en el texto mediante palabras y frases que denotan placer, satisfacción o bienestar.

El fragmento de Donald Trump con mayor puntuación de la categoría *joy* (0.9861) es el siguiente:

"this could have happened. And it represents a tremendous piece of the Republican Party, and more importantly, it represents a tremendous piece of this country, tremendous piece, a lot more than 50 %. Therefore, we have to get out and vote. This past week, I was honored to receive two endorsements of former Democrats for president: Tulsi Gabbard and Robert F. Kennedy, Jr. And they're both great people. They were Democrats, as you probably know, and they felt very strongly about the endorsement, and I feel very happy to get it. Every day, we are welcoming more Republicans, independents, traditional Democrats, and old-fashioned liberals. You know, they don't use that term anymore. They use progressive. We don't use that term. We like liberal, better. Progressive sounds so good. It...."

— Donald Trump, Johnstown, Pensilvania, 30 de julio de 2024

- **Anger / Enfado:** Es una emoción que surge ante situaciones percibidas como injustas o amenazantes, con expresiones faciales de cejas fruncidas y labios apretados. Dentro del contexto de discursos escritos, se manifiesta mediante lenguaje fuerte, acusaciones o expresiones de frustración.

El fragmento de Donald Trump con mayor puntuación de la categoría *anger* (0.9824) es el siguiente:

"angry at the debate, angry. I was angry. And yes, I am angry because he allowed 21 million illegal aliens invading our communities. Many of them are criminals. Many are criminals. I'm angry. I'm angry. They said, He's an angry person. No, they're destroying our country. I don't like – you know, she's smiling, all practice right? Did you see her? She's like this. We're talking about a border invasion, the likes of which no country has ever suffered. And she's like this. But I am angry about Venezuelan gangs taking over Aurora, Colorado and illegal Haitians, and he came in, illegal Haitian migrants taking over a beautiful place. It was so beautiful, Springfield, Ohio. I was there. I campaigned there a while ago. Springfield, it was so...."

— Donald Trump, Tucson, Arizona, 12 de septiembre de 2024

- **Disgust / Asco:** Ekman describía el asco como la emoción de repulsión hacia algo desagradable o contaminante, con expresiones faciales como la nariz arrugada y el labio superior levantado. En el ámbito escrito se entiende como expresiones de rechazo o aversión.

El fragmento de Donald Trump con mayor puntuación de la categoría *disgust* (0.9851) es el siguiente:

"to have no debates, but one maybe at the most. And she wants it to be on ABC because ABC, with George Stephanopoulos – have you ever heard of him? It's the nastiest of all. Who would think it, right? You think of NBC as terrible, and they are – MSNBC is disgusting, but the worst might be ABC, and that's the only one she'll do. And you know, when Biden came out with a brilliant idea to have a debate, how did that work out for him? Not so good. But he came out. They handed me Jake Tapper, sometimes referred to as Fake Tapper. But I have to tell you, he was totally fair. And Dana Bash. And they were totally fair. They really were, CNN..."

— Donald Trump, Bozeman, Montana, 9 de agosto de 2024

- **Fear / Miedo:** Se caracteriza por ser una respuesta emocional ante la percepción de peligro o amenaza, caracterizada por ojos muy abiertos y cejas elevadas. Su manifestación en texto se refleja en expresiones de preocupación, ansiedad o anticipación de consecuencias negativas.

El fragmento de Donald Trump con mayor puntuación de la categoría *fear* (0.9736) es el siguiente:

"have that. And that's why we all need to pull together to thwart these attempts and to bring back American strength, power, and prestige. We will soon have it back. No threat will shake me. No enemy will intimidate me. And I have – I have never been more determined than I am today, and I will never back down in my fight to make America great again, which is what we're doing. So, I want to make that statement because we are under threat. I have been threatened very directly, and I appreciate the agencies that we've been meeting with. But we've been threatened very directly by Iran. And I think you have to let them know because the best way to do it is through the..."

— Donald Trump, Mint Hill, Carolina del Norte, 25 de septiembre de 2024

- **Sadness / Tristeza:** Ekman describía la tristeza como la emoción que refleja pérdida, desánimo o aflicción, con expresiones faciales como comisuras de los labios hacia abajo y párpados caídos. Esto se evidencia en el texto mediante palabras que transmiten melancolía, pérdida o desánimo.

El fragmento de Donald Trump con mayor puntuación de la categoría *sadness* (0.9746) es el siguiente:

"place. But I'd like you to take a look at this. And it's so unnecessary it should have never happened. Please. Thank you. So sad. So unnecessary. Would have never happened if you had like the chart shows you. It would have never happened. What a sad, sad situation. Here today is another American mom, Tammy Nobles and her wonderful husband, Jeremiah. Two years ago, Tammy's 20-year-old daughter, Kayla, was found raped, tied up, and strangled to death with a telephone cord in her home in Maryland. Kayla's murderer was an illegal alien, MS-13 gang member who was apprehended by Border Patrol. But under the policy of Kamala Harris, he was released into the United States to kill and kill at will. Tammy, please come up. Thank you..."

— Donald Trump, Greensboro, Carolina del Norte, 2 de noviembre de 2024

- **Surprise / Sorpresa:** Por último, la sorpresa es la reacción emocional ante eventos inesperados, con expresiones faciales de boca y ojos abiertos. En texto, se evidencia mediante expresiones de asombro o incredulidad.

El fragmento de Donald Trump con mayor puntuación de la categoría *surprise* (0.975) es el siguiente:

"see when President Obama and Michelle called? Did you see? Hello. Hello. Yes. Yes. Who is this? Oh, this is Michelle and Barack. Oh. Oh. So surprised to hear. They got four cameras in front. Oh, I'm so surprised. It's on speakerphone. Listen, we just want to congratulate you on destroying Joe Biden – I mean, on winning the – Hey, is Joe Biden – was that the phoniest phone call you've ever seen? What don't you think, Dan? What do you think? Dan Meuser, a great congressman. What do you think? Was that a phony phone call? You wouldn't do it. You wouldn't get away. In your district, you wouldn't get away with it, would you? But she's a defund-the-police radical trying to pass herself off as..."

— Donald Trump, Harrisburg, Pensilvania, 31 de julio de 2024

4.4 Modelo de análisis de sentimiento

La elección de incluir sentimiento cuando ya tenemos emociones cumple un rol complementario e informativo. Por un lado, permitirá clasificar las emociones en positivas y negativas y así comprobar que el análisis de sentimientos está realizando un buen trabajo. Esto es especialmente útil porque podemos ver en qué medida cada emoción es positiva o negativa, y cuando haya alteraciones de la positividad o la negatividad, ver a qué emociones es debido.

Por otro lado, nos permitirá complementar el análisis de PLN con nuevas dimensiones y estadísticas que se mostrarán más adelante. Los análisis de sentimiento simplemente incluyen cuánto de positivo o negativo es un mensaje o si, por el contrario, no existe sentimiento y es meramente informativo.

Con esto claro, necesitamos un modelo especialmente fiable y probado que pueda complementar tanto el modelo de sentimientos como el de temáticas. Para ello utilizaremos uno de los modelos que más referencias tiene académicamente: RoBERTa.

RoBERTa (A Robustly Optimized BERT Pretraining Approach) [35] es un modelo de lenguaje basado en la arquitectura de transformers de tipo encoder, que mejora significativamente el rendimiento del modelo original BERT mediante ajustes en el proceso de preentrenamiento. RoBERTa ha demostrado rendimientos superiores en múltiples benchmarks, convirtiéndose en un estándar robusto y ampliamente adoptado en el campo del procesamiento del lenguaje natural.

Específicamente, utilizaremos el finetuning de RoBERTa de Cardiff [36], entrenado con más de 124 millones de tweets y dedicado específicamente a detectar la positividad o negatividad del mensaje [37]. El contexto de los tweets, aparte de ser uno de los más populares y mejor entrenados, es ideal para nuestro contexto. Los fragmentos son de una longitud muy parecida a los tweets y se adaptan perfectamente al finetuning. Si analizáramos los discursos enteros, este finetuning sería menos preciso, pero para nuestro caso es especialmente indicado.

4.4.1. Descripción de los estados del sentimiento

Explicemos ahora las etiquetas de sentimiento que nos provee el modelo RoBERTa Sentiment. Según reflejan los autores en la tarjeta explicativa del modelo, el sentimiento puede ser:

- **Negative:** El texto expresa una opinión negativa, crítica o de descontento. El fragmento de Donald Trump con mayor puntuación de *negative* (0.9742 %) es el siguiente:

"just had 117 people shot. You could take just Chicago and the whole nation's crime rate. Look, these are bad people. They're phony people, they're liars, they cheat on elections, they do a lot of bad things, and we have to win this election because crime statistics are a disaster. They're made up by people that work in the White House. And obviously, the crime is getting worse because we have probably 20 million people in our country right now. And every single day, you read about one of these horrible monsters from parts unknown who raped a young girl, killed her, cut them up, used his knives, not guns because it's a slower death. These are monsters, and we have them in our country. And we're going..."

— Donald Trump, Harrisburg, Pensilvania, 31 de julio de 2024

- **Neutral:** El texto no refleja emoción evidente. Es informativo, objetivo o sin carga afectiva. Es importante destacar que este neutral, nombrado como *neutral_sent* en la base de datos, no tiene porque tener relación con el neutral como emoción (*neutral_emo* en la base de datos) que se explicaba anteriormente. El fragmento de Donald Trump con mayor puntuación de *neutral_sent* (0.6830 %) es el siguiente:

"wanted it back in the states. And then about 14 years ago, people started talking about the number of weeks, the number of months, the number of this that they wanted it back in the states where people can decide. And that's what's happening. You look at Ohio, they decided. You look at Kansas, they decided. You look at a lot of different states, they decided. And sometimes, it comes out the way certain people want it. Sometimes, it didn't. Ohio came out with somewhat of a liberal interpretation and so did Kansas, which was a little surprising. But it's the vote of the people. Like Ronald Reagan, I believe in exceptions, for the life of the mother, rape, and incest. And I also believe that you have..."

— Donald Trump, St Cloud, Minesota, 27 de julio de 2024

- **Positive:** El texto transmite una valoración positiva, satisfacción o aprobación. El fragmento de Donald Trump con mayor puntuación de *positive* (0.9921 %) es el siguiente:

"Thank you very much. Thank you very much, everybody. Thank you very much. A very big hello to North Carolina, special place. You saw the other day, my little granddaughter, she's named Carolina. That's for a reason because Lara, her mother is from here, and she's doing a fantastic job, a fantastic person. So, it's great to be here. And great to be back in this beautiful state with thousands of proud, hard-working American patriots, which is what you are. I want to thank very much Glenn Mosack and everyone at The Mosack Group for welcoming me today. This is a beautiful, fantastic place. And I must tell you, Glenn is the owner and the boss and all of that, and he grabbed me as I'm coming up...."

— Donald Trump, Mint Hill, Carolina del Norte, 25 de septiembre de 2024

4.5 Selección de los discursos

Una vez tenemos claro la forma en la que vamos a analizar los discursos, debemos obtener la muestra de los discursos. Como decíamos anteriormente, cualquier muestra

sería válida y funcionaría con estos modelos, pero a efectos de este trabajo se tomarán todos los discursos que forman parte de la campaña electoral de Donald Trump.

La elección de un único candidato es necesaria para posteriormente poder obtener una IA que sí cree discursos coherentes para un candidato específico. El trabajo y el modelo posteriormente expuesto son útiles para cualquier ponente. Es decir, el trabajo está diseñado para poder utilizarse en cualquier contexto, simplemente se centra en Estados Unidos para realizar el posterior análisis de una situación política que está de especial actualidad.

4.5.1. Periodo a considerar

La campaña electoral resulta una muestra idónea en dos sentidos:

En primer lugar, es una muestra suficiente, tras el filtrado que se explicará posteriormente, la muestra queda en 73 discursos. Este número puede parecer insuficiente, pero se trata de discursos realmente extensos, de entre una y tres horas cada uno. Esto acaba representando 13.425 fragmentos individuales con sus respectivas puntuaciones en emociones, sentimiento y temáticas. Esto conforma una muestra más que suficiente para analizar el desempeño de Trump mediante modelos y para el posterior enriquecimiento.

El Stanford Sentiment Treebank [38], uno de los corpus de referencia en análisis de sentimientos, consta de 11.855 oraciones y con ello logró mejorar la exactitud de clasificación binaria de sentimiento hasta el 85,4 %. También tenemos la referencia de IMDB Large Movie Review Dataset [39], otro corpus clásico para clasificación binaria de sentimiento, que contiene 50.000 reseñas balanceadas (25.000 para entrenamiento y 25.000 para prueba). Con 25.000 muestras, ha servido como benchmark estándar en decenas de trabajos y permite obtener precisiones superiores al 85 %. Es decir, que los estándares de referencia de análisis de sentimientos PLN utilizan muestras de entre 10.000 y 25.000 fragmentos, por lo que el tamaño del dataset es adecuado.

En segundo lugar, el periodo temporal es el adecuado porque es donde se acentúan las dinámicas y estrategias políticas. Los sentimientos y las temáticas más rentables políticamente empiezan a explotarse por los candidatos. Le Pennec y Pons [40] analizaron datos de 62 países entre los que se encontraba EE.UU. y llegaron a la conclusión de que entre un 17% y un 29 % del voto se decide durante la campaña electoral. Por su parte, Jacobson [41] recopila múltiples estudios (gasto, publicidad, movilización, campañas negativas) y concluye que las campañas persuasivas y de movilización tienen efectos reales y que no todo depende de la identificación política e ideológica, sino de cómo llegan y se transmiten estas ideas.

Esta revisión nos permite seleccionar la campaña electoral de Donald Trump como un dataset razonable para llevar a cabo el trabajo. Es lo suficientemente grande y es un periodo de alta volatilidad en la intención del voto, teniendo gran importancia en el resultado de las elecciones.

La campaña electoral de Trump empezó oficialmente el 6 de junio en Phoenix, donde tuvo lugar su primer *rally* tras ser confirmado como candidato republicano. Esta campaña se acabó el 4 de noviembre en Grand Rapids, el día anterior a las elecciones generales que tuvieron lugar el 5 de noviembre. Los discursos anteriores al 6 de junio de Donald Trump no serán tenidos en cuenta en este análisis porque formaban parte de su campaña para ganar las primarias republicanas, y por lo tanto, tenían una estrategia discursiva diferente. El intervalo de discursos a estudiar es del 6 de junio de 2024 al 4 de noviembre de 2024.

4.5.2. Obtención de los discursos

A partir de aquí, podemos empezar con la recolección y procesamiento de los textos. Los textos serán obtenidos de la plataforma RollCall [42].

La elección de Rollcall como fuente de obtención de los discursos está justificada por su notoriedad en el contexto estadounidense como plataforma especializada en información política y legislativa que lleva cubriendo la información del Congreso de los Estados Unidos desde 1955. Durante la campaña electoral, RollCall recopiló todos los discursos de Donald Trump, permitiendo acceder a sus transcripciones así como también a los audios. A efectos de este trabajo, utilizaremos solo transcripciones escritas de este medio, ya que la fiabilidad académica está garantizada gracias a la supervisión editorial que caracteriza al medio y a la publicación transparente de sus transcripciones que luego son contrastadas por otros medios.

Sin embargo, las transcripciones no están disponibles para extraerlas limpias directamente, ya que no existe una API ni herramientas similares. Será necesario el uso de *scraping* a partir de los HTMLs de la página web para obtener las transcripciones completas. El proceso de extracción se tratará en el quinto apartado de Desarrollo de la solución.

Por último, se descartan 5 *rallies* que no aplican al análisis de discursos, puesto que son entrevistas. Estos *rallies* seguramente sean muy importantes también en la estrategia política de los candidatos, pero no son el objeto de estudio del trabajo. La comunicación de las entrevistas es totalmente diferente a la de los discursos y podría distorsionar la muestra y las puntuaciones de emociones, sentimientos y temáticas.

Se muestra la tabla 4.1 con la agenda completa de Trump, incluyendo las ciudades y estados donde se dio el discurso y links accesibles a la transcripción escrita y al audio y vídeo de los mismos:

Tabla 4.1: Discursos de Trump en campaña

Nº	Fecha	Ciudad	Estado	Link
1	June 6, 2024	Phoenix	Arizona	RollCall: Phoenix June 6
2	June 9, 2024	Paradise	Nevada	RollCall: Paradise June 9
3	June 15, 2024	Detroit	Michigan	RollCall: Detroit June 15
4	June 18, 2024	Racine	Wisconsin	RollCall: Racine June 18
5	June 22, 2024	Philadelphia	Pennsylvania	RollCall: Philadelphia June 22
6	June 28, 2024	Chesapeake	Virginia	RollCall: Chesapeake June 28
7	July 9, 2024	Doral	Florida	RollCall: Doral July 9
8	July 13, 2024	Meridian	Pennsylvania	RollCall: Meridian July 13
9	July 20, 2024	Grand Rapids	Michigan	RollCall: Grand Rapids July 20
10	July 24, 2024	Charlotte	North Carolina	RollCall: Charlotte July 24
11	July 27, 2024	St. Cloud	Minnesota	RollCall: St. Cloud July 27
12	July 31, 2024	Harrisburg	Pennsylvania	RollCall: Harrisburg July 31
13	August 3, 2024	Atlanta	Georgia	RollCall: Atlanta August 3
14	August 9, 2024	Bozeman	Montana	RollCall: Bozeman August 9
15	August 14, 2024	Asheville	North Carolina	RollCall: Asheville August 14
16	August 17, 2024	Wilkes-Barre	Pennsylvania	RollCall: Wilkes-Barre August 17
17	August 21, 2024	Asheboro	North Carolina	RollCall: Asheboro August 21
18	August 23, 2024	Glendale	Arizona	RollCall: Glendale August 23
19	August 29, 2024	La Crosse	Wisconsin	Entrevista (Se descarta)
20	August 30, 2024	Johnstown	Pennsylvania	RollCall: Johnstown August 30
21	September 7, 2024	Mosinee	Wisconsin	RollCall: Mosinee September 7
22	September 12, 2024	Tucson	Arizona	RollCall: Tucson September 12
23	September 13, 2024	Las Vegas	Nevada	RollCall: Las Vegas September 13

Continúa en la siguiente página

(Continuación de la tabla)

Nº	Fecha	Ciudad	Estado	Link
24	September 17, 2024	Flint	Michigan	Entrevista (Se descarta)
25	September 18, 2024	Uniondale	New York	RollCall: Uniondale September 18
26	September 21, 2024	Wilmington	North Carolina	RollCall: Wilmington September 21
27	September 23, 2024	Indiana	Pennsylvania	RollCall: Indiana September 23
28	September 24, 2024	Savannah	Georgia	RollCall: Savannah September 24
29	September 25, 2024	Mint Hill	North Carolina	RollCall: Mint Hill September 25
30	September 27, 2024	Warren	Michigan	RollCall: Warren September 27
31	September 28, 2024	Prairie du Chien	Wisconsin	RollCall: Prairie September 28
32	September 29, 2024	Erie	Pennsylvania	RollCall: Erie September 29
33	October 1, 2024	Waunakee	Wisconsin	RollCall: Waunakee October 1
34	October 1, 2024	Milwaukee	Wisconsin	RollCall: Milwaukee October 1
35	October 3, 2024	Saginaw	Michigan	RollCall: Saginaw October 3
36	October 4, 2024	Fayetteville	North Carolina	RollCall: Fayetteville October 4
37	October 5, 2024	Meridian	Pennsylvania	RollCall: Meridian October 5
38	October 6, 2024	Juneau	Wisconsin	RollCall: Juneau October 6
39	October 9, 2024	Scranton	Pennsylvania	RollCall: Scranton October 9
40	October 9, 2024	Reading	Pennsylvania	RollCall: Reading October 9
41	October 11, 2024	Aurora	Colorado	RollCall: Aurora October 11
42	October 11, 2024	Reno	Nevada	RollCall: Reno October 11
43	October 12, 2024	Coachella	California	RollCall: Coachella October 12
44	October 13, 2024	Prescott Valley	Arizona	RollCall: Prescott October 13
45	October 14, 2024	Oaks	Pennsylvania	Entrevista (se descarta)
46	October 15, 2024	Atlanta	Georgia	RollCall: Atlanta October 15
47	October 18, 2024	Detroit	Michigan	RollCall: Detroit October 18
48	October 19, 2024	Latrobe	Pennsylvania	RollCall: Latrobe October 19
49	October 20, 2024	Lancaster	Pennsylvania	Entrevista (se descarta)
50	October 21, 2024	Greenville	North Carolina	RollCall: Greenville October 21
51	October 21, 2024	Concord	North Carolina	RollCall: Concord October 21
52	October 22, 2024	Greensboro	North Carolina	RollCall: Greensboro October 22
53	October 23, 2024	Zebulon	Georgia	RollCall: Zebulon October 23
54	October 23, 2024	Duluth	Georgia	RollCall: Duluth October 23
55	October 24, 2024	Tempe	Arizona	RollCall: Tempe October 24
56	October 25, 2024	Traverse City	Michigan	RollCall: Traverse October 25
57	October 26, 2024	Novi	Michigan	RollCall: Novi October 26
58	October 26, 2024	State College	Pennsylvania	RollCall: State College October 26
59	October 27, 2024	New York City	New York	RollCall: New York October 27
60	October 28, 2024	Atlanta	Georgia	RollCall: Atlanta October 28
61	October 29, 2024	Allentown	Pennsylvania	RollCall: Allentown October 29
62	October 30, 2024	Rocky Mount	North Carolina	RollCall: Rocky Mount October 30
63	October 30, 2024	Green Bay	Wisconsin	RollCall: Green Bay October 30
64	October 31, 2024	Albuquerque	New Mexico	RollCall: Albuquerque October 31
65	October 31, 2024	Henderson	Nevada	RollCall: Henderson October 31
66	October 31, 2024	Glendale	Arizona	Entrevista (se descarte)
67	November 1, 2024	Warren	Michigan	RollCall: Warren November 1
68	November 1, 2024	Milwaukee	Wisconsin	RollCall: Milwaukee November 1
69	November 2, 2024	Gastonia	North Carolina	RollCall: Gastonia November 2
70	November 2, 2024	Salem	Virginia	RollCall: Salem November 2
71	November 2, 2024	Greensboro	North Carolina	RollCall: Greensboro November 2
72	November 3, 2024	Lititz	Pennsylvania	RollCall: Lititz November 3
73	November 3, 2024	Kinston	North Carolina	RollCall: Kinston November 3
74	November 3, 2024	Macon	Georgia	RollCall: Macon November 3
75	November 4, 2024	Raleigh	North Carolina	RollCall: Raleigh November 4
76	November 4, 2024	Reading	Pennsylvania	RollCall: Reading November 4
77	November 4, 2024	Pittsburgh	Pennsylvania	RollCall: Pittsburgh November 4
78	November 4, 2024	Grand Rapids	Michigan	RollCall: G.Rapids November 4

4.6 Procesamiento de textos

El tratamiento de los datos es fundamental para obtener mejores resultados en cualquier proceso de análisis. En el ámbito del PLN, los textos suelen tratarse mediante eliminación de signos de puntuación, de palabras comodín u otros. A continuación se contemplarán todas las múltiples posibles formas de tratamiento y se justificará cuáles son las más óptimas para los modelos que han sido seleccionados:

4.6.1. Signos de puntuación

La discusión fundamental a abordar en este punto es cómo enfocar el tratamiento de los signos de puntuación. La pregunta a responder es: ¿Aportan los signos de puntuación un mejor entendimiento de las temáticas o los sentimientos? Dividiremos este análisis en dos partes.

En primer lugar, analizaremos las interpelaciones del público. En los textos en crudo existen intervenciones del público cuando interrumpen los discursos de Trump con sus cánticos. Un ejemplo de esto lo podemos visualizar en la siguiente frase transcrita:

"Wow. Thank you very much. Thank you. This is a big crowd, a nice crowd. [Audience chants "USA"] Thank you very much [...]"

— Donald Trump, Bozeman, Montana, 9 de agosto de 2024

En este caso, resulta necesario eliminar el contenido entre corchetes. Es contenido que, pese a aportar contexto sobre cómo reaccionó el público, no forma parte del propio discurso. De hecho, podría confundir a los modelos pensando que estas interpelaciones narradas son en verdad palabras que pronunció el propio Trump. En definitiva, es deseable eliminar el contenido entre corchetes que no forma parte de los discursos para evitar discrepancias y confusiones en el modelo.

Por otro lado, tenemos signos de puntuación que sí forman parte del discurso y la transcripción de Trump. En este apartado nos referimos a puntos, comas y a comillas que se usan para explicitar citas que realiza Trump en sus discursos. Un ejemplo del uso de comillas lo podemos ver ilustrado en el mismo discurso del 9 de agosto, cuando hablaba sobre Bernie Sanders y citaba lo que decían de él. Así se mostraba en el texto en crudo:

"We had the same problem. Do you remember? He comes out. Everyone's saying, "He really likes your policy a lot." He doesn't like [...]"

— Donald Trump, Bozeman, Montana, 9 de agosto de 2024

Estos signos sí que aportan significado, pero esto no quiere decir que mejoren el rendimiento de los modelos. Existen multitud de estudios que nos pueden aportar algo de luz al respecto, sobre cuál debería ser la decisión en este sentido.

Recientemente, Razzhigaev et al. [43] encontraron que quitar tokens "menores" (determinantes, comas, comillas) degrada el rendimiento en tareas de razonamiento y comprensión a largo plazo, tanto en MMLU [44] como en benchmarks de largo contexto. Esto afectaría al análisis PLN, pero también existen problemas con el eliminado para la posterior generación de discursos. Karami et al. [45] establecieron que los *embeddings* de

Transformer distinguen frases por comas y comillas, y que eliminarlas reduce la calidad de las representaciones semánticas. Es decir, que también afectaría a los *embeddings* que luego utilizaremos para la generación de discursos.

Por lo tanto, tras esta revisión de estudios sobre el funcionamiento de modelos, podemos concluir que eliminar los signos de puntuación puede afectar al rendimiento de los modelos y a la generación de discursos y no deberíamos procesarlo para quitar estos signos de puntuación.

4.6.2. Stop words

La segunda discusión se centra en la eliminación o borrado de *stop words*. Una *stop word* o palabra vacía son palabras que, desde la perspectiva gramatical, son necesarias para la coherencia del discurso, pero que poseen un valor semántico reducido y que podrían dificultar el rendimiento de los modelos. Ejemplos de *stop words* son conjunciones, preposiciones o artículos.

La práctica de eliminar las *stop words* fue especialmente relevante en los modelos de clasificación de temáticas como el LDA. Estos modelos no proveen de un nombre a las temáticas, sino que solo dan las palabras que más se repetían en esa temática detectada. Si no se eliminan las *stop words*, se corre el riesgo de que las palabras más repetidas sean precisamente conjunciones o artículos, que son los más comunes dentro del léxico inglés.

Sin embargo, como ya se discutió en el apartado de elección de modelos, el modelo de temáticas escogido no funciona a partir de palabras repetidas y definiendo por su cuenta temáticas. Funciona mediante categorías seleccionadas previamente. En este contexto debemos plantearnos si las *stop words* siguen siendo un impedimento o si, por lo contrario, ayudan a tener una mejor clasificación tanto de sentimientos como de temáticas.

A este respecto, Saif et al. [46] analizan el impacto de eliminar *stop words* en el análisis de sentimientos aplicado a Twitter. A diferencia de tareas clásicas de clasificación de texto, los autores demuestran que algunas *stop words* como *not*, *never*, *very*, o *no* aportan información crítica para identificar la polaridad de un mensaje. Su eliminación puede degradar significativamente el rendimiento de los clasificadores de sentimiento. Por otro lado, Rezapour [47] encontraba que técnicas rutinarias de preprocesado como eliminar puntuación y *stop words* empeoran la detección de emociones, porque los modelos dependen de ellas para captar matices emocionales.

Por lo tanto, podemos llegar a la conclusión de que las *stop words* sí ayudan a detectar matices emocionales en modelos como los utilizados en este trabajo. Por otro lado, también hemos podido comprobar cómo no reduce la precisión del modelo de clasificación de temáticas. Es decir, no existe razón para eliminar las *stop words* del discurso. Todo lo contrario, eliminarlas puede incluso empeorar el rendimiento.

4.6.3. Chunks

La tercera discusión del tratamiento de texto son los *chunks* en los que vamos a dividir el discurso. Los discursos de campaña de Donald Trump duran entre una y tres horas habitualmente y el procesamiento de discursos tan largos causa muchos problemas. Primeramente, la precisión del análisis disminuye muchísimo, ya que los modelos no están preparados para analizar textos tan largos. Además, el coste de realizar estos análisis escala a niveles muy grandes y hace realmente insostenible su tratamiento correcto.

Por esta razón se divide el discurso en *chunks*. Se entiende como *chunk* a la unidad de texto que va a procesar el modelo. Un único texto se podría dividir en 200 *chunks* o

500 *chunks*, dependiendo del tamaño, que luego se procesarían de forma individual en los modelos. Finalmente, también sirven para obtener estadísticas agregadas del propio discurso. Existen tres características a tener en cuenta sobre cómo realizar los *chunks*. La forma de realizar los cortes (*fixed size* o corte semántico), el tamaño de los *chunks* (Cuántas palabras deberían formar parte de cada *chunk*) y el solapamiento (Si deberían repetirse palabras entre *chunks*). Analicemos las tres casuísticas:

Corte de los chunks

Existen dos principales opciones a este respecto. El corte fijo o *fixed size chunk* establece que los chunks se cortarían después de un número determinado de palabras, siempre el mismo. Por otro lado, el corte semántico detecta las frases o construcciones semánticas y realiza el corte cuando termina el conjunto semántico.

Existen diferencias a nivel de coste también a tener en cuenta. El corte semántico necesita de la detección de conjuntos semánticos, lo que aumenta el coste computacional. Por otro lado, el corte semántico puede realizar *chunks* demasiado grandes, que pese a tener sentido semántico, son demasiado grandes y acaban lastrando el rendimiento de los modelos.

A este respecto, Qu et al. [48] encontraron que el coste semántico puede ofrecer mejoras marginales pero que no ofrece una mejora de resultados que compense el gran aumento de coste. Como mencionábamos anteriormente, en este trabajo contamos con recursos limitados, mientras ambas opciones consigan resultados similares, nos decantaremos por la que tenga menor coste.

Además no debemos olvidar el problema del tamaño indefinido de los *chunks*. Si obtenemos uno demasiado grande, el rendimiento de los modelos decaerá. Debido a estas dos razones, lo más coherente es realizar un corte fijo.

Tamaño de los chunks

Una vez decidido que el corte debe ser fijo, es importante determinar el tamaño ideal de corte. Un corte demasiado corto puede llevar a resultados absurdos, ya que se pierde el significado de las palabras al procesarse de forma independiente. Un corte demasiado grande lleva a resultados muy ambiguos, poco representativos y con un coste muy grande. Para tomar una decisión sobre el tamaño, debemos realizar una revisión de estudios para comprobar cuál podría ser el tamaño de chunk ideal.

Para encontrar el tamaño ideal podemos recurrir al estudio de Jaiswal et al. [49]. Comprobaban que un *chunk size* de 128 *tokens* ya obtiene rendimientos comparables a modelos especializados en largo contexto, confirmando que 128–150 *tokens* es óptimo para clasificar textos extensos sin perder coherencia. Es por esto que escogeremos un *chunk size* de 128 *tokens*.

Solapamiento

El tamaño escogido garantiza una cantidad de contexto adecuada, pero podemos maximizar ese contexto para conseguir un mejor rendimiento de los modelos gracias al solapamiento entre *chunks*. Entendemos como solapamiento a la compartición de palabras entre *chunks* contiguos. Por ejemplo, si existe un solapamiento del 30 %, en *chunks* de 100 palabras, las 30 últimas palabras del primer *chunk* serán las 30 primeras palabras del segundo *chunk*. De esta forma, se pretende minimizar el efecto de los cortes arbitrarios que se pueden llegar a cometer con los cortes fijos. A este respecto, nos interesa analizar

si el solapamiento es efectivo, pero también en qué porcentaje debemos hacerlo y si el solapamiento incrementa demasiado el número de *chunks* haciendo el coste insostenible.

Ivgi et al. [50] estudiaba cómo realizar análisis de textos largos a partir de modelos que analizan textos cortos. Esto es exactamente lo que estamos haciendo nosotros. En su investigación concluían que cuando el texto se trata en *chunks* fijos, con solapamiento y procesados por modelos para textos cortos, el rendimiento es igual o superior al que ofrecen modelos especializados de largo contexto cincuenta veces más grandes.

También demuestra que el solapamiento es clave para retener dependencias cruzadas entre ventanas de texto. Es decir, este estudio valida que no solo los *chunks* solapados mejoran el coste, sino que también mejoran el análisis. Por lo tanto, gracias a este análisis podemos concluir que un solapamiento de 0,5 o del 50 % debería mejorar los resultados de los análisis de PLN.

4.6.4. Conclusión de la discusión del tratamiento

Después de esta discusión crítica, hemos podido descartar algunos métodos y simplificar el proceso para optimizar el resultado. Ahora, podemos establecer que los procesos de tratamiento que debemos realizar, en orden de ejecución, son:

1. Quitar corchetes e interpelaciones que no forman parte del discurso
2. Realizar chunks de 128 palabras
3. Modificar los chunks para que exista un solapamientos de 0.5

4.7 Diseño de la base de datos

Para efectos de este trabajo, la utilización de la base de datos es fundamental. Permitirá extraer estadísticas de una forma mucho más ágil y organizada para el posterior análisis. También facilitará la creación de los *embeddings* y los índices semánticos de FAISS. A continuación, se describirá la base de datos y se establecerán los diagramas relacionales y de clases.

4.7.1. Descripción de la base de datos

La extensión del problema es sencilla. Tan solo existirán dos tablas, una para los fragmentos y otra para los discursos. Ambas almacenarán las puntuaciones de las emociones, el sentimiento y las emociones. En el caso de los fragmentos, serán directamente las que arroje el análisis. En el caso de los discursos, serán la media de los fragmentos que la conforman. Estos atributos estarán en la tabla de discursos para mayor comodidad y eficiencia en el análisis de datos.

Ambas tablas también tendrán sus respectivos identificadores y, además, cada fragmento tendrá el id del discurso al que pertenece. Por último, la tabla de discursos contendrá también la fecha, la ciudad y el estado donde se produjo aquel discurso. Todos los atributos deberán ser valores no nulos y todos los atributos de puntuaciones asociadas a los modelos deberán ser valores enteros.

4.7.2. Diagrama de clases

En la figura 4.1 se puede observar un diagrama donde se muestra la distribución de las clases de la base de datos.




Figura 4.1: Diagrama de clases de la base de datos

4.7.3. Diagrama relacional

En esta sección se muestra el diagrama relacional de la base de datos de discursos en las figuras 4.2 y 4.3.

Esquema relacional de Fragment

```
Fragment(fragmento_id:cadena, discurso_id:cadena,
text:cadena,economy:real, infrastructure:real, health:real,
security:real, education:real,immigration:real, foreign_policy:real,
joy:real, anger:real, sadness:real, fear:real, disgust:real,
surprise:real, neutral_emo:real, negative:real, neutral_sent:real,
positive:real)
```

CAj:{discurso_id} Referencia Discourse(discurso_id)

CP: {fragmento_id}

VNN: {discurso_id, text, economy, infrastructure, health, security, education, immigration, foreign_policy, joy, anger, sadness, fear, disgust, surprise, neutral_emo, negative, neutral_sent, positive}

Figura 4.2: Esquema relacional de la tabla Fragment

Esquema relacional de Discourse

```
Discourse(discurso_id:cadena, titulo:cadena, fecha:fecha,
ciudad:cadena, estado:cadena, economy:real, infrastructure:real,
health:real, security:real, education:real, immigration:real,
foreign_policy:real, joy:real, anger:real, sadness:real, fear:real,
disgust:real, surprise:real, neutral_emo:real, negative:real,
neutral_sent:real, positive:real)
```

CP: {discurso_id}

VNN: {titulo, fecha, ciudad, estado, economy, infrastructure, health, security, education, immigration, foreign_policy, joy, anger, sadness, fear, disgust, surprise, neutral_emo, negative, neutral_sent, positive}

Figura 4.3: Esquema relacional de la tabla Discourse

4.7.4. Acceso a la base de datos

Debido a la sencillez de la base de datos, esta se almacenará en local. Para las consultas y comprobación se accederá mediante SQLite web, que permite la consulta de estas bases sin la necesidad de instalar ninguna aplicación alternativa. Es suficiente con escribir en la terminal de VS Code 'sqlite_web' seguido del nombre de la base de datos en local para acceder a ella a través del navegador web. Se muestra en la figura 4.4.

```
sqlite_web tfg.db  
>
```

Figura 4.4: Método de acceso a la base de datos

4.8 Diseño de embeddings para la recuperación de fragmentos

A continuación, una vez diseñada la base de datos, podemos empezar a pensar cómo vamos a diseñar los índices y los *embeddings*. Un *embedding* es una representación vectorial densa y continua de datos categóricos (como palabras, frases o documentos) en un espacio de menor dimensión [51]. En PLN, los *embeddings* permiten capturar relaciones semánticas entre unidades lingüísticas. Se establecen relaciones de cercanía para mejorar el recuperado de fragmentos.

Para el cálculo de *embeddings* se utilizará el modelo preentrenado MiniLM [52] del paquete *sentence-transformers*, basado en la arquitectura *Transformer*. Este modelo genera representaciones *embeddings* de alta calidad que capturan el significado semántico de cada fragmento textual. MiniLM logra un equilibrio notable entre precisión y velocidad, siendo ideal para aplicaciones en producción o en sistemas con recursos limitados.

Posteriormente, para la indexación se utilizará FAISS (*Facebook AI Similarity Search*) [53] para crear un índice que permite realizar búsquedas rápidas por similitud semántica. FAISS es una biblioteca desarrollada por Facebook AI que permite realizar búsquedas eficientes por similitud en colecciones de vectores de alta dimensión. Su funcionamiento se basa en la construcción de índices que organizan estos vectores para acelerar las búsquedas sin comprometer significativamente la precisión. Para representar la similitud entre vectores, FAISS permite usar diferentes métricas, como la distancia euclidiana (L2) o el producto escalar (*inner product*). Estas son diferentes formas de reducir el coste de búsqueda y mejorar la cercanía para la eficiencia de los *embeddings*.

4.9 Modelos de lenguaje para la generación de discursos

Por último, el modelo de lenguaje utilizado para este trabajo será ChatGPT 4 [4]. Este modelo muestra una capacidad avanzada para comprender el contexto, mantener la coherencia temática y adaptar el estilo de redacción al propósito comunicativo del texto. ChatGPT 4, desarrollado por OpenAI y basado en la arquitectura *Transformer*, ha demostrado un rendimiento significativamente superior a versiones anteriores en tareas que requieren razonamiento complejo, generación de lenguaje natural y adaptación al tono discursivo deseado. Además, Naismith et al. [54] comprobaba que en el ámbito de la semántica y redacción, el modelo era superior incluso a modelos específicamente entrenados para PLN.

4.9.1. Prompting

La fase de *prompting* es fundamental para la correcta generación de discursos. El *prompt* [55] es la instrucción o entrada de texto que un usuario proporciona a un modelo de lenguaje para indicarle qué tipo de respuesta desea obtener.

Nuestro *prompt* estará compuesto de dos partes, los fragmentos recuperados y la parte escrita. Debemos encontrar la forma más efectiva de que el modelo de lenguaje obtenga el mayor valor de los fragmentos recuperados mediante los *embeddings* y el FAISS. Un

prompt no efectivo, por mucho que los fragmentos sean los adecuados, no arrojará discursos realistas y útiles.

En su estudio, Logan et al. [56] concluían que no hace falta un prompting demasiado específico a medida que los modelos mejoran. Los mejores modelos como GPT 4 consiguen mejores resultados con la simplificación de prompts. De hecho, recomienda utilizar el método "BitFit" [57]. Este método se basa en utilizar de primeras un modelo preentrenado (como BERT o RoBERTa), para luego utilizar técnicas de *few shot learning*. Esta técnica, a diferencia del *zero shot* utiliza unos pocos ejemplos para mejorar los resultados. Concluyen que con *few shot learning* y un *prompt* simplificado se obtienen mejores resultados. Es decir, que debemos hacer un *prompt* simple pero que aporte fragmentos que puedan ser relevantes.

Debemos observar también estudios que no apoyen un *prompting* de *few shot* como el que vamos a hacer. Una de las críticas más citadas es Ye et al. [58]. Este estudio apoya el uso de *prompts* nulos, apoyando la reducción y simplificación de las explicaciones porque muchas veces estas explicaciones distorsionan el resultado. Sin embargo, este estudio admite que esto, a menudo, se debe a que las explicaciones no son eficientes, pero que con explicaciones buenas el rendimiento aumenta. Si hemos determinado que los modelos anteriores generan embeddings de calidad y que el recuperado es óptimo, las explicaciones sí podrían mejorar la calidad del discurso generado.

Para el *prompt* por lo tanto, deberemos indicarle al modelo de lenguaje el contexto en el que se encuentra para que adapte los discursos a ese contexto. Además, le indicaremos que debe basarse en los fragmentos que luego le pasaremos. Esto lo haremos con el siguiente *prompt*:

"You are Donald Trump speaking at a rally during a presidential campaign. Speak in English with his style. You MUST base your speech primarily on the example fragments provided below."

Después le introduciremos los fragmentos, pero haciéndole hincapié otra vez en la importancia de basarse en los ejemplos:

"Here are relevant example fragments that show how Trump speaks about the selected topic and how he conveys the given emotion and sentiment:"

A continuación, le pasamos los fragmentos. A efectos de este estudio, le pasaremos los 10 primeros fragmentos que cumplan con las características introducidas. Se puede filtrar por temática, emoción y sentimiento y establecer unos límites de correlación, por ejemplo que solo se recuperen fragmentos con al menos 0.8 de *health* y 0.4 de *joy*.

Además, existe la posibilidad de buscar por cercanía semántica, explotando totalmente la eficiencia de los *embeddings* y el FAISS. Por ejemplo, si queremos hablar de drogas, podemos indicar la temática como *Health* e indicar en *semantic query* las drogas. Es decir, indicamos un mínimo de 0,8 en *Health* y en *semantic query* indicamos "*drugs*". Esto hará que los fragmentos relacionados con drogas y que cumplan el mínimo de *health* se sitúen al principio de los recuperados y así el discurso hable más acerca de ello.

Después de los fragmentos, hacemos las últimas especificaciones:

"Now, please generate a coherent speech in English about [topic], conveying [emotion] and a [sentiment] sentiment. Use clear transitions and a coherent structure. Do not explicitly state the emotion or sentiment a lot they should be expressed through

the tone and style of the message. Avoid repeating the topic excessively; it may be mentioned, but it should remain mostly implicit in the text."

La razón detrás de estas últimas especificaciones es debida a los errores que cometía el modelo en las pruebas. El modelo solía realizar discursos muy compactos y seguidos, ya que no tiene la referencia de cómo es un discurso de Trump en su conjunto, tan solo fragmentos sueltos. Con las transiciones claras y la estructura coherente, el modelo genera discursos con mejor forma y estructura.

Respecto a decir explícitamente las temáticas, las emociones y los sentimientos, el modelo solía expresarlos mediante la repetición de la palabra en algunas ocasiones. Para esto mismo se clarifica en el *prompt* que debe expresarlo a través del texto, tal y como lo hace Trump en los fragmentos.

El resultado final de *prompt* es el siguiente:

"You are Donald Trump speaking at a rally during a presidential campaign. Speak in English with his style. You MUST base your speech primarily on the example fragments provided below.

Here are relevant example fragments that show how Trump speaks about the selected topic and how he conveys the given emotion and sentiment: [fragments]

Now, please generate a coherent speech in English about [topic], conveying [emotion] and a [sentiment] sentiment.

Use clear transitions and a coherent structure. Do not explicitly state the emotion or sentiment a lot they should be expressed through the tone and style of the message. Avoid repeating the topic excessively; it may be mentioned, but it should remain mostly implicit in the text."

4.10 Evaluación de los discursos generados

Cuando evaluamos la precisión del análisis PLN o de la generación de discursos, conseguir una métrica de precisión es realmente complejo. A diferencia de otros campos donde se aplica la IA, no existe exactamente ninguna forma de evaluar totalmente de forma que es enfado o que es asco. A menudo, los estudios de PLN tienden a recurrir a filólogos que clasifican sus textos y comparan las clasificaciones de los filólogos con los resultados de la IA. Sin embargo, existe una clara limitación de alcance a este respecto para este trabajo. La cantidad de horas que se necesitaría para clasificar más de 13 mil fragmentos simplemente no es asumible. Sin embargo, sí que podemos analizar si los discursos generados a partir de los fragmentos recuperados son realistas o no.

Para ello realizaremos una encuesta donde se sitúen algunos fragmentos pronunciados por Donald Trump, algunos producidos por la IA sin ningún tipo de ayuda y otros con la IA tras todo el trabajo de PLN y de recuperación de fragmentos. Los encuestados serán preguntados si creen que el texto ha sido generado por IA o si lo pronunció Donald Trump en la realidad. Con esto podremos medir qué porcentaje de personas confunden un discurso de la IA con uno de Donald Trump. Y especialmente, podremos medir si el trabajo ha conseguido disminuir el porcentaje de acierto o si, por el contrario, hace que se reconozca a la IA más fácilmente.

La encuesta recogerá también datos para encontrar relaciones cruzadas sobre grupos poblacionales específicos. Por ejemplo, si una persona más mayor es más proclive a verse engañada por la IA.

Para los prompts de los discursos sin fragmentos recuperados, utilizaremos el mismo modelo de lenguaje para poder ser lo más fiables posible y poder medir el impacto real de los fragmentos. También incluiremos el mismo prompt inicial, sin los fragmentos y sin las clarificaciones finales (que eran obtenidas a base de pruebas realizadas con fragmentos).

4.10.1. Diseño de la encuesta de verificación

La encuesta con la cual verificaremos si el impacto de los fragmentos ha sido significativo, tendrá dos partes: la recogida de datos y el test de verificación.

En la primera parte se recogen algunos datos que pueden resultar significativos en un posterior análisis para cruzarlos. Las preguntas que se les realizaron a los encuestados en la primera parte se pueden consultar en el anexo A.1.

Las preguntas sobre la información y la escucha de discursos pretenden explorar si las personas más informadas son más difíciles de engañar. Por otro lado, la simpatía pretende extraer los sesgos que puedan surgir de la ideología y si estos hacen que los afines sean más proclives a creer que un discurso es de Trump. La frecuencia de uso pretende examinar si el tiempo dedicado a utilizar IA está proporcionalmente relacionado con el reconocimiento de la IA. Por último, la sexta pregunta pretende recabar información sobre las personas escépticas e ingenuas. Explorar si existe una correlación entre el grado de escepticismo percibido por una persona y el porcentaje de reconocimiento de la IA.

La segunda parte incluye exclusivamente los discursos que los encuestados rellenan respondiendo si consideran que lo hizo una IA o lo dijo Donald Trump. También se ha incluido debajo de cada discurso una escala de certeza del 1 al 5, que mide la seguridad con la que los encuestados han respondido a la pregunta anterior. La segunda parte se compone de 7 discursos: 3 pronunciados por Donald Trump en campaña, 2 realizados por IA y 2 realizados por IA con recuperado de fragmentos mediante *embeddings* y FAISS. Los fragmentos de Trump fueron escogidos de entre los que más puntuación tenían de *Immigration, Security y Health*. Esto se justifica ya que los fragmentos también se van a generar a partir de fragmentos con alta puntuación en estos atributos. Ambos fragmentos de IA y IA con fragmentos fueron producidos sobre temáticas al azar. Para la IA con fragmentos se utilizaron fragmentos con más de 0,8 en la temática escogida y con al menos 0,5 en la emoción más correlacionada con la temática, que se verá en la parte de análisis. La construcción final de la segunda parte de la encuesta se puede consultar en el anexo A.2 junto a las respuestas correctas en el anexo A.3.

CAPÍTULO 5

Desarrollo de la solución

Durante el desarrollo de la solución abordaremos la parte más técnica del trabajo de fin de grado. Exploraremos cómo se ha procesado el texto, las configuraciones que se han realizado para los modelos o algunas partes del código relevantes. En especial, navegaremos a través del flujo de operaciones por el que han pasado los ficheros de texto hasta transformarse en fragmentos útiles para el *prompting* y generación de discursos.

5.1 Obtención de las transcripciones

Empezamos con la recolección y procesamiento de los textos. Los textos son obtenidos de la página web RollCall.com, como se indicaba en el diseño. Como decíamos, tendremos que extraer las transcripciones sin ningún tipo de API ni similares que nos ayuden a hacerlo de forma rápida. De hecho, el texto está entremezclado con métricas de PLN propias de RollCall e intervenciones de otros ponentes que también debemos eliminar. Tendremos que trabajar a partir de los ficheros HTML en crudo.

Es decir, que será necesario el uso de *scraping* a partir de los ficheros HTML de la página web para obtener las transcripciones completas. En primer lugar, seleccionamos el HTML inspeccionando en cada página web y lo guardamos en un documento en local. Una vez guardado en local, debemos buscar algún patrón que nos permita extraer las transcripciones de Trump con un simple código, ya que no es asumible hacerlo a mano. Analizando la estructura del HTML, podemos observar que los fragmentos indican quién es el ponente tal como se muestra en la figura 5.1.

```
<h2 class="text-md inline">Donald Trump</h2>
```

Figura 5.1: Código de detección del autor

Y por otra parte, el principio del fragmento a extraer se indica como la figura 5.2

```
<div class=" flex-auto text-md text-gray-600 leading-loose">Thank you. Wow.  
Thank you very much. Thank you. [...]
```

Figura 5.2: Código de detección del fragmento

Por lo tanto, podemos elaborar un sencillo código que, cuando identifique a Donald Trump como ponente, guarde el texto que está unas filas más adelante y lo almacene en un fichero csv. Cada fragmento en una fila diferente.

5.2 Procesado de texto

Sin embargo, con el paso anterior tan solo hemos conseguido los crudos de RollCall. Estos textos no están tratados y tienen multitud de cosas que cambiar. Durante la revisión crítica del apartado de diseño de la solución, se había acordado:

- Limpiar corchetes e interpolaciones del público
- Hacer *chunks* de un *fixed size* de 128 tokens
- Que los chunks tengan un solapamiento de 0.5

Pasemos entonces a realizar la limpieza del texto para coincidir con lo discutido en el apartado teórico. Empezaremos con los corchetes e interpolaciones.

5.2.1. Corchetes e interpolaciones

Para eliminar los corchetes e interpolaciones basta con identificar los corchetes. No debemos olvidarnos de eliminar también el contenido entre corchetes, las interpolaciones del público, que podrían confundir al modelo. De esta forma, podemos coger los ficheros del repositorio inicial y guardarlos ya sin corchetes. En la figura 5.3 se muestra un extracto del código donde se leen los csv, se borran los corchetes y se guardan en una carpeta nueva.

```
1 # Leer el archivo CSV
2     df = pd.read_csv(csv_file)
3
4     # Verificar si existe la columna 'text'
5     if 'text' in df.columns:
6         # Eliminar texto entre corchetes en la columna 'text'
7         df['text'] = df['text'].apply(remove_bracketed_text)
8
9         # Guardar el archivo procesado en la carpeta de salida
10        file_name = os.path.splitext(os.path.basename(csv_file))[0]
11        output_file = os.path.join(output_folder, f"{file_name}
12                                   _sincorchetes.csv")
13        df.to_csv(output_file, index=False)
```

Figura 5.3: Código de eliminación de corchetes e interpolaciones

5.2.2. Chunks y solapamiento

Para los *chunks* no solo deberemos partir el texto, sino que deberemos reagruparlo, ya que RollCall lo separa de una forma arbitraria que nosotros desconecemos. Primero lo reagruparemos para luego cortar por *chunks* de 128. Además, dentro del mismo proceso incluiremos también el solapamiento de 0.5. La función con la que se hace el *rechunk* con solapamiento se puede observar en la figura 5.4.

Como se puede observar, se calcula un *step*, que es la diferencia entre el *chunk size* y el solapamiento. Esto se utiliza para obtener el estado final de los fragmentos directamente, en vez de primero partirlos y luego solaparlos, que sería mucho más costoso computacionalmente.

Una vez finalizado este proceso, tenemos los fragmentos listos para ser analizados por los tres modelos que seleccionamos anteriormente.

```
1 def chunk_text_by_words(text: str, chunk_size: int = 128, overlap_ratio:
2     float = 0.5):
3     words = text.split()
4     if not words:
5         return []
6     overlap = int(chunk_size * overlap_ratio)
7     step = chunk_size - overlap
8     chunks = []
9     for start in range(0, len(words), step):
10         chunk = words[start:start + chunk_size]
11         if not chunk:
12             break
13         chunks.append(" ".join(chunk))
14         if start + chunk_size >= len(words):
15             break
16     return chunks
```

Figura 5.4: Código de segmentación del texto en *chunks*

5.3 Configuración de modelos

El siguiente paso es configurar los modelos para que obtengan resultados satisfactorios atendiendo a la discusión crítica realizada en el diseño de la solución. Todos los códigos están diseñados para procesar los 73 discursos de forma consecutiva, acortando tiempos, aunque todos van a tener procesos de análisis bastante grandes en términos temporales. Todos los códigos de configuración de los modelos incluyen variables o métodos en los que calcular la media de los sentimientos, emociones o discursos para luego poder asignársela al discurso. Cabe recordar que los discursos no se evalúan de forma global sino que se les asigna la media de las puntuaciones de sus fragmentos.

5.3.1. Bart Large MNLI

Para nuestro modelo de temáticas, Bart Large MNLI, lo primero es definir las temáticas, ya que este modelo es un modelo de *zero shot classification*. Es decir, que las etiquetas son dadas por el usuario. Se muestra en la figura 5.5 cómo se realiza la asignación de etiquetas.

```
1 # Tematicas a clasificar
2 candidate_labels = [
3     "Economy", "Infrastructure", "Health", "Security",
4     "Education", "Immigration", "Foreign Policy"
5 ]
```

Figura 5.5: Código de asignación de etiquetas

Tras esto, para clasificar cada uno de los fragmentos simplemente llamamos a la función que se encarga de clasificar fragmentos, pasándole el fragmento, las etiquetas y el *classifier*, en este caso, Bart Large MNLI, tal como se muestra en la figura 5.6.

Se muestra también en la figura 5.7 cómo se configura el *classifier* para que el modelo seleccionado sea el que actúa y además lo haga a partir de *zero shot classification*. Es decir, que acepte las etiquetas como argumento de la función y las tenga en cuenta.

```

1 def clasificar_fragmento(text, classifier, labels):
2     result = classifier(text, labels, multi_label=True)
3     return {label: score for label, score in zip(result['labels'], result['
        scores'])}

```

Figura 5.6: Código de llamada al classifier

```

1 classifier = pipeline(
2     "zero-shot-classification",
3     model="facebook/bart-large-mnli"
4 )

```

Figura 5.7: Código de configuración del classifier

5.3.2. Distil RoBERTa Emotion

Para el modelo de emociones de Distil RoBERTa, la configuración no dista demasiado del modelo anterior. El único cambio significativo a destacar, es que ahora lo procesaremos en *batches* para reducir el coste y el *overhead*, ya que este modelo es el más costoso a nivel de recursos y de tiempo. Como las etiquetas ya vienen predefinidas en este modelo, no hace falta declararlas.

```

1 for start in range(0, len(texts), batch_size):
2     batch_texts = texts[start:start + batch_size]
3     # pipeline puede procesar listas directamente
4     batch_results = emotion_pipeline(batch_texts)
5
6     for i, result in enumerate(batch_results):
7         scores = {entry["label"]: entry["score"] for entry in result}
8
9         idx_global = start + i
10        fragmentos_data.append({
11            "fragmento_id": f"{discourse_id}_{idx_global}",
12            "discurso_id": discourse_id,
13            "text": batch_texts[i],
14            **scores
15        })

```

Figura 5.8: Código de configuración del modelo de emociones

Como se puede observar en la figura 5.8, el proceso de *pipeline* es bastante similar. En esta figura también se muestra el proceso de *append*, mediante el que else asignan los resultados del *pipeline* a los fragmentos que corresponden.

5.3.3. RoBERTa Sentiment

Por último, el modelo de sentimiento es el más sencillo y menos costoso a nivel computacional. El proceso es muy similar al de emociones, puesto que tienen un origen común. Lo único que tenemos que andar con cuidado son las etiquetas, ya que el modelo no devuelve negativo, neutral o positivo, sino *label_0*, *label_1* y *label_2*. El proceso de reetiquetado se muestra también en la figura 5.9 junto a la configuración.

```
1 for idx, txt in enumerate(texts):
2     result = sentiment_pipeline(txt)
3     if isinstance(result[0], list):
4         result = result[0]
5     # extraer labels y scores
6     scores = {entry["label"]: entry["score"] for entry in result}
7     # mapeo a nombres claros
8     neg = scores.get("LABEL_0", 0.0)
9     neu = scores.get("LABEL_1", 0.0)
10    pos = scores.get("LABEL_2", 0.0)
```

Figura 5.9: Código de configuración del modelo de sentimiento

5.3.4. Ejecución de los modelos

Tras esta última configuración, podemos procesar los 73 ficheros a través de 3 códigos por separado. Obtendremos 6 ficheros: 3 ficheros de fragmentos (uno de emociones, otro de sentimiento y otro de temáticas) y los respectivos 3 de discursos. Deberíamos tener 73 filas en los de discursos y 13425 filas en el de fragmentos. Como habíamos visto antes, estos ficheros incluyen también el id del discurso o del fragmento. Con un simple código que haga un *append* por el id, podemos unirlos en dos únicos ficheros CSV que contengan toda la información unificada. Uno de fragmentos y otro de discursos. Estos serán los ficheros que utilizaremos para poblar la base de datos en la siguiente sección.

5.4 Base de datos

5.4.1. Creación y definición de la base de datos

Lo primero de todo, crearemos una base de datos llamada *tfg.db* en el repositorio local, en el mismo que el resto del código que estamos utilizando. Como habíamos dicho antes, es una base de datos relativamente pequeña y nos podemos permitir gestionarla de forma más eficiente desde local. Para crearla y conectarlos posteriormente, simplemente utilizamos la librería *sqlite3* como se indica en la figura 5.10.

```
1 db_path = r"C:\Users\pgeesp\tfg\tfg.db"
2 conn = sqlite3.connect(db_path)
3 cursor = conn.cursor()
```

Figura 5.10: Código de conexión y creación de la base de datos

La arquitectura de la base de datos se ha definido utilizando *SQLAlchemy*[59], una biblioteca de mapeo objeto-relacional que permite definir tablas como clases de Python. Se han implementado dos entidades principales: *discourse* y *fragments*, con sus respectivos identificadores en la clave primaria y el resto de atributos que se indicaban en los diagramas del diseño de la solución. La aplicación de esto en código se puede visualizar en la figura 5.11.

```

1 Base = declarative_base()
2
3 class Discourse(Base):
4     __tablename__ = "discourses"
5     discurso_id = Column(String, primary_key=True)
6     date = Column(Date, nullable=False)
7     city = Column(String, nullable=False)
8     state = Column(String, nullable=False)
9     economy = Column(Float, nullable=False)
10    infrastructure = Column(Float, nullable=False)
11    health = Column(Float, nullable=False)
12    security = Column(Float, nullable=False)
13    education = Column(Float, nullable=False)
14    immigration = Column(Float, nullable=False)
15    [...]

```

Figura 5.11: Código de configuración de la base de datos

5.4.2. Carga de la base de datos

Una vez definido, dentro del mismo fichero pasamos a la carga de la base de datos. Para ello, primero convertiremos cada fila del CSV en una instancia del modelo correspondiente (*Fragments* o *Discourse*), extrayendo también la fecha, el estado y la ciudad. Luego lo insertaremos mediante el *session.merge*, que además evita duplicados, salvando cualquier error de este tipo. En la figura 5.12 se puede apreciar el uso del *session.merge()* para la carga de datos.

```

1 for _, row in frag_df.iterrows():
2     session.merge(Fragment(
3         fragmento_id = str(row["fragmento_id"]).strip(' '),
4         discurso_id = str(row["discurso_id"]).strip(' '),
5         text = row["text"],
6         economy = float(row["economy"]),
7         infrastructure = float(row["infrastructure"]),
8         health = float(row["health"]),
9         security = float(row["security"]),
10        education = float(row["education"]),
11        immigration = float(row["immigration"]),
12        [...]

```

Figura 5.12: Código de carga de la base de datos

Tras esto, ya tenemos nuestra base de datos poblada con todos los discursos, lista para ser analizada y lista para utilizarse para los *embeddings* que utilizaremos en el recuperación de fragmentos.

5.5 Generación de embeddings con Mini-LM

Cómo se indicó anteriormente, usaremos el modelo Mini LM L6 en su versión v2 para este proceso. Este proceso comienza con la extracción de los fragmentos desde la base de datos 'tfg.db' y su preprocesamiento básico, consistente en la eliminación de saltos de línea para asegurar una entrada limpia y uniforme al modelo de embeddings.

La generación de *embeddings* se realiza de forma vectorizada. Es decir, codificando todos los fragmentos con una sola llamada al modelo. Para ilustrar mejor este concepto, podemos observar la figura 5.13.


```
1 # limpiar saltos de línea
2 df["text_clean"] = df["text"].str.replace("\n", " ", regex=False)
3
4 # calcular embeddings
5 embedder = SentenceTransformer("all-MiniLM-L6-v2")
6 embs = embedder.encode(df["text_clean"].tolist(), show_progress_bar=
7     True)
8
9 # guardar embeddings
10 np.save(embs_path, embs)
```

Figura 5.13: Código de generación de *embeddings*

De esta forma, queda guardado en nuestra carpeta del proyecto un fichero 'embs.npy' que posteriormente utilizaremos para recuperar los fragmentos. Sin embargo, esto no es suficiente, necesitamos también el índice semántico FAISS para que la recuperación sea aún más precisa.

5.6 Construcción del índice semántico FAISS

Para la construcción de este índice mediante FAISS requerimos de un paso previo, la normalización a L2, que permite aproximar de una mejor forma y realizar búsquedas mucho más rápidas según Douze et al. [60]. Se indica en la figura 5.14 como hacerlo.

```
1 # construir y guardar índice FAISS
2 faiss.normalize_L2(embs)
3 d = embs.shape[1]
4 index = faiss.IndexFlatIP(d)
5 index.add(embs)
6 faiss.write_index(index, index_path)
```

Figura 5.14: Código de generación el índice FAISS

5.7 Generación de discursos con GPT-4

La parte de generación del discurso no tiene demasiada complicación después del diseño del *prompt*. Podemos dividirla en dos partes: la recuperación de fragmentos y el envío del *prompt*.

Para la recuperación de fragmentos se cargan los ficheros de *embeddings* y FAISS y luego se recuperan los fragmentos. Los fragmentos se recuperan teniendo en cuenta: por un lado, los mínimos de puntuación en los campos de temáticas, emociones y sentimiento y por otro lado la inclusión de una *semantic query*. Para los mínimos, se hace una máscara booleana para seleccionar solo los fragmentos que están por encima del mínimo exigido por el usuario. Para el índice semántico, si existe una *semantic query*, es decir, una especificación como podría ser "drugs", se buscan fragmentos por FAISS. Todo esto lo podemos observar en la figura 5.15. Una vez recuperado, tan solo nos queda crear el *prompt* y enviarlo a la API de GPT-4 indicando el modelo. Para hacer el *prompt* simplemente metemos en *system* la primera parte del *prompt*, cogemos los fragmentos y completamos el *prompt* a continuación con las especificaciones finales. Para más claridad se incluye el código siguiendo estos pasos en la figura 5.16.

```

1  def retrieve_fragments(topic, min_topic, emotion, min_emotion, query=None,
2      k=5):
3      mask = (df[topic] >= min_topic) & (df[emotion] >= min_emotion)
4      if not mask.any():
5          return pd.DataFrame()
6      if query:
7          q_emb = embedder.encode([query])
8          faiss.normalize_L2(q_emb)
9          D, I = index.search(q_emb, min(k*5, len(embs)))
10         selected, sims = [], []
11         for idx, sim in zip(I[0], D[0]):
12             if mask.values[idx]:
13                 selected.append(idx)
14                 sims.append(float(sim))

```

Figura 5.15: Código de recuperación de fragmentos

```

1  def build_trump_prompt(fragments, topic, emotion, sentiment_label):
2      system = (
3          "You are Donald Trump speaking at a rally during a presidential
4          campaign. Speak in English and use his style."
5          "You MUST base your speech primarily on the example fragments provided
6          below."
7      )
8      examples = []
9      for _, row in fragments.iterrows():
10         tag = (
11             f"[{topic}:{row[topic]:.2f} | {emotion}:{row[emotion]:.2f} | "
12             f"{sentiment_label}:{row[sentiment_label]:.2f}]"
13         )
14         examples.append(f"{tag}\n{row['text_clean']}\n")
15     prompt = (
16         system + "\n\n"
17         "Here are relevant example fragments that show how Trump speaks about
18         the selected topic and how he conveys the given emotion and
19         sentiment:\n\n" +
20         "\n".join(examples) +
21         f"\nNow, please generate a coherent speech in English about **{topic}**,"
22         f"conveying **{emotion}** and a **{sentiment_label}** sentiment,"
23         "with clear transitions and coherent structure"
24         f"Do not explicitly state the emotion or sentiment a lot they should be
25         expressed through the tone and style of the message"
26         f"Avoid repeating the topic excessively; it may be mentioned, but it
27         should remain mostly implicit in the text."
28     )
29     return prompt

```

Figura 5.16: Código de envío del prompt

Esto debería ser suficiente para recibir un discurso generado por la IA enriquecida por fragmentos, impreso por terminal como se muestra en la figura 5.17.

```

PS C:\Users\pgesp\tfg> & c:/Users/pgesp/tfg/.venv/Scripts/python.exe c:/Users/pgesp/tfg/rag/generardiscursos.py
Thank you, thank you very much, everyone. What a fantastic crowd. Look at this turnout! We've got the same number inside as we do outside. They're watching on a screen. Should've got here earlier, right? But hey, you're all fantastic and that's what matters. We're here to discuss something very special today.

You know, I went to school in Philadelphia, great city, great place. And let me tell you, I learned a lot, not just from books, but from life, from the streets, from doing business. Education is not just about what's inside a book, folks. It's about wisdom, it's about experience. And I think we can all agree on that, can't we?

```

Figura 5.17: Parte de un discurso impreso por terminal

CAPÍTULO 6

Análisis de resultados

Este apartado está dedicado a depurar los datos que obtuvimos de los modelos y de la encuesta de verificación y transformarlos en gráficos y tablas que puedan servirnos para extraer análisis y conclusiones valiosas. Primeramente se tratan los resultados de los modelos de sentimiento, emociones y temáticas y, en segundo lugar, los resultados de la encuesta de verificación.

6.1 Análisis de los discursos de Trump

En esta sección, analizaremos la estrategia discursiva de Donald Trump a partir de los datos obtenidos por los modelos. Plantearemos unas preguntas o hipótesis al inicio de cada análisis e intentaremos contestarlas gracias a la información arrojada por los datos.

6.1.1. Análisis de frecuencia de los atributos

La pregunta a responder en primer lugar es: ¿Cuáles son los atributos más frecuentes de cada uno de los análisis? Es decir, desvelar cuál es la temática más tratada y con qué sentimiento y emoción transmite habitualmente Donald Trump. ¿Es cierto que Trump habla especialmente de inmigración? ¿Es cierto que Trump tiene un tono negativo y confrontativo? Veámoslo primeramente mediante un simple análisis de valores medios.

Temáticas

La tabla 6.1 refleja los valores medios de las temáticas abordadas por Trump en sus discursos de la campaña electoral.

Temática	Security	Economy	Health	Infrastructure	Foreign Policy	Immigration	Education
Media	0.55446	0.44944	0.37016	0.30177	0.28807	0.19335	0.13437

Tabla 6.1: Valores medios por temática en los discursos

Como podemos observar, los temas más abordados son la seguridad y la economía, pero podemos complementar aún más este análisis con el porcentaje de dominancia de cada emoción. Es decir, cuántas veces, en porcentaje, la emoción es la que tiene mayor puntuación de todas en el fragmento. Se muestran los porcentajes en la tabla 6.2.

En dicha tabla podemos ver con gran claridad, que *security* no solo es la temática con mayor puntuación media, sino que es la temática más predominante dentro de los

Temática	Security	Economy	Health	Immigration	Foreign Policy	Infrastructure	Education
Porcentaje (%)	48.36	22.25	14.67	5.45	5.14	3.02	1.12

Tabla 6.2: Temática predominante por fragmento (%)

discursos de Donald Trump. Seguido por la economía, la salud y con puntuaciones algo residuales para el resto.

Este análisis preliminar muestra que la estrategia no es exactamente la que planteábamos en la hipótesis. La inmigración deja de ser un foco tan grande, es la segunda temática menos tratada. El foco cambia hacia la seguridad, debido al panorama internacional, al escudo social y a la integración de diferentes poblaciones. Pero definitivamente ya no siempre se asocia la seguridad única y exclusivamente a que los inmigrantes son el problema, existen otros focos de inseguridad.

Por otro lado, detectamos un foco clásico de Trump en la economía. Presume de sus cifras de creación de empleo durante su legislatura y critica fuertemente una ralentización económica durante el periodo de Joe Biden. También existe cierta mención a la sanidad, sobre todo, centrado en la lucha contra las drogas y en la seguridad social o 'Medicare'.

En conclusión, la estrategia de Donald Trump remarca al electorado qué no están a salvo bajo el mandato demócrata y qué, si quieren un futuro seguro y próspero a nivel económico y de sanidad, deben votarle a él.

Emociones

Analicemos ahora la estrategia discursiva respecto de las emociones expresadas dentro de cada discurso. La tabla 6.3 muestra la puntuación media global de todas las emociones en los discursos electorales de Trump.

Emoción	Neutral	Disgust	Anger	Surprise	Fear	Joy	Sadness
Media	0.32484	0.26077	0.16099	0.10207	0.06355	0.05096	0.03682

Tabla 6.3: Valores medios por emoción en el conjunto de datos

Este análisis preliminar nos permite detectar que las emociones que más transmite Donald Trump son la neutral, el asco y el enfado. Este análisis lo podemos complementar con el porcentaje de dominancia de cada emoción de nuevo. Podemos observar este análisis en la tabla 6.4.

Emoción	Neutral	Disgust	Anger	Surprise	Fear	Joy	Sadness
Porcentaje (%)	38.35	28.74	12.57	8.89	4.69	4.24	2.50

Tabla 6.4: Emoción predominante por fragmento (%)

Como decíamos anteriormente en el diseño de la solución, la emoción neutral no tiene una definición clara, simplemente agrupa aquello que es informativo o no se detecta como ninguna de las 6 emociones. A efectos de este estudio, no lo analizaremos. Lo que sí vemos es que existe una clara predominancia del *disgust* en la mayoría de fragmentos analizados durante la campaña de Donald Trump. Más de un cuarto del tiempo que habló Donald Trump en campaña lo hizo expresando asco predominantemente (28,75%).

Para Ekman [34], es una emoción de repulsión hacia algo desagradable que se manifiesta mediante expresiones de rechazo. Si observamos los fragmentos con mayor pun-

tuación de *disgust*, el uso que hace Trump de esta emoción es similar al del enfado, pero en vez de presentar a la administración o a los inmigrantes como generadores de injusticia, simplemente les rechaza de plano. Simplemente no son deseables en ninguna de sus formas. En este análisis también podemos ver que existen menciones a los medios de comunicación, en una batalla constante por controlar las fuentes de información. Trump desacredita constantemente a los medios que popularmente se conocen como "demócratas".

La segunda emoción más predominante y con mayor media es el enfado. De acuerdo con Ekman, el enfado se materializa en un lenguaje fuerte y se manifiesta ante situaciones injustas. Realizando un análisis de los fragmentos con mayor puntuación de enfado, estas injusticias son principalmente en el partido contrario, el demócrata. Tanto en Joe Biden, al principio, como en Kamala Harris después. También existen enfados con los inmigrantes y su supuesto comportamiento criminal, pero siempre se acaba materializando la culpa en la administración Biden-Harris que "los dejaron entrar". Así pues, Trump instrumentaliza la emoción de enfado para atacar a su oponente y generar un impacto de polarización en su audiencia con bastante asiduidad.

Por otro lado, podemos denotar una falta absoluta de miedo y tristeza dentro de sus discursos. Este miedo es una estrategia muy utilizada en política para influenciar el voto, el miedo al "malvado oponente", pero Trump prefiere un estilo más directo. Podemos descartar la hipótesis de que Trump mete miedo a sus votantes para capitalizar su voto.

Como conclusión, los discursos de Trump son triunfalistas y seguros y tratan de motivar para votar a la gente mediante la confrontación y desacreditación, en vez de mediante el miedo. Generar polarización y motivos para enfadarse con el rival y votar contra él, pero no por miedo a lo que puedan hacer, si no por confrontación ideológica. En especial, el foco está puesto en el asco, el rechazo frontal sin demasiado razonamiento. Simplemente la asociación de lo demócrata a algo malo y evitable que nunca puede ser deseable.

Sentimientos

Complementemos el análisis de emociones junto al análisis de sentimiento que se muestra en la tabla 6.5.

Sentimiento	Negativo	Neutral	Positivo
Media	0.45506	0.28593	0.25901

Tabla 6.5: Valores medios por sentimiento en el conjunto de datos

Como podemos observar, el sentimiento se inclina de forma habitual hacia lo negativo. Es decir, que las opiniones frecuentemente son expresadas de forma no constructiva, sino crítica y mostrando descontento. Esto no hace más que confirmar lo que decíamos en el apartado de emociones, donde las emociones que más utilizaba Trump eran mayormente confrontativas y poco conciliadoras.

Es importante notar que la neutralidad, a diferencia del análisis de emociones, aquí sí tiene un significado más definido. Pese a que el tono sea mayoritariamente confrontativo, existe mucha parte del discurso que Trump también está calmado y simplemente informa (28,59 %) o incluso contento, triunfalista y positivo (25,90 %). Es decir, Trump no utiliza una estrategia únicamente negativa, sino que sabe combinar este sentimiento con algunas partes donde transmite información y algunas partes donde anima al público y sale reforzado.

Analizando los fragmentos con mayor puntuación, el sentimiento negativo se traduce en ataques directos a los mismos grupos de los que hablábamos anteriormente (demócratas, inmigrantes y medios de comunicación) y los positivos mayormente se refieren a su propio programa y propuestas, a los primeros momentos donde Trump da las gracias por las ovaciones y a los momentos triunfalistas del *"Make America Great Again"* y todas sus variaciones.

6.1.2. Análisis de correlación entre temáticas y entre emociones

A continuación, analizaremos qué temáticas y qué emociones suelen presentarse de forma conjunta en un fragmento o si, por el contrario, no existe ninguna correlación entre ellas.

Emociones




Figura 6.1: Heatmap de Correlación entre las emociones

Analicemos ahora la primera correlación en la figura 6.1. Cómo podemos observar, la gran mayoría de emociones no se presentan de forma habitual junto a otras. Lo que sí podemos observar es que existe una amplia variedad de correlaciones negativas. Es decir, de emociones que nunca o rara vez se muestran junto a otras.

La correlación más grande fuera de neutral, es entre *disgust* y *joy* (-0,29). Existe una correlación negativa relativamente influyente. En pocas ocasiones *disgust* y *joy* predominan conjuntamente en un fragmento. Lo mismo ocurre con *disgust* y *surprise*. Por el contrario, la única correlación positiva (muy pequeña, 0,03) es de *disgust* y *anger*, lo que cuadra con

la idea que establecíamos en el anterior apartado. Son dos emociones compatibles dentro del discurso de Trump, aunque no se usen siempre conjuntamente.

También existe una polarización grande de las emociones de *surprise* y *joy* frente a *anger*. Además de la comentada con *disgust*, *surprise* y *anger* rara vez se dan de forma conjunta (-0,23) y tienden a disminuir cuando la otra está presente. Lo mismo pasa con *joy* y *anger* (-0,24).

La conclusión a extraer de este análisis es clara. Las emociones percibidas como más positivas (*joy*, *surprise*) y como más negativas (*anger*, *disgust*) según Ekman son las más dominantes y polarizantes. En otras palabras, tienden a darse más de forma aislada que junto a otras emociones. En general, los fragmentos tienden a ser predominantes de una emoción en vez de compartir protagonismo con otras.

Temáticas

Analicemos ahora, a través de la figura 6.2, si existen algunas temáticas que se presentan junto a otras.




Figura 6.2: Heatmap de correlación entre las temáticas

En este caso, todas las correlaciones sí son positivas. Esto se debe principalmente a que las puntuaciones de temáticas se calculan de forma individual y no en softmax igual a 1. Igualmente, existen claros picos que vale la pena comentar.

La correlación más alta está entre *health* e *infraestructure*. Revisando los fragmentos con alta predominancia de estas temáticas (más de 0,8 en ambas), estas se suelen correlacionar mediante la construcción de hospitales, la construcción de un sistema de salud de calidad

o diciendo que la administración ha malgastado dinero y debería haberlo invertido en sanidad y en infraestructura.

Lo mismo ocurre con *infrastructure* y temas como *security* o *foreign policy*. Trump lo relaciona explicando que va a conseguir la paz y estabilidad en Estados Unidos y que, gracias a ello, podrá construir una "América más próspera". Una relación similar a la que realiza con *economy*, dejar de malgastar y generar una infraestructura que dinamice la economía.

La última de las grandes correlaciones que cabe destacar es la de educación y sanidad. De forma muy parecida a otros países, parecen ser dos aspectos que siempre se tratan juntos por Trump, afirmando que sin ellos no existe el futuro.

Por último, llama la atención la baja correlación de inmigración con el resto de temas. Como veníamos avisando anteriormente, inmigración tiene una clara correlación con seguridad (0.42), ya que Trump echa la culpa de la falta de seguridad en EE.UU. a los inmigrantes. Sin embargo, parece ser que la inmigración suele ser un tema que se trata de forma especialmente aislada. Es decir, que Trump, cuando habla de inmigración, no suele mezclarlo con otros temas porque seguramente quiere que el mensaje claro.

Como conclusión a este apartado, Trump no suele mezclar las emociones, suele variar entre ellas, pero no suelen haber varias predominantes en un mismo fragmento. Por otro lado, sí que existen temas que suelen ir de la mano, como *health* e *infrastructure* o como *health* y *education*, mientras que *immigration* se suele presentar de forma aislada.

6.1.3. Análisis cruzado de correlación de los atributos

Correlación entre emociones y sentimiento

Este punto de análisis nos servirá para corroborar que las puntuaciones tienen sentido. El objetivo es corroborar qué emociones son más positivas y cuáles más negativas y si estas correlaciones se corresponden a las explicaciones que aportaba Ekman. La comprobación se puede observar en la figura 6.3.




Figura 6.3: Heatmap de correlación entre emociones y sentimientos

Atendiendo a lo que vemos en el *heatmap* de la figura 6.3, las emociones, a priori, se correlacionan con el sentimiento (positivo o negativo) que deberían. El análisis de emociones y de sentimiento aparentemente tiene sentido. Según este análisis, podemos clasificar como emociones negativas a: *disgust* (0,58), *anger* (0,35) y en menor parte *fear* (0,15).

Por otro lado, son positivas: *joy* (0,59) y *surprise* (0,18). Según este análisis, *sadness* parece una emoción que no transmite ningún sentimiento en específico, solo la emoción de tristeza que indicaba Ekman.

Respecto del sentimiento neutral, recordemos que es aquel que expresa información y calma. Nos sirve para identificar las emociones más polarizantes. Es decir, las que menos información transmiten y simplemente se basan en afirmaciones más vacías. Este análisis también parece tener sentido, puesto que las más polarizantes son *joy* y *disgust*, que eran las que más puntuaban a la hora de ser positivas o negativas respectivamente.

Por último, observamos que la emoción neutral presenta en su mayoría sentimiento positivo o informativo y que claramente no es negativo. Sin embargo, seguimos sin saber qué representa esta categoría por el funcionamiento del propio modelo.

En resumen, tenemos 3 emociones que podemos calificar como negativas, 3 como positivas (si incluimos neutral) y *sadness* como neutra. Sin embargo, podemos enriquecer aún más este análisis. Las correlaciones, aparte de ayudarnos a comprobar que nuestro análisis tenga sentido, nos permiten enriquecer las descripciones de Ekman en este contexto, aportando gradualidad al análisis. Es decir, en qué grado son negativas o positivas las emociones. La más negativa es *disgust*, seguida con distancia de *anger* y con menos de la mitad del anterior, *fear*. Por el lado positivo, la que mayor grado tiene es *joy*, mientras que *surprise*, aunque clasificada como positiva, lo es mucho menos que *joy*.

A partir de ahora no realizaremos análisis de sentimientos y emociones por separado para no ser repetitivos, ya que ahora entendemos en qué grado cada emoción representa cada sentimiento.

En este apartado, podemos concluir que existe una clara diferenciación entre emociones positivas y negativas y que existe una gradualidad entre ellas; no todas son igual de positivas o negativas. Además, *joy* y *disgust* son emociones especialmente polarizantes.

Correlación entre emociones y temáticas

Analicemos ahora cuáles son las emociones que instrumentaliza Trump para hablar de cada una de las temáticas. ¿Habla de los inmigrantes con desprecio? ¿Habla de la educación con alegría? Podemos observar la respuesta a estas preguntas en la figura 6.4.

Mediante este análisis observamos que, excepto en algunos casos contados, la mayoría de las correlaciones son extremadamente débiles o simplemente inexistentes. Pese a esto, existen algunos datos relevantes que podemos analizar.

La economía e infraestructura no parecen expresarse mediante ninguna emoción en particular. De hecho, ambas tienen la correlación más grande con neutral, lo que nos hace sospechar que cuando Donald Trump habla de estas temáticas, lo hace de forma puramente informativa y no sentimental.

La inmigración, en contra de lo que podríamos pensar, no tiene una correlación demasiado grande con *anger* o *disgust*. Si bien es cierto que estas son las emociones con las que mayor correlación tiene la temática, la correlación no es lo suficientemente grande como para resultar significativa.




Figura 6.4: Heatmap de correlación entre emociones y temáticas

Las correlaciones más significativas con respecto al resto, se dan en seguridad y en educación. Cuando Trump habla de seguridad, parece instrumentalizar a menudo el sentimiento de *anger* (0,17), muy superior al resto de correlaciones. Analicemos las expresiones que utiliza Trump en los fragmentos con una presencia alta de estos atributos (*security* >0,8 y *anger* >0,5). Trump dice que "el país se va al infierno" por la falta de seguridad o habla de fraudes y engaños de la administración Biden-Harris. También utiliza algunas preguntas retóricas para elevar el tono, como por ejemplo un "¿que demonios está ocurriendo aquí?". En general, se puede afirmar que Trump incrementa la polarización y la percepción negativa a la seguridad para atribuirle este valor negativo al tema. Que la gente sienta verdadero enfado y negatividad hacia la situación actual de seguridad en EE.UU.

La correlación entre educación y *joy* (0,21) es la más grande de todo el estudio. Pese a ser moderada, en comparación con el resto, es una correlación realmente importante. Analizando los fragmentos con presencia de ambos atributos, Trump suele instrumentalizar la alegría para ensalzar la gran educación de Estados Unidos. Destacar el gran capital humano que tienen para construir un gran país. Este parece ser un motor claro para generar ilusión en su electorado, puesto no estaba constantemente transmitiendo negatividad como vimos anteriormente. Pese a que las negativas sean predominantes, Trump también sabe transmitir mensajes de alegría e ilusión y lo hace principalmente a través de la educación y en menor medida, a través de la salud (0,12).

En definitiva, existen pocas correlaciones importantes entre emociones y temáticas. Las que más podemos resaltar, son la de *anger* y *security* y la de *joy* y *education*.

6.1.4. Análisis por Estados

Para esta sección analizaremos si existen un cambio discursivo estratégico dependiendo del Estado en el que se encuentre Donald Trump. ¿Se centra Trump más en la economía en los estados pobres? ¿Se centra más en la inmigración en los estados fronterizos?

Número de discursos y limitaciones

Antes de hacer este análisis debemos ser conscientes de las limitaciones del alcance del análisis. Existen algunos estados en los que solo se ha realizado un discurso. Esto no necesariamente limita el análisis completamente, ya que estos son discursos de dos o tres horas, y esto es una muestra más que suficiente para el análisis PLN. Sin embargo, otras variables, como la cercanía a las elecciones o el contexto político de ese momento (variables que se estudiarán más tarde), pueden distorsionar algo el análisis. Por ejemplo, el único discurso en California fue el 12 de octubre de 2024. Esto no nos impide saber qué priorizó Trump en cuanto a sentimientos o temáticas en este estado, pero sí nos impide saber si quizás en un momento más lejano a las elecciones esta estrategia habría cambiado. Más tarde, realizaremos el análisis de si estas variables suponen una desviación muy grande y, por lo tanto, cuantificaremos mejor la limitación del análisis. En la figura 6.5 se muestran los discursos por estado. Se puede consultar en el anexo A.4 a que estado corresponden cada una de las iniciales.




Figura 6.5: Número de discursos por estado

Como podemos observar en la figura ??, los 7 estados donde Trump acumula más discursos son precisamente los *swing states*. Un *swing state* es un estado donde las votaciones están especialmente ajustadas. Cabe recordar que en la mayoría de Estados Unidos, aunque te vote un 50 % del electorado de un estado, si este es el candidato más votado, se lleva todos los representantes de ese estado. De aquí la importancia tan grande de los *swing states*, las elecciones se deciden prácticamente de forma exclusiva en estos estados. Los *swing state* varían entre elecciones y en estas eran Pensilvania (PA), Carolina del Norte (NC), Michigan (MI), Wisconsin (WI), Georgia (GA), Arizona (AZ) y Nevada (NV). En especial, Pensilvania (PA) y Carolina del Norte (NC) eran los más importantes al repartir una cantidad mayor de compromisarios y, por lo tanto, acercar más a los candidatos a la victoria. Estos dos últimos también son los dos más visitados por Trump.

Correlación de temáticas con Estados

Hecho este análisis podemos pasar a ver las diferencias entre estados, primero analizaremos la presencia de temáticas en cada estado mediante la figura 6.7




Figura 6.6: Tabla de correlación entre temáticas y estados

En líneas generales, podemos describir que la estrategia de Trump no cambia necesariamente demasiado dependiendo del estado en el que hable. Trump parece tener una estrategia consistente que repite en la gran mayoría de estados y que, dados los resultados, ha sido exitosa. Por otro lado, existen algunas desviaciones en algunos estados que puede resultar interesante explorar.

Temáticas como seguridad, educación o política exterior parecen no variar de forma significativa en ningún estado particular. La seguridad sigue siendo el tema dominante en absolutamente todos los estados que visita Donald Trump.

Si nos fijamos en economía y infraestructura, notaremos en parte la correlación que marcábamos anteriormente. Por ejemplo, en Florida (FL), considerado un estado rico en EE.UU., tiene unos niveles de economía (0,41) y de infraestructura (0,25) por debajo de la media (0,449 y 0,301 respectivamente). Lo mismo ocurre con California (CA), con un nivel idéntico de economía, también por debajo de la media. Podemos decir que, en los estados más ricos, Trump prioriza menos la infraestructura y la economía, lo cual parece coherente. Este electorado ya tiene trabajo y vive en ciudades muy modernas, tienen otras prioridades.

Respecto de la sanidad, vemos un claro pico en Nuevo México (NM). Nuevo México también tiene el mayor pico en términos de economía e infraestructura. Nuevo México es uno de los estados con mayor tasa de pobreza de EE.UU. y además uno de los más golpeados por el narcotráfico. Nuevo México en ocasiones sirve como puerta de entrada para el contrabando de droga que viene desde Centroamérica. Es por esto que ha sufrido de forma fuerte la crisis de fentanilo que azota el país estadounidense en estos últimos años. Esto parece explicar este índice tan alto de *health*. Trump habla recurrentemente de la crisis sanitaria que sufre Nuevo México durante su único discurso allí. Además la pobre situación económica de este estado en comparación al resto del país, explica porque Trump se centró especialmente en estos temas cuando habló en Nuevo México.

Por último, la inmigración tiene el pico más importante de la tabla en Colorado (CO). Casi duplicando la media de inmigración (0,19 contra 0,36 en CO). Esto puede parecer algo contraintuitivo, Colorado no es un estado fronterizo ni tampoco tiene tasas altas de inmigración. Para entender este pico, debemos entender las dinámicas de redistribución de inmigrantes de EE.UU. Al ser uno de los estados con menos inmigrantes, Colorado, en especial Denver, están siendo grandes receptores de inmigrantes en los últimos años. Inmigrantes de la frontera sur, más cercana a Colorado. Es por esto que existe algo de crispación al respecto entre electorado de Colorado, ya que no estaban acostumbrados a esta situación. Trump ha aprovechado para instrumentalizarlo y hablar casi el doble de inmigración en este Estado para, presuntamente, polarizar más al electorado y sacar tajada de ello.

Como conclusión, la estrategia discursiva de Donald Trump no varía demasiado de estado a estado. Existen algunas peculiaridades en algunos estados que Trump sabe explotar, pero en general, se sigue respetando la estrategia de temáticas que se había definido anteriormente en el análisis global.

Correlacion de emociones con Estados

Realicemos el mismo análisis pero en esta ocasión, por emocioness. En la figura 6.7 se muestran las correlaciones correspondientes.




Figura 6.7: Tabla de correlación entre emociones y estados

De nuevo, existe poca variación en la estrategia emocional de un estado a otro. Destacaremos algunos picos de forma breve que pueden resultar interesantes:

- Colorado (CO): Posee bajones de *joy* (0,023) y *surprise* (0,075) bastante por debajo de lo habitual y picos de *anger* (0,178) más altos de la media. Esto cuadra con la predominancia de la temática de inmigración que habíamos visto que tendía a instrumentalizarse mediante emociones negativas. También existe el mayor pico de *fear*. Probablemente en este estado se instrumentalice bastante más el miedo hacia el inmigrante desconocido al que no están tan acostumbrados.
- Nuevo México (NM): Posee el mayor pico de *anger* (0,189) coincidiendo con el mayor pico de *security*, una temática con clara utilización de *anger* como emoción para expresarla como habíamos visto en las correlaciones.

- Florida: Posee un pico relativamente alto de *fear* (0,114), pero esto no se correlaciona con los principales temas tratados con más frecuencia en Florida que en otros sitios (especial pico en economía). Es una combinación fuera de lo habitual. Explorando por los fragmentos con *fear* y *economy* alto, Trump instrumentaliza a los pobres e inmigrantes para meter miedo a las clases altas de perder su privilegio y sus trabajos.

6.1.5. Evolución temporal de los atributos

La próxima etapa del análisis es analizar como evoluciona la estrategia de Donald Trump a lo largo del tiempo. Por ejemplo, podríamos preguntarnos si incrementa la alegría cuando se acercan las elecciones o si las emociones clasificadas como polarizantes anteriormente, son las más utilizadas en el final de campaña. Para analizar esto, primero realizaremos un análisis mediante gráficos temporales, para luego utilizar estadísticos que complementen este análisis.

Gráficos temporales




Figura 6.8: Gráfico de evolución mensual de las emocionales

La figura 6.8 nos permite ver la evolución de la que hablábamos anteriormente. Este gráfico nos hace darnos cuenta de dos cosas. En primer lugar, existe un pico, hacia abajo o hacia arriba de las medias de los sentimientos en Julio. Esto es debido al intento de homicidio que sufrió Donald Trump en su discurso del 13 de Julio de 2025 en Butler, Pensilvania. Este discurso y el posterior alteran la media y para los estadísticos calculados más tarde serán descartados para poder analizar únicamente la relevancia temporal. Este fenómeno será posteriormente analizado, pero en la evolución temporal será tratado como un punto anómalo y por eso se descarta.

Por otro lado, el gráfico parece mostrar un aumento de las emociones positivas (*surprise* y *joy*) que acaban más altas de lo que empezaron en Junio. Por el contrario, parece haber un descenso de las negativas, acabando *disgust* por debajo de lo que empezó y de igual forma lo hace *fear*. Esto se confirma observando la progresión de sentimiento que nos muestra la figura 6.9.

En la figura 6.9 volvemos a ver el pico debido al intento de homicidio y se clarifica aún más la tendencia comentada. Donald Trump tiene a incrementar su positivismo y disminuir su negativismo a medida que se acercan las elecciones. Eso sí, las emociones negativas siguen predominando, pero menos de lo que lo hacían al principio de campaña.




Figura 6.9: Gráfico de evolución mensual del sentimiento

Por último, podemos visualizar el mismo análisis gráfico realizado sobre las temáticas en la figura 6.10. Se muestran las 7 temáticas y sus respectivas evoluciones hasta Noviembre, mes de las elecciones.




Figura 6.10: Gráfico de evolución mensual de las temáticas

De nuevo, vemos cambios razonablemente grandes. La tendencia a hablar sobre economía sube especialmente a medida que se acerca la campaña. Por su lado, parece caer la predominancia de los discursos de seguridad dentro de los discursos de Donald Trump. Aún así, este análisis gráfico deja dudas sobre el comportamiento de la mayoría de las temáticas. Por lo tanto, se justifica la necesidad de los estadísticos para analizar el comportamiento de estas temáticas.

Estadísticos temporales: Pendiente

En primer lugar, sacaremos las pendientes de cada uno de los atributos para detectar si es ascendente o descendente. Cabe recordar que tanto este estadístico como el siguiente no tendrán en cuenta los discursos del intento de homicidio (13 de julio), ni el de vuelta (20 de julio), que, como se verá a continuación, son grandes puntos anómalos. En la tabla 6.6 se muestra la emoción junto con la pendiente y tendencia. También se muestran las pendientes y tendencias del sentimiento en la tabla 6.7.

Emoción	Pendiente	Tendencia
joy	0.00145	↑ creciente
anger	0.00102	↑ creciente
sadness	0.00142	↑ creciente
fear	-0.00466	↓ decreciente
disgust	-0.00621	↓ decreciente
surprise	0.00374	↑ creciente
neutral	0.00324	↑ creciente

Tabla 6.6: Tendencias lineales de emociones

Sentimiento	Pendiente	Tendencia
positive	0.01250	↑ creciente
neutral	-0.00121	↓ decreciente
negative	-0.01130	↓ decreciente

Tabla 6.7: Tendencias lineales de sentimientos

Con estas pendientes se confirman las hipótesis anteriormente establecidas, las emociones y el sentimiento positivo tienden a crecer con el paso del tiempo y con el acercamiento de la fecha de las elecciones. Analicemos ahora las temáticas cuya pendiente y tendencia se muestra en la tabla 6.8.

Temática	Pendiente	Tendencia
economy	0.01131	↑ creciente
infrastructure	0.00445	↑ creciente
health	0.00040	↑ creciente
security	-0.00493	↓ decreciente
education	0.00296	↑ creciente
immigration	-0.00544	↓ decreciente
foreign_policy	-0.00164	↓ decreciente

Tabla 6.8: Tendencias lineales de temáticas

En esta tabla, podemos ver más claro que la economía sí sube razonablemente y es la temática que más lo hace. También lo hacen la infraestructura y la educación. Por otro lado, también se confirma que baja la mención de la seguridad y de la inmigración, que tiene la mayor pendiente en valor absoluto (-0,00544). Trump prefiere priorizar los temas de los que suele hablar con más positividad y despriorizar aquellos más confrontativos cuando se acerca el final de campaña. Esto vuelve a encajar con sus dinámicas temporales emocionales que explorábamos anteriormente.

Estadísticos temporales: Correlación con la variable tiempo

El anterior análisis nos puede servir para confirmar las tendencias visuales que apreciábamos al principio, pero es difícil calcular la intensidad de la correlación. Así que podemos calcular la correlación con la variable tiempo directamente. En primer lugar, se calcula la correlación con la variable tiempo de las emociones y el sentimiento en las tablas 6.9 y 6.10 respectivamente.

Emoción	Correlación
joy	0.468
anger	0.357
sadness	0.768
fear	-0.752
disgust	-0.784
surprise	0.487
neutral	0.326

Tabla 6.9: Correlación de emociones con el paso del tiempo

Sentimiento	Correlación
positive	0.773
neutral	-0.367
negative	-0.792

Tabla 6.10: Correlación de sentimientos con el paso del tiempo

Este análisis es del todo conclusivo. Existen correlaciones muy fuertes de varias emociones y especialmente del sentimiento positivo y negativo. *Disgust* y *fear* son claramente la que más disminuyen a medida que avanza el tiempo. Gracias a este análisis podemos ver un gran aumento de *sadness*, una emoción que es neutral. Por último, observamos que todas las emociones positivas aumentan en su totalidad a medida que pasa el tiempo. Analicemos ahora las temáticas, cuya correlación se muestra en la tabla 6.11.

Temática	Correlación
economy	0.827
infrastructure	0.745
health	0.049
security	-0.702
education	0.589
immigration	-0.585
foreign_policy	-0.232

Tabla 6.11: Correlación de temáticas con el paso del tiempo

En esta tabla, se confirman nuestros análisis del apartado anterior, pero ahora podemos ver realmente la magnitud. A medida que se acercan las elecciones, hay un enfoque muy fuerte (0,827) en economía y infraestructura (0,745), a cambio de despriorizar seguridad (-0,702) y inmigración (-0,585). Educación también sube razonablemente (0,589).

Como conclusión, Donald Trump tiende a suavizar su tono confrontativo y ser más positivo y triunfalista durante los finales de campaña. Esto lo acompaña aumentando el protagonismo de temas que facilitan esta expresión de sentimientos positivos (como lo son economía, infraestructura y educación) y despriorizando los temas con los que habla con mayor negatividad (inmigración y seguridad).

6.1.6. Análisis del impacto del intento de homicidio

El intento de homicidio de Donald Trump fue un hecho que dio la vuelta al mundo y que impactó enormemente en el día a día y en la intención de votos de millones de estadounidenses. El discurso, está incluido en la muestra, sin embargo, es un discurso extremadamente corto por la interrupción del ataque y con escaso valor analítico, pues no sabía que podía ser atacado. El principal interés se haya en como actúo tras el ataque. En esta subsección existen dos preguntas principales a contestar: ¿Cómo fue la vuelta de Donald Trump tras el intento de homicidio? y ¿Afectó esto a su estrategia electoral?

Discurso de vuelta

Este fue el famoso discurso donde Trump se refugió detrás de cristales antibalas para realizar su mitin. Resulta de gran interés saber como Trump reaccionó ante un evento tan traumático y que impacto tuvo esto en su siguiente discurso para recuperarse.

La tabla 6.12 compara el discurso de vuelta de Trump (20 de julio, Grand Rapids, Michigan), con el discurso inmediatamente posterior (24 de julio, Charlotte, Carolina del Norte) y con la media total (sin incluir el discurso de vuelta, ni el del ataque).

	2024-07-20	2024-07-24	Media total
Sentimientos			
positive	0.7158	0.2639	0.2604
neutral_sent	0.1973	0.2704	0.2863
negative	0.0869	0.4657	0.4532
Emociones			
joy	0.1984	0.0430	0.0516
anger	0.0422	0.1477	0.1604
sadness	0.0215	0.0230	0.0374
fear	0.0993	0.0703	0.0636
disgust	0.0377	0.3026	0.2580
surprise	0.1727	0.1095	0.1017
neutral_emo	0.4282	0.3038	0.3273
Temáticas			
economy	0.3689	0.3955	0.4513
infraestructure	0.2587	0.2926	0.3025
health	0.4813	0.4144	0.3680
security	0.4223	0.5720	0.5561
education	0.1281	0.1286	0.1345

Tabla 6.12: Comparación entre los discursos del 20 y 24 de julio y la media total sin incluir el discurso de vuelta y el del ataque

Lo primero que llama la atención es el increíble aumento de la positividad como sentimiento y la consecuente bajada de la negatividad. La diferencia con la media de positividad es de (0,4554), un incremento increíblemente significativo. De normal Trump puntuaba con un 26,04 % de positivísimo en su discurso, pero en esta ocasión, el 71,58 % del discurso fue positivo. Por lo contrario, tanto solo un 8,69 % lo fue frente al habitual 45,32 %, una caída de 0,3663.

Desgranando un poco más este análisis, si nos fijamos en las emociones, el positivismo fue debido al gran incremento respecto de la media en *joy* y *surprise*, que suben un 284,49 % y un 69,81 % respectivamente. Por otro lado, las emociones negativas caen ostensiblemente: *anger* con 0,0422 frente a una media de 0,1604, casi 4 veces menos, y especialmente *disgust* con 0,0377 frente a un 0,2580 de normal, casi 9 veces menos.

Respecto de las temáticas, no existen variaciones significativas dentro del discurso, todas se encuentran en un rango normal de desviación. La única que puede llamar la atención es el foco especial en *health*, puesto que Donald Trump recordaba constantemente que estaba sano y que debían mantenerse a salvo. Pero realmente no era un discurso propositivo sobre sanidad y no deberíamos tenerlo tanto en cuenta.

Analizando la evolución hacia el posterior discurso, vemos como Trump volvió a una normalidad bastante grande 4 días después. Todo parece indicar que este aumento de positivismo estuvo realmente planificado y que no fue una tendencia a lo largo de la campaña. Simplemente fue una forma de volver más fuerte para luego reanudar la estrategia que ya tenían definida.

En conclusión, tras el intento de homicidio, Trump optó por una narrativa positiva, de alegría y satisfacción, probablemente para conseguir el favor de la opinión pública y poder, en cierta parte, ser un 'martir'. Sin embargo, esto tan solo afectó al discurso inmediatamente posterior, que fue un claro punto anómalo, pero no al siguiente y seguramente tampoco al resto. Pero para afirmar esto con seguridad debemos de analizar el impacto que tuvo a lo largo del tiempo este suceso.

Análisis temporal del impacto del intento de homicidio

Tras la vuelta, hemos visto que Trump volvió directamente a la normalidad, pero con un solo discurso no podemos afirmar que esto fue así. Necesitaremos ver si los discursos a partir del intento de homicidio cambiaron su estrategia discursiva.

Sin embargo, no podemos comparar simplemente antes y después del tiroteo, pues estaríamos dejando interferir a la variable de la cercanía de las elecciones demasiado y no sabríamos si el aumento o descenso es debido al intento de homicidio o a la variable temporal. Para tratar de reducir esto, compararemos los datos de la totalidad de la campaña (sin el discurso de vuelta, ni el del ataque) con los datos desde el 24 de Julio al día de las elecciones (tramo post-intento). De esta forma, si las dinámicas son similares, podremos concluir que la tendencia de ese lapso de tiempo no es diferente de la que se siguió a lo largo de toda la campaña, disminuyendo el efecto de la variable tiempo, aunque no reduciéndolo del todo.

Como último apunte, podrían surgir dudas al respecto de la validez de las conclusiones anteriores de la variable tiempo. Sin embargo, en los gráficos ya se pueden apreciar los aumentos y descensos de los que hablábamos antes del intento de homicidio y las tendencias ya eran positivas. De igual forma, analizaremos las correlaciones y las medias antes y después para ver si han cambiado en ese periodo y poder tener la mayor seguridad posible.

Aclarado esto, veamos la comparación de la totalidad contra el período post-intento. Analizaremos primero las medias, es decir, si ha cambiado la forma de comunicar el mensaje. Podemos visualizar las medias en la tabla 6.13.

Como vemos, no existe ninguna diferencia significativa comparando el post-intento con la media total. Prácticamente todas las cifras son iguales y las que distan, están todas dentro de la normalidad. Esto, sin embargo, podría ser fruto de que hay muchos menos discursos antes del intento, que después y, por lo tanto, no hay capacidad de que influ-

	Media total	Post-Intento	Pre-Intento
Sentimientos			
positive	0.246	0.255	0.206
neutral_sent	0.287	0.285	0.298
negative	0.467	0.460	0.497
Emociones			
joy	0.049	0.050	0.042
anger	0.161	0.163	0.155
sadness	0.037	0.038	0.034
fear	0.068	0.062	0.069
disgust	0.267	0.259	0.293
surprise	0.100	0.100	0.088
neutral_emo	0.318	0.326	0.318
Temáticas			
economy	0.442	0.458	0.417
infraestructure	0.297	0.302	0.294
health	0.368	0.368	0.352
security	0.558	0.555	0.560
education	0.131	0.134	0.121
immigration	0.195	0.192	0.206
foreign_policy	0.289	0.291	0.294

Tabla 6.13: Medias de variables: total, pre y post intento

yan en la media. Pero la realidad cuando lo comparamos con las medias pre-intento, es que tampoco distan significativamente. Existen algunas variaciones en economía o *disgust* por ejemplo, pero poco significativas. Se podrían explicar por la variable temporal anteriormente analizada (la economía subía con el tiempo y *disgust* bajaba).

Para estar totalmente seguros, analicemos también si varía la correlación con la variable tiempo. La calcularemos en su totalidad y tan solo en el periodo post-intento. Cabe destacar que la correlación pre-intento no se puede calcular debido al reducido número de discursos. Se muestran las correlaciones en la tabla 6.14.

De forma sorprendente, este análisis, mucho más detallado, nos ofrece conclusiones diferentes a la media. La media sí estaba camuflando algunos cambios de tendencia que sí eran relevantes para el análisis. La mayoría de atributos siguen con la misma tendencia pero hay algunos casos específicos que vale la pena comentar.

En el caso del sentimiento, sigue todo extremadamente parecido para positivo y negativo, por lo tanto, lo que ha cambiado es la composición de esa positividad y negatividad, pero no el conjunto de ella. Para analizar la composición debemos fijarnos especialmente en *anger* y *surprise* (donde se producen las mayores variaciones).

En general, todos los atributos emocionales sufren cambios grandes en su correlación con la variable tiempo, pero todas mantienen su misma tendencia excepto *anger* que vira radicalmente. La correlación de *anger* post-intento, es marcadamente negativa, por lo que podemos inferir que el intento de homicidio sí influyó en un cambio de tendencia menos agresivo y confrontativo por parte de Donald Trump.

El otro cambio significativo es el de *disgust*, que pasa de tener una correlación inversa fuerte, a mantenerse relativamente estable tras el intento. Aquí es donde vemos el

	Correlación total	Post-intento
Sentimientos		
positive	0.773	0.818
neutral_sent	-0.367	0.365
negative	-0.792	-0.870
Emociones		
joy	0.467	0.240
anger	0.354	-0.811
sadness	0.767	0.474
fear	-0.751	-0.909
disgust	-0.784	-0.171
surprise	0.487	0.983
neutral_emo	0.326	-0.520
Temáticas		
economy	0.827	0.805
infraestructure	0.744	0.701
health	0.050	-0.156
security	-0.703	-0.865
education	0.589	0.350
immigration	-0.586	-0.597
foreign_policy	-0.232	-0.773

Tabla 6.14: Correlación de variables con el tiempo: total vs. post intento

balance entre emociones negativas que hace que el sentimiento negativo siga siendo el mismo. Simplemente las emociones negativas post-intento tendieron mucho más hacia el asco que hacia el enfado, mientras que pre-intento, eran claramente más tendentes con el tiempo al enfado que al asco. La dinámica cambió radicalmente a partir del 13 de julio. Por último, no existen variaciones significativas en las temáticas más allá de la educación, que se puede explicar con el primer análisis temporal que hacíamos.

Por lo tanto, podemos concluir que el intento de homicidio sí tuvo un impacto en la estrategia discursiva de Donald Trump. Los discursos siguieron siendo igual de positivos o negativos que siempre, pero cambiaron las emociones mediante las que transmitían ese sentimiento. El asco empezó a ser bastante más protagonista después del 13 de julio en detrimento del enfado, que comenzó a disminuir tras el tiroteo. Esto, al igual que en el análisis temporal, no significa que el enfado deje de ser protagonista, tan solo que, debido al intento, fue menos protagonista.

6.2 Análisis de la generación de discursos mediante IA

La segunda parte del análisis de resultados está orientada hacia la parte de generación de discursos. El objetivo es evaluar si los discursos que ha generado el modelo enriquecido con la recuperación de fragmentos son de calidad. En otras palabras, si se percibe la mejora en la generación de discursos frente a un modelo generativo estándar.

Como ya avisábamos anteriormente, en el campo del PLN no existen métricas de precisión para los modelos más allá de comparaciones con textos previamente clasificados por filólogos. Pero sí que podemos medir la percepción de las personas. El objetivo final

de este apartado es generar una base lo más realista posible sobre la que poder hacer un discurso. Por lo tanto, podemos evaluar el realismo de los *outputs* y compararlos con los *outputs* estándar. Si el realismo aumenta, estos serán una mejor base para estos discursos. Para ello se diseñó la encuesta que se detallaba en el diseño de la solución y que se puede consultar en el anexo. Cabe recordar que el objetivo de la encuesta es encontrar si ha sido útil el proceso de recuperación de fragmentos mediante *embeddings* y FAISS. Durante todo el análisis nos referiremos a la generación realizada a través del trabajo como "IA con fragmentos" y a la estándar como "IA sin fragmentos".

6.2.1. Resultados generales de acierto

A continuación, veremos los resultados de cada una de las preguntas individuales. En la tabla 6.15 se muestra, el número de discurso, el tipo de generación del discurso (si es real, Trump; si no es real, cómo se generó) y las respuestas de los encuestados junto al porcentaje de acierto.

Discurso	Generación	Responde Trump	Responde IA	Aciertos (%)
1	IA sin fragmentos	45	63	63 / 108 (58.33 %)
2	Trump	70	38	70 / 108 (64.81 %)
3	Trump	73	34	73 / 108 (67.59 %)
4	IA con fragmentos	53	55	55 / 108 (50.93 %)
5	IA sin fragmentos	16	91	91 / 108 (84.26 %)
6	IA con fragmentos	71	36	36 / 108 (33.33 %)
7	Trump	65	43	65 / 108 (60.19 %)
Media	–	–	–	59.92 %

Tabla 6.15: Respuestas por discurso individual: número de clasificaciones como Trump o IA, y aciertos.

Fijándonos discurso a discurso, podemos ver como los discursos de IA con fragmentos parecen reducir el nivel de acierto. En especial el sexto, que consigue engañar a 2 de cada 3 personas. Si resumimos la tabla y agrupamos las respuestas por la tipología de generación, obtendremos la figura 6.11.




Figura 6.11: Clasificación promedio según el tipo real del discurso.

Con esta figura podemos obtener las primeras conclusiones. La IA con fragmentos es identificada como Trump un 29,17 % más que la IA sin fragmentos, que comparte el mismo prompt y modelo. Sin embargo, siguen sin conseguir emular perfectamente a Trump, puesto que los fragmentos realmente de Trump, fueron identificados como reales un 6,71 % más que los fragmentos de IA con fragmentos.

Podemos afirmar que las generaciones realizadas con la IA con fragmentos consiguen emular de una mejor forma los discursos de Trump que la IA sin fragmentos. No obstante, el modelo sigue teniendo margen de mejora, puesto que aún no consiguen suplantar a Trump totalmente.

No es la única conclusión que podemos sacar. Si nos fijamos, las personas tienden a identificar como IA a Trump hasta un 35,49 % de la veces. De hecho, tan solo el 59,92 % de las veces el encuestado identificó correctamente si se trataba de IA o de un discurso real de Trump. Estos datos nos invitan a pensar, que pese a introducir fragmentos más fáciles de identificar (como demuestran ser los generados por IA sin fragmentos), las personas son incapaces de diferenciar personas de IA en textos escritos. De hecho, si excluimos a la IA sin fragmentos, tan solo un 46,13 % acertó en la pregunta.

La deducción a este respecto es sencilla, las personas, en general, son poco capaces de diferenciar a una IA de un humano cuando se trata de textos escritos, especialmente cuando están enriquecidas. En un test donde tan solo se incluirán fragmentos reales y de IA, la persona promedio se equivocaría más de lo que acertaría tratando de desenmascarar a la IA.

6.2.2. Cambios en la percepción de seguridad

Como comentábamos anteriormente, se ha introducido después de cada discurso una pregunta de nivel de confianza de la respuesta para realizar un análisis más fino. En casos donde los resultados de la IA con fragmentos sean similares a los de la IA sin fragmentos, si conseguimos hacer dudar un poco más al encuestado podría ser un buen síntoma. Por lo tanto, la hipótesis a corroborar aquí es que las personas dudan más con la IA con fragmentos que sin fragmentos.

Discurso	Tipo de IA	Certeza si acierta	Certeza si falla
1	IA sin fragmentos	3.15 / 5	3.07 / 5
4	IA con fragmentos	3.13 / 5	2.96 / 5
5	IA sin fragmentos	3.26 / 5	2.71 / 5
6	IA con fragmentos	3.44 / 5	2.97 / 5
Media IA sin fragmentos		3.21 / 5	2.97 / 5
Media IA con fragmentos		3.26 / 5	2.97 / 5

Tabla 6.16: Media del nivel de certeza (1 a 5) entre los participantes que acertaron o fallaron en la identificación de discursos generados por IA.

Como vemos en la tabla 6.16, no existe diferencia significativa entre la seguridad con la que se responde a las preguntas de IA con fragmentos y sin fragmentos. No podemos extraer ninguna conclusión de este análisis. Por otro lado, como medida de verificación, el análisis parece tener sentido, pues las personas dudan más cuando fallan, lo que parece lógico, pero desgraciadamente no nos sirve para arrojar ninguna conclusión extra.

6.2.3. Resultados por poblaciones

En este apartado buscamos extraer algunas conclusiones que permitan completar el análisis general. Estudiaremos 5 tipos de agrupaciones: por edad, por familiaridad con los discursos de Trump, por ideología, por familiaridad con la IA y por percepción de escepticismo. Calcularemos medias por cada uno de los grupos y luego analizaremos la correlación con la variable, usando Spearman, especialmente indicado en escalas 1 a 5. Esta correlación nos servirá para afinar el análisis y comprobar las intuiciones que podamos establecer a partir de la media.

Limitaciones del análisis

Antes de empezar con el análisis es importante resaltar las limitaciones de este. El estudio empleó un método de muestreo no probabilístico, específicamente combinando técnicas de muestreo por bola de nieve y por conveniencia. Aunque estas metodologías son útiles para acceder rápidamente a determinadas poblaciones y facilitar la recolección de datos en condiciones limitadas, no garantizan la representatividad estadística de la muestra respecto a la población general.

El muestreo por bola de nieve (que se basa en redes sociales y contactos personales de los participantes iniciales para incorporar nuevos encuestados) y el muestreo por conveniencia (que selecciona sujetos en función de su disponibilidad y cercanía) pueden introducir sesgos significativos. En consecuencia, los hallazgos derivados deben interpretarse con cautela y considerarse preliminares, ya que reflejan, principalmente, las características de un grupo concreto, más que de la población en su conjunto.

Una manifestación directa de estas limitaciones se observa en la variable edad. Tal como se muestra en la figura 6.12, el 72 % de los encuestados se encuentra en el rango de 18 a 29 años, mientras que los demás grupos están notablemente infrarepresentados. Este desequilibrio dificulta extraer conclusiones sólidas basadas en diferencias generacionales y compromete la validez externa del análisis en función de la edad.




Figura 6.12: Distribución de participantes por rango de edad de un total de 108 encuestados

Por lo tanto, aunque los resultados obtenidos permiten detectar patrones y tendencias relevantes, es importante tener en cuenta el carácter exploratorio del estudio. Para futuras investigaciones sería recomendable utilizar técnicas de muestreo aleatorio o estratificado que aseguren una mayor representatividad y permitan generalizar los resultados con mayor rigor.

Medias por grupo de edad




Figura 6.13: Porcentaje de aciertos en la identificación de discursos generados por IA con y sin fragmentos, agrupado por edad.

Empezando ya con el análisis, la figura 6.13 parece aportar una clara tendencia, a mayor edad, peor identificación a la IA con fragmentos. Es decir, La IA del trabajo engaña mejor a personas más mayores. Respecto a la IA sin fragmentos también podemos apreciar esa correlación, no obstante, parece haber datos anómalos en la franja de 50-59 en la parte de IA sin fragmentos. Esto puede deberse a que una muestra de 12 personas tan solo en esta franja de edad puede ser del todo insuficiente y puede producir anomalías como las representadas en la figura.

Medias por nivel de familiaridad con los discursos de Trump

A continuación, mediremos los aciertos según la cantidad de veces que hayan escuchado a Donald Trump. Aparentemente, a más información tengan de cómo habla Trump, más deberían reconocer los discursos del líder republicano. La pregunta era de tipo escala Likert. Es decir, 1 representará poca familiaridad con los discursos de Trump y 5, mucha familiaridad. Podemos ver los resultados de estas poblaciones en la figura 6.14.

La gráfica de la figura 6.14 muestra aparentemente que los niveles extremos de conocimiento o desconocimiento de Trump son generalmente malos para la identificación. Esto podría ser debido a, por un lado, un exceso de confianza que hace que haya menos revisión y suspicacia porque creen que están en lo correcto, y por otro lado, una falta de información con la que asociar a Trump. Ambas parecen lastrar el acierto de las personas.

Al respecto de nuestra IA, resulta llamativo ver como las personas más familiares con los discursos de Donald Trump son las que han sido engañadas con mayor frecuencia por la IA enriquecida. No existe una correlación con el resto de números, pero el bajón en el 5 es realmente importante. Por lo tanto, podemos subrayar que, dentro del sector más exigente de la encuesta, la IA actúa especialmente bien.




Figura 6.14: Porcentaje de aciertos en la identificación de discursos generados por IA con y sin fragmentos, agrupado por nivel de información acerca de los discursos Trump (1–5).

Medias por nivel de simpatía (Ideología)

La siguiente población a analizar es una división mediante ideología. Esta pregunta también estuvo formulada en escala Likert del 1 al 7, representando 1 estar en total desacuerdo con Trump y 7, estar totalmente de acuerdo. En el gráfico tan solo se muestra hasta el 6, porque ninguno de los 108 encuestados se identificó totalmente con Trump. La teoría a corroborar aquí es comprobar si las personas con ideologías afines a Trump, son más capaces de identificar a la IA correctamente. Estableceremos nuestras conclusiones gracias a la figura 6.15.




Figura 6.15: Porcentaje de aciertos en la identificación de discursos generados por IA con y sin fragmentos, agrupado por nivel de simpatía (1–6).

No se puede extraer conclusiones claras de esta población. Al respecto de nuestra IA, parece ser que las personas autopercibidas como de poco afines a Trump (del 1 al 3), son más proclives a detectar a la IA con fragmentos.

Medias por familiaridad con la IA

Para continuar comprobaremos si la familiaridad con el uso de la IA tiene alguna correlación con el éxito en la identificación de un discurso generado por IA. Podemos apreciar en la figura 6.16 las medias.




Figura 6.16: Porcentaje de aciertos en la identificación de discursos generados por IA con y sin fragmentos, agrupado por familiaridad con IA.

En esta ocasión, tampoco parece haber ninguna correlación real entre el uso de la IA y el nivel de acierto. Si que es cierto, que aquellos que están muy familiarizados son los que mejor puntúan en ambas categorías. Sin embargo, los segundos mejores son los que nunca las usan, posiblemente porque sean personas que dudan más de estas tecnologías. No existen aparentemente tendencias específicas para nuestra IA al respecto de esta población.

Medias por escepticismo

Por último analicemos la autopercepción de escepticismo. La hipótesis a revisar de acuerdo con esto es que las personas que se consideran más escépticas son las que más detecten a la IA. No se muestra el 1 porque nadie se considero muy poco escéptico. Podemos echar un vistazo a los resultados mediante la figura 6.17.

Parece corroborarse la hipótesis planteada. Las personas que se identifican abiertamente como poco escépticas, son las que puntúan claramente por debajo del resto de personas. Además, parece que un exceso de percepción de escepticismo en la persona tiene el efecto contrario, los más escépticos son los que peor puntúan en ambas categorías. Al respecto de nuestra IA, parece engañar especialmente bien con personas poco escépticas (2) y muy escépticas (5), mientras que funciona por debajo de la media en personas moderadamente escépticas (3).




Figura 6.17: Porcentaje de aciertos en la identificación de discursos generados por IA con y sin fragmentos, agrupado por nivel de escepticismo (2-5).

6.2.4. Análisis de Correlación por Spearman

Analizaremos en tres bloques: aquellas donde existe una correlación segura, es decir que $p < 0.05$, aquellas que podrían tener correlación si se hiciera un mejor muestreo, a efectos de este trabajo $p < 0.2$, y aquellos que definitivamente no tienen correlación. Cabe recordar que ρ indica el sentido de la correlación. En la tabla 6.17 se muestra la p y la ρ de la correlación entre la fila y la columna.

Variable	IA con fragmentos	IA sin fragmentos
Edad	$p = 0,0429$, $\rho = -0,20$	$p = 0,6828$, $\rho = -0,04$
Familiaridad Trump	$p = 0,9229$, $\rho = 0,01$	$p = 0,3959$, $\rho = -0,08$
Ideología	$p = 0,1224$, $\rho = -0,15$	$p = 0,3322$, $\rho = 0,09$
Familiaridad IA	$p = 0,1683$, $\rho = 0,13$	$p = 0,9971$, $\rho = 0,00$
Escepticismo	$p = 0,3572$, $\rho = -0,09$	$p = 0,8664$, $\rho = -0,02$

Tabla 6.17: Correlaciones de Spearman: valores p y coeficientes ρ entre variables personales y acierto de la IA con y sin fragmentos. En negrita, las correlaciones estadísticamente significativas ($p < 0,05$).

Según el análisis de la tabla 6.17 solo existen una correlación estadísticamente significativa. Podemos concluir, con bastante seguridad, que nuestra IA, a mayor edad, mayor capacidad de engaño tiene. ρ es negativa puesto que el acierto disminuye a mayor es la edad, correlación negativa. Recordemos que existe una limitación del análisis en cuestiones de edad, por lo tanto, no podemos afirmar con total rotundidad esta correlación, pero sí indicar que definitivamente existen indicios.

Para nuestra segunda parte, existen dos correlaciones más que vale la pena comentar: la ideología y la familiaridad con la IA, ambas respecto de la IA con fragmentos. Como decíamos, estas podrían llegar a ser significativas en muestreos mayores.

La primera hipótesis que queda en duda es que a mayor alejamiento ideológico a Trump, mayor es el acierto. Es decir, que las personas autopercebidas como poco afines a Trump son más proclives a detectar a la IA con fragmentos. ρ es negativa puesto que el nivel de cierto disminuye a mayor es el número de la ideología (un 7 es totalmente a favor de Trump). Todo este posible análisis es respecto de nuestra IA, no de la estándar.

La segunda hipótesis que queda en duda es la familiaridad con la IA. En este caso, la correlación es positiva, a mayor familiaridad, más identifican nuestra IA. Es decir, que de existir esta correlación, nuestra IA engañaría mejor a las personas poco familiarizadas con la IA, que a las que la usarán relativamente más.

Respecto al resto de resultados, las p son demasiado altas para tenerlas en cuenta. No parece que exista ninguna correlación entre el resto de variables.

En conclusión, se confirma la hipótesis de la edad (a mayor edad, mayor engaño de nuestra IA) aunque con limitaciones. También se deja en duda dos posibles correlaciones, que seguramente sean débiles: las personas autopercebidas como de poco afines a Trump identifican mejor nuestra IA y las personas más familiarizadas con la IA también son menos proclives a ser engañadas por nuestra IA. No existe ninguna correlación de la IA sin fragmentos.

CAPÍTULO 7

Conclusiones

El análisis de este trabajo de final de grado ha permitido obtener una visión global y específica de los discursos de Donald Trump y su estrategia de campaña, así como del grado de credibilidad de la generación de discursos.

Extrayendo conclusiones de la primera parte, la estrategia discursiva de Trump es realmente interesante, aunque en algunos aspectos dista de lo que podríamos esperar de este perfil de político. Su estrategia está claramente marcada por el negativismo, donde los sentimientos de asco y enfado son los principales dominadores. Trump no es conciliador ni espera serlo, tiene una estrategia combativa y polarizadora. Sin embargo, su foco ha virado, la inmigración ha dejado de ser un foco tan importante, para serlo la seguridad y la salud pública. Trump confronta con sentimiento negativo estos problemas, y los achaca especialmente a la administración anterior.

El análisis descriptivo no solo se queda en la estrategia básica, también analiza la utilización de estas mismas emociones. Una de las conclusiones es que, en ocasiones, existen temáticas que se tratan de formas específicas. La educación es claramente un tema alegre del que estar orgullosos, y la seguridad es un tema preocupante con el que deberían enfadarse. La conclusión que se muestra en esta parte del análisis es que, si bien Trump no se adapta a todos los temas, aquellos más importantes para él, como la salud, la educación y la seguridad, son tratados de forma diferente para obtener un mayor impacto en el electorado.

Cuando analizamos por estados obtenemos una conclusión similar, aunque muy razonable. Trump perfila unas líneas básicas de utilización de temáticas que replica generalmente. Pero sabe adaptarla a aquellos estados donde una preocupación es más grande, para capitalizar ese interés y traducirlo en votos. El ejemplo más claro son la diferencia de riqueza entre estados: mientras que en estados ricos desprioriza los discursos sobre economía e infraestructura, en estados más pobres los potencia especialmente para capitalizar su descontento y necesidad.

También se analiza la estrategia electoral respecto de la temporalidad y situación de sus discursos. Extraemos dos conclusiones realmente interesantes. Primeramente, la estrategia de Donald Trump es clara, priorizar por encima de todo los *swing states* incluso si en el resto de estados no puede realizar ningún discurso. Y en segundo lugar, Trump tiende a moderarse y a mandar más mensajes y emociones positivas a medida que se acercan las elecciones. El negativismo sigue siendo predominante, pero en proporciones mucho menores.

Por último, una de las conclusiones más llamativas la obtenemos desgranando el intento de homicidio de Trump. El actual presidente salió de su intento de homicidio con un discurso de victoria y alegría que supuso un punto de inflexión y anomalía increíblemente destacado durante su campaña. Lejos de hundirse, utilizó aquel discurso de

vuelta para realizar un discurso en las antípodas de lo que solía hacer. La evidencia demuestra que este hecho sí que tuvo efecto en las tendencias de sus discursos. A partir de aquel momento, la tendencia hacia el positivismo y las emociones positivas incrementó, aunque nunca llegó a superar de forma absoluta al negativismo.

En la segunda parte del trabajo de fin de grado generábamos discursos y analizábamos su credibilidad para comprobar si los resultados de la generación eran positivos. Además, esta encuesta, al recoger datos del perfil de las personas, permite, no solo comprobar la credibilidad, si no establecer estudios de poblaciones sobre la capacidad de engaño de la IA.

La primera conclusión a la que podemos acceder es que el trabajo tiene un resultado exitoso. Discursos generados por la IA con prompts parecidos puntúan mucho peor que los generados gracias a la recuperación de fragmentos proporcionados por los *embeddings* y el índice FAISS. Específicamente, el recuperado consigue una mejora porcentual del 29,17% frente a una sin fragmentos. Nuestro proceso aún no es capaz de suplantar a Trump con totalidad, pero se queda cerca, más exactamente a un 6,71%.

La segunda conclusión clara a extraer de este apartado es que existe una correlación entre la edad y la capacidad de nuestra IA para engañar a una persona. Según el muestro de 108 personas, la edad influye activamente, a mayor edad, mayor probabilidad hay de engaño de nuestra IA. Sin embargo hay que reconocer las limitaciones del muestreo e interpretar esta correlación con cautela. Por esto mismo, se expone en las ampliaciones una mejor prueba de esto.

7.1 Ampliaciones y estudios futuros

Este trabajo, si bien completo, es una prueba de concepto en muchas de sus vertientes. Algunos de los puntos a ampliar se exponen a continuación.

- **Exploración de otros periodos electorales o pre-electorales:** Resultaría de interés analizar como Trump ha cambiado su estrategia respecto de sus elecciones de 2016 y 2020. También podría ser interesante desvelar como de diferente es su campaña para la candidatura republicana de su campaña para la casa blanca.
- **Exploración de Kamala Harris:** Explorar las diferencias entre las estrategias discursivas de Trump y Harris podría arrojar más luz sobre la utilización de la política en EE.UU. y sobre las razones del resultado electoral del 2024.
- **Realizar un estudio cruzado con las estimaciones de votación:** Cruzar la utilización de los sentimientos con la intención de voto en tiempo real, si se dispone de estos datos, podría realmente aportar una profundidad muy grande al estudio
- **Utilización de modelos entrenados para la realización de discursos:** Si se dispone de los recursos, en vez de utilizar un modelo de lenguaje y realizar la tarea de *prompting*, se podría entrenar a un modelo de lenguaje, incluso propio, con todas las etiquetas, para obtener resultados más depurados.
- **Inclusión de análisis de audio y vídeo:** Definitivamente la mejor ampliación posible es incluir el audio y el vídeo de los discursos y analizarlo con otras herramientas de IA de detección de sentimientos a través de ello. Acabaría de enriquecer definitivamente el análisis y hacerlo replicable a cualquier contexto.
- **Muestreo probabilístico estratificado:** El muestreo realizado en el trabajo dista de ser ideal. Con los medios adecuados se podrían corroborar con mucha mayor certeza las hipótesis que se plantean en este trabajo.

Bibliografía

- [1] Patrick Henry Winston. *Artificial intelligence*. Addison-Wesley Longman Publishing Co., Inc., 1984.
- [2] Yifan Yao et al. «A survey on large language model (llm) security and privacy: The good, the bad, and the ugly». En: *High-Confidence Computing* (2024), pág. 100211.
- [3] Fouad Nasser A Al Omran y Christoph Treude. «Choosing an NLP library for analyzing software documentation: a systematic literature review and a series of experiments». En: *2017 IEEE/ACM 14th international conference on mining software repositories (MSR)*. IEEE. 2017, págs. 187-197.
- [4] Josh Achiam et al. «Gpt-4 technical report». En: *arXiv preprint arXiv:2303.08774* (2023).
- [5] MICHAEL LAVER, KENNETH BENOIT y JOHN GARRY. «Extracting Policy Positions from Political Texts Using Words as Data». En: *American Political Science Review* 97.2 (2003), 311–331. DOI: [10.1017/S0003055403000698](https://doi.org/10.1017/S0003055403000698).
- [6] Justin Grimmer. «A Bayesian Hierarchical Topic Model for Political Texts: Measuring Expressed Agendas in Senate Press Releases». En: *Political Analysis* 18.1 (2010), 1–35. DOI: [10.1093/pan/mpp034](https://doi.org/10.1093/pan/mpp034).
- [7] Hadi Jelodar et al. «Latent Dirichlet Allocation (LDA) and Topic Modeling: Models, Applications, a Survey». En: *Multimedia Tools and Applications* 78.11 (2019), págs. 15169-15211.
- [8] Tengfei Liu, Nevin L Zhang y Peixian Chen. «Hierarchical latent tree analysis for topic detection». En: *Machine Learning and Knowledge Discovery in Databases: European Conference, ECML PKDD 2014, Nancy, France, September 15-19, 2014. Proceedings, Part II* 14. Springer. 2014, págs. 256-272.
- [9] Luis M de Campos et al. «LDA-based term profiles for expert finding in a political setting». En: *Journal of Intelligent Information Systems* 56 (2021), págs. 529-559.
- [10] Yu Wang. «Topic Classification for Political Texts with Pretrained Language Models». En: *Political Analysis* 31.4 (2023), 662–668. DOI: [10.1017/pan.2023.3](https://doi.org/10.1017/pan.2023.3).
- [11] Moritz Osnabrügge, Elliott Ash y Massimo Morelli. «Cross-domain topic classification for political texts». En: *Political Analysis* 31.1 (2023), págs. 59-80.
- [12] Yongqin Xian et al. «Latent embeddings for zero-shot classification». En: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, págs. 69-77.
- [13] Jeffrey Pennington, Richard Socher y Christopher D Manning. «Glove: Global vectors for word representation». En: *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*. 2014, págs. 1532-1543.
- [14] Xin Li, Yuhong Guo y Dale Schuurmans. «Semi-supervised zero-shot classification with label representation learning». En: *Proceedings of the IEEE international conference on computer vision*. 2015, págs. 4211-4219.

- [15] Gavin Abercrombie y Riza Theresa Batista-Navarro. «'Aye' or 'No'? Speech-level Sentiment Analysis of Hansard UK Parliamentary Debate Transcripts». En: *11th International Conference on Language Resources and Evaluation*. European Language Resources Association. 2018, págs. 4173-4180.
- [16] Antoni Mestre et al. «Sentiment-Enriched AI for Toxic Speech Detection: A Case Study of Political Discourses in the Valencian Parliament». En: ().
- [17] Valerio Ficcadenti, Roy Cerquetti y Marcel Ausloos. «A Joint Text Mining-Rank Size Investigation of the Rhetoric Structures of the US Presidents' Speeches». En: *arXiv preprint arXiv:1905.04705* (2019). URL: <https://arxiv.org/abs/1905.04705>.
- [18] Ana Lorena Jiménez-Preciado et al. «The Power of Words from the 2024 United States Presidential Debates: A Natural Language Processing Approach». En: *Information* 16.1 (2024), pág. 2.
- [19] Valentin Kassarnig. «Political speech generation». En: *arXiv preprint arXiv:1601.03313* (2016).
- [20] Israel Cohen et al. «Pearson correlation coefficient». En: *Noise reduction in speech processing* (2009), págs. 1-4.
- [21] Sanford Weisberg. *Applied linear regression*. Vol. 528. John Wiley & Sons, 2005.
- [22] Clark Wissler. «The Spearman correlation formula». En: *Science* 22.558 (1905), págs. 309-311.
- [23] Emmanuel Bisong. «Google AutoML: Cloud Natural Language Processing». En: *Building Machine Learning and Deep Learning Models on Google Cloud Platform*. Berkeley, CA: Apress, 2019, págs. 447-457.
- [24] Prakash M Nadkarni, Lucila Ohno-Machado y Wendy W Chapman. «Natural language processing: an introduction». En: *Journal of the American Medical Informatics Association* 18.5 (2011), págs. 544-551.
- [25] Brand Safety Assessment. «MeaningCloud at TASS 2018: News Headlines Categorization for». En: ().
- [26] Somasekhar Giddaluru et al. «Stance Detection in Hinglish Data using the BART-large-MNLI Integration Model». En: *Engineering, Technology & Applied Science Research* 14.4 (2024), págs. 15477-15481.
- [27] Comparative Agendas Project. *PAP 2019 Codebook*. https://comparativeagendas.s3.amazonaws.com/codebookfiles/Codebook_PAP_2019.pdf. Accessed May 19, 2025. 2019.
- [28] Rahat Izhar, Shahid Nazir Bhatti y Sultan A Alharthi. «An NLP-Enabled Approach to Semantic Grouping for Improved Requirements Modularity and Traceability». En: *International Journal of Advanced Computer Science & Applications* 16.2 (2025).
- [29] Saif M Mohammad y Peter D Turney. «Nrc emotion lexicon». En: *National Research Council, Canada* 2 (2013), pág. 234.
- [30] Johannes Hartmann. *emotion-english-distilroberta-base*. <https://huggingface.co/j-hartmann/emotion-english-distilroberta-base>. Available at <https://huggingface.co/j-hartmann/emotion-english-distilroberta-base>. 2023. URL: <https://huggingface.co/j-hartmann/emotion-english-distilroberta-base>.
- [31] Dorottya Demszky et al. «GoEmotions: A dataset of fine-grained emotions». En: *arXiv preprint arXiv:2005.00547* (2020).
- [32] Victor Sanh et al. «DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter». En: *arXiv preprint arXiv:1910.01108* (2019).
- [33] Zhilin Yang et al. «Breaking the softmax bottleneck: A high-rank RNN language model». En: *arXiv preprint arXiv:1711.03953* (2017).

- [34] Paul Ekman y Wallace V. Friesen. «Constants across cultures in the face and emotion». En: *Journal of Personality and Social Psychology* 17.2 (1971), págs. 124-129.
- [35] Yinhan Liu et al. «Roberta: A robustly optimized bert pretraining approach». En: *arXiv preprint arXiv:1907.11692* (2019).
- [36] Francesco Barbieri et al. *TweetEval: Unified Benchmark and Comparative Evaluation for Tweet Classification*. <https://huggingface.co/cardiffnlp/twitter-roberta-base-sentiment>. Modelo disponible en <https://huggingface.co/cardiffnlp/twitter-roberta-base-sentiment>. 2020. URL: <https://huggingface.co/cardiffnlp/twitter-roberta-base-sentiment>.
- [37] Francesco Barbieri et al. «TweetEval: Unified benchmark and comparative evaluation for tweet classification». En: *arXiv preprint arXiv:2010.12421* (2020).
- [38] Richard Socher et al. «Recursive deep models for semantic compositionality over a sentiment treebank». En: *Proceedings of the 2013 conference on empirical methods in natural language processing*. 2013, págs. 1631-1642.
- [39] Kamil Topal y Gultekin Ozsoyoglu. «Movie review analysis: Emotion analysis of IMDb movie reviews». En: *2016 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining (ASONAM)*. IEEE. 2016, págs. 1170-1176.
- [40] Caroline Le Pennec y Vincent Pons. *How do campaigns shape vote choice? Multi-country evidence from 62 elections and 56 TV debates*. Inf. téc. National Bureau of Economic Research, 2019.
- [41] Gary C Jacobson. «How do campaigns matter?» En: *Annual Review of Political Science* 18.1 (2015), págs. 31-47.
- [42] Roll Call. *Roll Call: Congressional News and Insight*. Accedido el 19 de mayo de 2025. 2024. URL: <https://rollcall.com/>.
- [43] Anton Razzhigaev et al. «LLM-Microscope: Uncovering the Hidden Role of Punctuation in Context Memory of Transformers». En: *arXiv preprint arXiv:2502.15007* (2025). Aceptado en NAACL 2025.
- [44] Yubo Wang et al. «Mmlu-pro: A more robust and challenging multi-task language understanding benchmark». En: *The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track*. 2024.
- [45] Mansooreh Karami et al. «"Let's Eat Grandma": Does Punctuation Matter in Sentence Representation?» En: *arXiv preprint arXiv:2101.03029* (2022).
- [46] Hassan Saif et al. «On Stopwords, Filtering and Data Sparsity for Sentiment Analysis of Twitter». En: *Proceedings of the Ninth International Conference on Language Resources and Evaluation (LREC'14)*. Reykjavik, Iceland: European Language Resources Association (ELRA), 2014, págs. 810-817.
- [47] Mahdi Rezapour. «Emotion Detection with Transformers: A Comparative Study». En: *arXiv preprint arXiv:2403.15454* (2024).
- [48] Renyi Qu, Ruixuan Tu y Forrest Bao. «Is Semantic Chunking Worth the Computational Cost?» En: *arXiv preprint arXiv:2410.13070* (2024).
- [49] Aman Jaiswal y Evangelos Milios. «Breaking the token barrier: Chunking and convolution for efficient long text classification with bert». En: *arXiv preprint arXiv:2310.20558* (2023).
- [50] Maor Ivgi, Uri Shaham y Jonathan Berant. «Efficient long-text understanding with short-text models». En: *Transactions of the Association for Computational Linguistics* 11 (2023), págs. 284-299.

- [51] Kevin Judd y Alistair Mees. «Embedding as a modeling problem». En: *Physica D: Nonlinear Phenomena* 120.3-4 (1998), págs. 273-286.
- [52] Wenhui Wang et al. «Minilm: Deep self-attention distillation for task-agnostic compression of pre-trained transformers». En: *Advances in neural information processing systems* 33 (2020), págs. 5776-5788.
- [53] Jeff Johnson, Matthijs Douze y Hervé Jégou. «Billion-scale similarity search with GPUs». En: *IEEE Transactions on Big Data* 7.3 (2019), págs. 535-547.
- [54] Ben Naismith, Phoebe Mulcaire y Jill Burstein. «Automated evaluation of written discourse coherence using GPT-4». En: *Proceedings of the 18th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2023)*. 2023, págs. 394-403.
- [55] Sander Schulhoff et al. «The prompt report: A systematic survey of prompting techniques». En: *arXiv preprint arXiv:2406.06608* 5 (2024).
- [56] Robert L Logan IV et al. «Cutting down on prompts and parameters: Simple few-shot learning with language models». En: *arXiv preprint arXiv:2106.13353* (2021).
- [57] Elad Ben Zaken, Shauli Ravfogel y Yoav Goldberg. «Bitfit: Simple parameter-efficient fine-tuning for transformer-based masked language-models». En: *arXiv preprint arXiv:2106.10199* (2021).
- [58] Xi Ye y Greg Durrett. «The unreliability of explanations in few-shot prompting for textual reasoning». En: *Advances in neural information processing systems* 35 (2022), págs. 30378-30392.
- [59] Rick Copeland. *Essential sqlalchemy*. "O'Reilly Media, Inc.", 2008.
- [60] Matthijs Douze et al. «The faiss library». En: *arXiv preprint arXiv:2401.08281* (2024).

APÉNDICE A

Anexos

A.1 Recogida de datos

A continuación se pueden observar las preguntas que se formularon en la primera parte de la encuesta de verificación:

1. ¿En qué rango de edad te sitúas?

- 18–29
- 30–39
- 40–49
- 50–59
- 60+

2. ¿Cuánto de informado crees que estás sobre la actualidad estadounidense?

- 1 (Nada informado)
- 2
- 3
- 4
- 5 (Muy informado)

3. ¿Cuántas veces has escuchado discursos o declaraciones de Donald Trump?

- 1 (Nunca)
- 2
- 3
- 4
- 5 (Muchas veces)

4. ¿Cuál es tu nivel de simpatía con Donald Trump?

- 1 (Ninguna simpatía)
- 2
- 3
- 4
- 5
- 6
- 7 (Máxima simpatía)

5. ¿Con qué frecuencia utilizas la IA generativa en tu día a día (p.ej. ChatGPT, Deepseek, Perplexity...)?

- 1 (Nunca)
- 2
- 3
- 4
- 5 (Todos los días)

**6. ¿Cómo de acuerdo estás con esta afirmación?: “Soy escéptico con lo que veo. Sue-
lo comprobar la veracidad de la información que obtengo.”**

- 1 (Totalmente en desacuerdo)
- 2
- 3
- 4
- 5 (Totalmente de acuerdo)

A.2 Test de verificación

A continuación, se muestran todos los discursos que se expusieron en la segunda parte de la encuesta de verificación:

Primer Discurso:

"We have a disgrace at our border, a catastrophe like never before! They're pouring in by the millions: murderers, criminals, terrible people! And you know who's letting it happen? Crooked Joe Biden! Weak, pathetic, America-Last leadership Under my administration, we had the safest, and most secure border in history! The Wall was going up big and beautiful. Remember that? Remember "Zero Tolerance? Remember Remain in Mexico? Of course you do, because it worked! But now? It's an invasion! They're stealing your jobs, your schools, your hospitals—and some of them... not all... but some... are very bad people! And let me tell you something. The Democrats don't care! They want open borders because they want illegals to vote for them! It's a scam! They're rigging America!"

Segundo Discurso:

"The border, we're going to make it strong very quickly. We're going to get people out that are criminals and horrible people, but we're also going to do something else. Drill, baby, drill. Two things. On that same day, we will begin the task of finding and deporting

every single illegal alien gang member from our country. We'll get them out. This will be a major, national undertaking according to newly published data from ICE. The great patriots of ICE, I call them. These guys are tough as hell, I tell you. They should be fighting for Dana White, UFC, ICE. You got to see them. They go in MS-13. That's another beautiful gang. They're tough as hell. They've taken them out by the thousands. She wants to end ICE. She doesn't want to have ICE. But they informed us that over the last short period of time, 13,099 illegal aliens, convicted of murder, are at large and dropped into the United States against their wishes, against our Border Patrol's wish the wishes of our Border Patrol. They were saying, "Please don't do this. Please don't do this".

Tercer Discurso:

"They're sick people. And you know why? You know why they do this? Because we're winning. We're all winning. Just remember that. Everything Kamala says is a lie. She says I want to take away Medicare and Social Security. It's crazy. I would never say that. Who would say that? Because if you do say that, that's your – number one, it would be wrong. And number two, it's the end of your political career. So, who would say that? I never said that. She said, "He wants to immediately end Social Security." She's crazy. Hillary Clinton wouldn't lie like that. We can't stand Hillary. She's crooked as hell. She says I want to end Obamacare, affordable health, OK? No, I never said that. You got to, - I fixed it. I made it good, but it still stinks, OK? If we got something better, I would do it, if it was less expensive. It's too expensive, and it's not a very good form of health care. But if we got something better, I'd do it, but I never said I'm going to end it. She said, "He wants to immediately end it." She talks about Project 2025 all the time. I have nothing to do with it. I've said it every way possible. I even said to a very good lawyer, "Am I allowed to sue them for continuously "We put it in writing. We sent it. And the lawyer said, "Well, sir, you're running a campaign".

Cuarto Discurso:

"Thank you, thank you very much, everybody. Wow, what a crowd, what a crowd! You know, they don't show this. The fake news, they never show this. They don't want to admit that we're doing something great here, something really great. We're talking about education. Yes, education the thing that makes America great. And you know, folks, I love education. I went to the Wharton School of Finance, one of the best in the world. They say it's the hardest school to get into, the best school in the world. Did very well. So, I know a thing or two about education. Now, let's talk about what's happening in our schools. You've got these left-wing lunatics, these radical Democrats, trying to take over our classrooms, and it's a disgrace, folks. It's a disgrace. They want to teach our children to hate America. Can you believe that? But we won't let that happen, folks. Not on my watch. We're going to make education great again. Yes, we are, folks. We're going to bring back patriotism in our schools, teach our kids to love this country just like we do. Isn't that great? Isn't that what we want? And we're going to get rid of this radical, destructive curriculum that's trying to infiltrate our schools. We won't stand for it. We won't stand for it. Now, remember this, folks. They can try to take over our schools, but they can't take away our spirit. They can't take away our love for this great nation."

Quinto discurso:

"First, we had the most incredible vaccines developed in record time, thanks to Operation Warp Speed. The fastest in history! And now, we're going to make health care more affordable, more accessible, and more phenomenal than ever before. No more Obamacare disasters—we're going to replace it with something terrific. But wait, I have a surprise for you. You know, the Fake News never talks about how we lowered drug pri-

ces, how we fought for America First health care. But today, I'm announcing something huge—something nobody saw coming. We're going to eliminate the individual mandate forever! No more forcing you to buy bad, overpriced insurance. Freedom! And that's not all... We're launching "trump care". A revolutionary new plan where you choose your doctor, you get the best prices, and you keep your freedom. No bureaucrats. No nonsense. Just winning! And one more thing, because the Democrats hate this, we're bringing back short-term health plans! Cheap, flexible, America-first coverage. The swamp hates it, which means you're going to love it!"

Sexto discurso:

"This country, our beloved America, is being taken advantage of, and it's something we must talk about. It's a big, big problem folks, believe me. We're being laughed at by the world. We've got people coming in, and they're not sending their best. They're sending people that have lots of problems. They're bringing drugs. They're bringing crime. They're rapists. And some, I assume, are good people. But we've got to face facts folks, the good ones are not the majority. We're losing our jobs, we're losing our country. This isn't about being politically correct, this is about being correct! We're being drained, we're being bled dry. We can't afford it anymore, folks. We just can't. I've seen what's happening, and it's not pretty. I've been around the world, I've seen the good, the bad, and the ugly. And let me tell you, what's happening here, it's ugly. We're losing our identity, our culture, our values. We're losing the essence of America, folks. It's a disgrace. We've got to get tough, folks. We've got to get smart. We have to put America first, not these people who are just walking in, taking our jobs, taking our money, taking our safety. We can't let it happen. We just can't."

Séptimo Discurso:

"He's going to formally grant a mass amnesty to millions of illegal aliens that came into our country. And you have people you have people that have been working for ten years to try and come in legally, and they just keep working. Under this program, a deluge of illegals will be given immediate green cards and put on the fast track to rapid citizenship so they can vote. I think a lot of them are going to vote for me. You want to know the truth? Because if you look at the Hispanic population, if you look at the black population, they're voting for Trump, they're voting for Trump. You, you, look at you, you. Thank you. I like that person right there. But they give them free welfare. They give them free health care, food stamps. Chain migration, chain migration, one of the catastrophic things, one of the many catastrophic things that we're confronted with when they come in. Crooked Joe is sending a message to the world that he rewards illegal entry, and that's what's happening. They hear about all of the things that are coming in. And don't kid yourself, the ones that are hurt the most, the Black population, the Hispanic population. And you know what else who else is hurt badly? Unions. Because unions are not able to compete with this. This is a mass entry into our country, and the unions are getting absolutely killed by it."

A.3 Respuestas del test

En la tabla A.1 se puede comprobar cual era la fuente de cada discurso de la encuesta.

Discurso	Fuente
Primer discurso	IA sin fragmentos
Segundo discurso	Donald Trump, Aurora, Colorado, 11 de octubre de 2024
Tercer discurso	Donald Trump, Henderson, Nevada, 31 de octubre de 2024
Cuarto discurso	IA con fragmentos
Quinto discurso	IA sin fragmentos
Sexto discurso	IA con fragmentos
Séptimo discurso	Donald Trump, Racine, Wisconsin, 18 de junio de 2024

Tabla A.1: Relación entre los discursos utilizados y su fuente

A.4 Abreviaturas de los estados

En la tabla A.2 se pueden consultar las abreviaturas de cada uno de los estados donde Trump dio un discurso de campaña.

Abreviatura	Nombre del estado
PA	Pennsylvania
NC	North Carolina
MI	Michigan
WI	Wisconsin
GA	Georgia
AZ	Arizona
NV	Nevada
VA	Virginia
NY	New York
NM	New Mexico
MT	Montana
MN	Minnesota
FL	Florida
CO	Colorado
CA	California

Tabla A.2: Correspondencia entre abreviaturas y nombres completos de los estados representados en la Figura 6.5.

A.5 Acceso público a la base de datos de los discursos

Disponible en: [Donald Trump Speeches 2024 - Kaggle](#)

Anexo B – Relación del TFG con los Objetivos de Desarrollo Sostenible (ODS)

ODS	Nombre	Alto	Medio	Bajo	No procede
1	Fin de la pobreza				X
2	Hambre cero				X
3	Salud y bienestar				X
4	Educación de calidad	X			
5	Igualdad de género		X		
6	Agua limpia y saneamiento				X
7	Energía asequible y no contaminante				X
8	Trabajo decente y crecimiento económico			X	
9	Industria, innovación e infraestructura		X		
10	Reducción de las desigualdades		X		
11	Ciudades y comunidades sostenibles				X
12	Producción y consumo responsables				X
13	Acción por el clima				X
14	Vida submarina				X
15	Vida de ecosistemas terrestres				X
16	Paz, justicia e instituciones sólidas	X			
17	Alianzas para lograr los objetivos		X		

Tabla A.3: Grado de relación del TFG con los Objetivos de Desarrollo Sostenible

Este Trabajo de Fin de Grado se relaciona especialmente con los siguientes ODS:

- **ODS 4 – Educación de calidad:** el proyecto promueve el desarrollo de competencias digitales, analíticas y éticas en el uso de tecnologías avanzadas como la inteligencia artificial generativa y el análisis de datos.

- **ODS 5 – Igualdad de género:** el análisis de discursos permite detectar y reflexionar sobre posibles sesgos de género, contribuyendo a la equidad en la comunicación política.

- **ODS 9 – Industria, innovación e infraestructura:** el trabajo impulsa la innovación metodológica en el análisis automatizado de lenguaje político y el uso de tecnologías punteras como los modelos generativos de lenguaje.

- **ODS 10 – Reducción de las desigualdades:** el estudio facilita la identificación de narrativas que reproducen o combaten desigualdades sociales y discursivas, fomentando un enfoque crítico e inclusivo.

- **ODS 16 – Paz, justicia e instituciones sólidas:** fomenta la transparencia, el pensamiento crítico y la participación democrática mediante el análisis automatizado y reproducible del discurso político.

- **ODS 17 – Alianzas para lograr los objetivos:** el TFG se basa en datos abiertos, software libre y prácticas de ciencia abierta, promoviendo la colaboración interdisciplinar y la transferencia de conocimiento.